

Generación de datos clínicos sintéticos mediante modelos generativos profundos

Grado en Ciencia e Ingeniería de
Datos

Trabajo Fin de Grado

Autor:

Álvaro Espejo Martínez

Tutor/es:

José Manuel Juárez Herrero

Bernardo Cánovas Segura

Generación de datos clínicos sintéticos mediante modelos generativos profundos

Evaluación de la fidelidad estadística, la utilidad analítica y la privacidad sobre MIMIC-III

Autor

Álvaro Espejo Martínez

Tutor/es

José Manuel Juárez Herrero

Departamento de Ingeniería de la Información y las Comunicaciones

Bernardo Cánovas Segura

Departamento de Informática y Sistemas

Grado en Ciencia e Ingeniería de Datos



Facultad
de Informática
UMU



UNIVERSIDAD
DE MURCIA

Murcia, 28 de Mayo de 2026

Agradecimientos

Puede parecer que la entrega del TF es un mero trámite, y a efectos prácticos lo es, algo por lo que pasa todo el mundo. En mi caso, no puedo negar que este proyecto lleva consigo un peso emocional que refleja el broche de una etapa. Mirando atrás, considero este espacio una bonita oportunidad para darles las gracias a todas las personas que han formado parte de ella, desde profesores a familia, pasando por los compañeros de clase, algunos de ellos ya amigos para toda la vida, que han compartido la experiencia de ser la primera promoción de este grado. Miro atrás como el que sabe que no puede evitar que algo llega a su fin mientras la nostalgia se apodera de él, pero con la plenitud de haber vivido una experiencia por la que no puedo estar más agradecido. Por todo ello, gracias.

Declaración firmada sobre originalidad del trabajo

D. **Álvaro Espejo Martínez**, con DNI **09224070N**, estudiante de la titulación de **Grado en Ciencia e Ingeniería de Datos** de la Universidad de Murcia y autor del TF titulado “**Generación de datos clínicos sintéticos mediante modelos generativos profundos**”.

De acuerdo con el Reglamento por el que se regulan los Trabajos Fin de Grado y de Fin de Máster en la Universidad de Murcia (aprobado C. de Gob. 30-04-2015, modificado 22-04-2016 y 28-09-2018), así como la normativa interna para la oferta, asignación, elaboración y defensa de los Trabajos Fin de Grado y Fin de Máster de las titulaciones impartidas en la Facultad de Informática de la Universidad de Murcia (aprobada en Junta de Facultad 27-11-2015)

DECLARO:

Que el Trabajo Fin de Grado presentado para su evaluación es original y de elaboración personal. Todas las fuentes utilizadas han sido debidamente citadas. Así mismo, declara que no incumple ningún contrato de confidencialidad, ni viola ningún derecho de propiedad intelectual e industrial

Murcia, a 28 de Mayo de 2026



Fdo.: Álvaro Espejo Martínez
Autor del TF

Resumen

A diferencia de otros ámbitos biomédicos, la escasez de datos clínicos abiertos relacionados con la historia clínica en UCI limita severamente el desarrollo de modelos predictivos. El objetivo de este proyecto es proponer y evaluar un marco de generación de registros clínicos en una Unidad de Cuidados Intensivos. Con este objetivo, se explora el potencial de tres familias de modelos generativos (CTGAN, TVAE Y TabDDPM) juntos con cuatro variantes de DP-CTGAN con privacidad diferencial formal. Hemos evaluado experimentalmente su capacidad a partir de 22.520 registros provenientes de UCI de la base de datos MIMIC-III. Tras aplicar criterios de inclusión sobre primera estancia, duración mínima de 48 horas y edad adulta, se obtiene una cohorte de 22.520 estancias representadas como snapshot tabular de 127 variables. La evaluación se articula en tres dimensiones independientes: fidelidad estadística (JSD, KS, MMD², distancia de Wasserstein, error en la matriz de correlaciones), utilidad analítica (protocolo TSTR sobre predicción de mortalidad y sepsis con cuatro clasificadores) y privacidad (DCR, NNDR, ventaja de ataque de inferencia de pertenencia). Los resultados muestran que TVAE y CTGAN reproducen la distribución clínica real con fidelidad muy alta (JSD mediana $< 0,01$) y una degradación de utilidad inferior a 0,04 puntos de AUROC. La incorporación de privacidad diferencial introduce un coste controlado y cuantificable: entre 0,03 y 0,08 puntos de AUROC al pasar de $\varepsilon = \infty$ a $\varepsilon = 1$, con una reducción simultánea del 26 % en la ventaja del atacante. El hallazgo más relevante desde el punto de vista práctico es que el *data augmentation* con datos sintéticos recupera prácticamente el rendimiento del entrenamiento sobre datos reales en todos los modelos, incluyendo la variante con mayor protección formal ($\varepsilon = 1$).

Extended Abstract

Introduction

The digitisation of healthcare has generated unprecedented volumes of clinical records, yet access to such data remains severely restricted. Privacy regulations such as HIPAA in the United States and the GDPR in the European Union impose strict controls on the sharing of patient information, limiting the ability of researchers and developers to build and validate predictive models. Traditional anonymisation techniques, including the removal of direct identifiers or the application of k -anonymity, have been shown to be insufficient in high-dimensional settings: Rocher et al. demonstrated that 99.98 % of Americans can be uniquely re-identified using just 15 demographic attributes, and genomic aggregate studies have shown that individual membership in a cohort can be inferred from summary statistics alone. The core problem is that anonymisation reduces utility without providing verifiable privacy guarantees, and that the curse of dimensionality makes quasi-identifier combinations effectively unique in clinical datasets.

Synthetic data generation offers a principled alternative. Rather than sharing real records, a generative model learns the underlying statistical distribution of the training data and produces a new dataset whose statistical properties mirror those of the original without containing actual patient records. This approach has attracted growing interest in the biomedical domain, where the combination of clinical richness and regulatory constraints makes it an especially compelling solution.

This work implements, trains and evaluates a comprehensive framework for synthetic clinical data generation over MIMIC-III, a publicly available critical care database. Seven generative configurations are compared across three independent evaluation dimensions: statistical fidelity, analytical utility and privacy. The experimental results provide quantitative evidence of the feasibility of replacing or supplementing real clinical data with synthetic alternatives, and characterise the cost of incorporating formal differential privacy guarantees.

Dataset and Preprocessing

MIMIC-III (Medical Information Mart for Intensive Care III) is a de-identified clinical database comprising records from patients admitted to the intensive care units (ICUs) of the Beth Israel Deaconess Medical Center in Boston between 2001 and 2012.

Access requires completion of the CITI Program training and signing a Data Use Agreement with PhysioNet.

The raw database contains over 330 million rows in the CHARTEVENTS table alone, recording minute-level physiological measurements collected by two distinct clinical information systems: CareVue and MetaVision. Reconciling measurements across these systems required mapping duplicate item identifiers (ITEMIDs) to a unified set of clinical signals.

A cohort of 22,520 ICU stays was constructed by applying three inclusion criteria: first ICU stay per patient, length of stay of at least 48 hours, and patient age of at least 18 years at admission. Each stay was then transformed into a tabular snapshot by computing four aggregate statistics (mean, minimum, maximum and standard deviation) over the first 48 hours of monitoring for each of ten vital signs and eighteen laboratory biomarkers. Together with nine administrative and demographic variables and five binary comorbidity flags derived from ICD-9 diagnosis codes, the resulting dataset contains 127 columns per patient, with 22,520 rows. The target variable is `hospital_expire_flag`, indicating in-hospital mortality, with a prevalence of 13.8 %.

The ten vital signs included are heart rate, systolic blood pressure, diastolic blood pressure, mean arterial pressure, oxygen saturation, body temperature, respiratory rate and the three components of the Glasgow Coma Scale (GCS): eye response (1–4), verbal response (1–5) and motor response (1–6). A notable characteristic of ICU populations is that intubated patients receive a verbal GCS score of 1 by definition, producing a zero-inflated distribution that poses a specific challenge for generative models. The eighteen laboratory biomarkers span renal function (creatinine, blood urea nitrogen), hepatic function (bilirubin, albumin), metabolic state (lactate, glucose), acid-base balance (base excess, arterial pH, PaO₂, PaCO₂, bicarbonate), electrolytes (sodium, potassium), haematology (haemoglobin, platelets, white blood cell count, INR) and cardiac function (troponin).

Missing values were handled through a differentiated imputation strategy: forward-fill followed by backward-fill during time-series aggregation, and population median imputation for the tabular snapshot. This reduced the missing value rate from 32.4 % to 0 % without introducing distributional artefacts.

Generative Models

Four generative architectures were implemented and evaluated, yielding seven model configurations in total.

CTGAN adapts the Generative Adversarial Network framework to tabular data through two key contributions. First, a Variational Gaussian Mixture Model (VGM) normalises each continuous column into a scalar value and a one-hot mode indicator, allowing the generator to handle multimodal marginal distributions. Second, a conditional vector and training-by-sampling mechanism address class imbalance by ensuring

that all category values are sampled proportionally during training. The discriminator employs the PacGAN strategy, processing groups of ten samples simultaneously to discourage mode collapse. Both generator and discriminator are multi-layer perceptrons trained with the Wasserstein GAN with gradient penalty (WGAN-GP) objective. Training ran for 300 epochs with a batch size of 500.

TVAE applies the Variational Autoencoder framework with the same VGM preprocessing pipeline. An encoder compresses each input row into a Gaussian latent space, and a decoder reconstructs the original distribution. The training objective is the Evidence Lower Bound (ELBO), combining a reconstruction term with a KL divergence regularisation penalty. The encoder and decoder each use two hidden layers of 128 units with an L2 regularisation weight of 10^{-5} . TVAE produces more stable training dynamics than CTGAN and generally yields smoother but more complete coverage of the data distribution.

TabDDPM adapts the Denoising Diffusion Probabilistic Model to tabular data. A cosine noise schedule progressively corrupts the training data over $T = 1000$ steps, and a four-layer residual MLP with SiLU activations and 512 units per layer learns to reverse this process. Categorical variables are handled via multinomial diffusion with a transition matrix that converges to a uniform distribution as noise accumulates. Sinusoidal positional encodings are used to condition the network on the current diffusion step t . The model was trained for 1000 epochs with a learning rate of 3×10^{-4} and a batch size of 4096.

DP-CTGAN incorporates formal differential privacy guarantees into the CTGAN training procedure using the DP-SGD algorithm. In each iteration, per-sample gradients for the discriminator are computed individually, clipped to a maximum ℓ_2 norm of $C = 1.0$, and perturbed with calibrated Gaussian noise before the parameter update. The privacy budget is tracked using the Rényi Differential Privacy (RDP) moments accountant as implemented in Opacus. The generator, which never directly accesses real data, is trained without noise. Four privacy budgets were evaluated: $\varepsilon \in \{1, 5, 10, \infty\}$ with $\delta = 1/N \approx 4.4 \times 10^{-5}$, where $\varepsilon = \infty$ corresponds to DP-SGD training with the clipping mechanism but without noise injection. To ensure compatibility with the Opacus per-sample gradient hooks, DP-CTGAN omits the VGM transformation and conditional sampling used in standard CTGAN; this architectural simplification, rather than the noise itself, accounts for the performance gap between DP-CTGAN $\varepsilon = \infty$ and CTGAN.

Evaluation Framework

The evaluation framework covers three independent dimensions, each designed to capture a distinct aspect of synthetic data quality.

Statistical fidelity measures the similarity between real and synthetic data distributions using five complementary metrics. The Jensen-Shannon Divergence (JSD),

estimated via 50-bin histograms over the real data range for each of the 121 numerical columns, provides a symmetric and bounded measure of marginal distributional discrepancy. The Kolmogorov-Smirnov statistic (KS) captures the maximum absolute difference between empirical CDFs without requiring binning, making it sensitive to tail behaviour. The squared Maximum Mean Discrepancy (MMD²) with an RBF kernel using the median heuristic for bandwidth selection assesses distributional discrepancy in a kernel-induced feature space. The first Wasserstein distance (W1), computed on the first two PCA components, provides a geometric measure of the cost of transporting probability mass. Finally, the mean absolute error between real and synthetic Pearson correlation matrices ($\Delta\rho$) captures whether inter-variable relationships are preserved. Visual inspection via UMAP projections jointly embedding real and synthetic samples, and an XGBoost discriminator test targeting an AUC close to 0.5, complement the quantitative metrics.

Analytical utility follows the Train on Synthetic, Test on Real (TSTR) protocol. Four classifiers (logistic regression, random forest with 200 trees, XGBoost and a two-hidden-layer MLP) are trained exclusively on synthetic data and evaluated on a fixed stratified hold-out of 4,504 real patients. Performance is compared against the Train on Real, Test on Real (TRTR) baseline trained on 18,016 real samples. The primary metric is the Area Under the ROC Curve (AUROC), with $\Delta\text{AUROC} = \text{AUROC}_{\text{TSTR}} - \text{AUROC}_{\text{TRTR}}$ quantifying degradation. Two clinical prediction tasks are evaluated: in-hospital mortality (prevalence 13.8%) and sepsis risk, proxied by a qSOFA score ≥ 2 (prevalence 16.6%). A data augmentation experiment combines 50% real and 50% synthetic training data to assess whether synthetic records can complement rather than fully replace real ones.

Privacy is evaluated through three metrics benchmarked against a real hold-out reference set. The Distance to Closest Record (DCR) measures, for each synthetic sample, the Euclidean distance to its nearest neighbour in the real training set after standardisation. The Nearest Neighbour Distance Ratio (NNDR) computes the ratio of the first to second nearest neighbour distances: values close to 1 indicate generalisation, while values near 0 signal potential memorisation of individual records. The Membership Inference Attack (MIA) advantage measures the probability that a synthetic sample is geometrically closer to the training set than to the hold-out set, minus the 0.5 random baseline. All three metrics are compared against the same statistics computed for real hold-out samples, which serve as a calibration reference and naturally exhibit a positive MIA advantage due to the size asymmetry between the training and hold-out partitions.

Índice general

1. Introducción	1
1.1. La escasez de datos abiertos en la inteligencia artificial médica	1
1.2. Síntesis de datos clínicos	2
1.3. Un problema todavía abierto	3
1.4. Estructura de la memoria	4
2. Estado del arte	7
2.1. Barreras de acceso y disponibilidad de datos clínicos	7
2.1.1. La Cuestión Ético-Legal de la Privacidad de los Datos	9
2.1.2. ¿Por qué no simplemente anonimizar?	10
2.1.3. K-anonimidad, ¿Solución?	11
2.1.4. Probabilidad de una Reidentificación Exitosa	14
2.1.5. La agregación como nuevo frente de vulnerabilidad	16
2.2. Fundamentos de modelos generativos profundos	17
2.2.1. Modelos Discriminativos frente a Modelos Generativos	17
2.2.2. Redes Generativas Antagónicas (GANs)	17
2.2.3. Autoencoders Variacionales (VAEs)	18
2.2.4. Modelos de Difusión	18
2.2.5. Modelos para Datos Secuenciales: TimeGAN	19
2.3. Uso de datos sintéticos en investigación biomédica	20
2.3.1. Aplicaciones Principales	20
2.3.2. Marco de Evaluación de Datos Sintéticos	20
2.4. Modelos para generación de datos médicos sintéticos	21
2.4.1. Síntesis de Registros Tabulares	22
2.4.2. Síntesis de Series Temporales Clínicas	22
2.4.3. Privacidad Diferencial en Síntesis de Datos Clínicos	23
2.4.4. Síntesis comparativa	23
2.5. MIMIC-III como banco de pruebas estándar	24
3. Objetivos y Metodología	27
3.1. Objetivo general	27
3.2. Subobjetivos	27
3.3. Metodología	28
3.3.1. Fuente de datos y construcción de la cohorte	28
3.3.2. Pipeline de preprocesamiento	29

3.3.3.	Selección y diseño de los modelos generativos	29
3.3.4.	Marco de evaluación	29
4.	Desarrollo	31
4.1.	Dataset y Preprocesamiento	31
4.1.1.	El dataset MIMIC-III	31
4.1.2.	Definición de la cohorte	32
4.1.3.	Selección de variables clínicas	33
4.1.4.	Pipeline de preprocesamiento	34
4.1.5.	Dos representaciones del mismo dato	37
4.1.6.	Análisis exploratorio	39
4.2.	Modelos Generativos: Diseño e Implementación	41
4.2.1.	Diseño experimental y decisiones arquitectónicas	41
4.2.2.	Modelos tabulares: CTGAN y TVAE	44
4.2.3.	Modelo de difusión: TabDDPM	48
4.2.4.	Privacidad diferencial: fundamentos y aplicación	50
5.	Experimentación y Resultados	55
5.1.	Evaluación de Fidelidad Estadística	55
5.1.1.	Metodología de evaluación de fidelidad	55
5.1.2.	Métricas de distribuciones marginales	56
5.1.3.	Métricas de distribuciones conjuntas	57
5.1.4.	Análisis visual: UMAP y t-SNE	58
5.1.5.	Test de discriminación	58
5.1.6.	Discusión comparativa de fidelidad	60
5.2.	Validación de Utilidad Analítica	64
5.2.1.	Framework de validación TRTR/TSTR	65
5.2.2.	Tarea principal: predicción de mortalidad	65
5.2.3.	Experimento de data augmentation clínico	66
5.2.4.	Tarea secundaria: detección de sepsis	67
5.2.5.	Discusión comparativa de utilidad	69
5.3.	Análisis de Riesgos de Privacidad	69
5.3.1.	Marco de auditoría de privacidad	69
5.3.2.	Distancia al registro más cercano (DCR y NNDR)	70
5.3.3.	Ventaja de inferencia de pertenencia (MIA)	71
5.3.4.	Efecto de la privacidad diferencial sobre la MIA	73
5.3.5.	Frontera Pareto privacidad-utilidad	74
6.	Conclusiones	75
6.1.	Conclusiones	75
6.2.	Trabajo futuro	77
	Bibliografía	79

A. Variables del snapshot tabular (22.520 × 127)	85
B. Fidelidad estadística por variable	89
C. Glosario de términos técnicos y clínicos	91
D. Declaración de uso de herramientas de IA generativa	95

Índice de figuras

3.1.	Fases metodológicas del trabajo. Los resultados de cada fase alimentan la siguiente.	28
4.1.	Pipeline experimental del trabajo: desde los datos crudos de MIMIC-III hasta las tres dimensiones de evaluación de los datos sintéticos generados.	31
4.2.	Porcentaje de estancias de la cohorte sin ningún registro para cada constante vital dentro de la ventana de 48h. Valores calculados sobre los datos crudos extraídos de CHARTEVENTS, antes de imputación. .	36
4.3.	Evolución temporal de cuatro constantes vitales durante las primeras 48h para una muestra de cinco estancias. Las trayectorias en azul corresponden a supervivientes y en rojo a pacientes fallecidos.	39
4.4.	Distribuciones de seis variables clínicas clave segmentadas por la variable objetivo (azul: supervivientes, rojo: fallecidos).	41
4.5.	Mapa de correlaciones de Pearson entre variables clínicas clave y la variable objetivo en el snapshot tabular.	42
5.1.	Proyecciones UMAP (arriba) y t-SNE (abajo) del espacio de <i>features</i> para cada modelo generativo. Los puntos grises representan muestras reales y los de color muestras sintéticas. El alto grado de solapamiento en CTGAN y TVAE indica indistinguibilidad distribucional global; la separación visible en TabDDPM es consecuencia directa de sus distribuciones marginales distorsionadas.	59
5.2.	Distribución de la JSD por variable para cada modelo generativo. La línea central de cada caja representa la mediana reportada en la Tabla 5.1; la caja muestra el rango intercuartílico sobre las 121 variables evaluadas. La diferencia de dos órdenes de magnitud entre TabDDPM y el resto de modelos refleja la distorsión sistemática de sus distribuciones marginales.	61
5.3.	Matrices de correlación de Pearson del dataset real y de cada modelo generativo. El color indica dirección e intensidad de la correlación (rojo: positiva, azul: negativa). TVAE y CTGAN reproducen fielmente la estructura de correlaciones del dataset original; DP-CTGAN $\varepsilon=1$ presenta una matriz casi uniforme, coherente con su $\Delta\rho = 0,376$	63

5.4.	Distribuciones DCR por modelo generativo. El panel superior izquierdo muestra el holdout real como referencia. La línea discontinua negra indica la mediana del holdout (7,35); la línea del color del modelo, su propia mediana. La distribución de DP-CTGAN $\varepsilon=1$ exhibe una cola pronunciada hacia la derecha (mayoría de muestras muy alejadas del dataset real) junto con un pequeño peso en valores bajos, efecto característico del ruido gaussiano de DP-SGD.	72
5.5.	Ventaja de inferencia de pertenencia (MIA advantage) por modelo generativo. La línea discontinua gris indica la referencia del holdout real (+0,390); todos los modelos se sitúan por debajo, lo que indica que ningún generador revela más información sobre el conjunto de entrenamiento de la que revelaría un nuevo paciente real de la misma distribución. Las líneas de puntos naranja y roja marcan los umbrales orientativos de riesgo moderado (0,10) y alto (0,20).	73
5.6.	Izquierda: frontera Pareto privacidad-utilidad. El eje X recoge el AUROC TSTR (utilidad, mayor es mejor) y el eje Y la MIA advantage (privacidad, menor es mejor; eje invertido). La línea discontinua gris indica la MIA advantage del holdout real como referencia. Derecha: curva de tradeoff ε para las variantes DP-CTGAN; eje izquierdo MIA advantage (morado), eje derecho AUROC TSTR (naranja).	74
B.1.	Divergencia Jensen-Shannon por variable y por modelo generativo. Cada punto representa una de las 121 variables numéricas evaluadas. Las variables con mayor JSD corresponden a los componentes GCS (en DP-CTGAN) y a los biomarcadores con distribuciones de cola larga como albúmina, troponina y bilirrubina (en TabDDPM).	90

Índice de tablas

2.1.	Comparativa de los principales trabajos de síntesis de datos clínicos revisados en este capítulo. DP: privacidad diferencial.	24
4.1.	Estadísticas descriptivas de la cohorte final.	33
4.2.	Mapeo de ITEMID entre CareVue y MetaVision para constantes vitales.	34
4.3.	Rangos fisiológicos máximos aplicados en la validación de constantes vitales.	36
4.4.	Prevalencia de comorbilidades en la cohorte final ($N = 22.520$), derivadas de <code>DIAGNOSES_ICD</code> mediante códigos ICD-9.	40
4.5.	Modelos generativos entrenados en este trabajo, familia a la que pertenecen y su rol en el marco experimental.	43
4.6.	Hiperparámetros de CTGAN y TVAE. Los valores marcados con $(\dagger)$ son comunes a ambos modelos.	47
4.7.	Hiperparámetros de TabDDPM y comparativa con CTGAN/TVAE.	51
4.8.	Configuración de DP-CTGAN. Los hiperparámetros de arquitectura son idénticos a CTGAN (Tabla 4.6).	54
5.1.	Métricas de fidelidad estadística por modelo generativo. Mejor valor en negrita.	61
5.2.	Resultados TRTR y TSTR para predicción de mortalidad intrahospitalaria, promediados sobre cuatro clasificadores <i>downstream</i> . Δ AUROC mide la diferencia respecto al baseline TRTR. Los modelos DP-CTGAN se ordenan de menor a mayor privacidad (mayor a menor ε).	66
5.3.	Comparación de AUROC entre TSTR puro y TSTR con <i>data augmentation</i> (50 % real + 50 % sintético) para predicción de mortalidad. La columna “Ganancia” recoge la diferencia de AUROC entre augmentation y TSTR puro.	67
5.4.	AUROC para detección de sepsis ($qSOFA \geq 2$) en el experimento TSTR. XGBoost como clasificador único. La columna de prevalencia indica el porcentaje de pacientes $qSOFA+$ en el dataset sintético.	68

5.5.	Métricas de privacidad por modelo. DCR y NNDR calculados frente al dataset real completo (22.520 registros). MIA advantage: fracción de muestras sintéticas más cercanas al training que al holdout, menos 0,5. La fila de referencia corresponde al holdout real, cuyos valores representan el comportamiento esperado para datos nuevos de la misma distribución.	71
A.1.	Variables administrativas y demográficas (9 columnas).	85
A.2.	Constantes vitales: 10 señales $\times$ 4 estadísticos + GCS total = 41 columnas.	86
A.3.	Biomarcadores de laboratorio: 18 variables $\times$ 4 estadísticos = 72 columnas.	86
A.4.	Comorbilidades binarias derivadas de DIAGNOSES_ICD (5 columnas).	87
B.1.	Las 20 variables con mayor JSD mediana entre los siete modelos. Las celdas sombreadas corresponden a $JSD > 0,30$	89
D.1.	Resumen de herramientas de IAG empleadas en la elaboración del TFG.	96

1. Introducción

A lo largo del Grado en Ciencia e Ingeniería de Datos, las prácticas con datos reales han sido una constante: datasets de ventas, encuestas sociológicas, registros meteorológicos, imágenes de benchmark. Sin embargo, en ningún momento del currículo aparecieron datos clínicos. La pregunta era inevitable: ¿por qué no? Cuando uno busca datasets médicos para practicar, la respuesta llega rápido: formularios de acceso, cursos de ética obligatorios, acuerdos de uso de datos, comités institucionales. La información existe, pues los hospitales generan enormes volúmenes de datos cada día, pero está en la práctica fuera del alcance de cualquier investigador que no pertenezca a una institución con acceso privilegiado. Esta experiencia, repetida en muchos rincones de la comunidad investigadora, constituye el punto de partida del presente trabajo.

1.1. La escasez de datos abiertos en la inteligencia artificial médica

La inteligencia artificial ha demostrado en la última década un potencial transformador en medicina: sistemas de apoyo al diagnóstico, modelos de predicción de deterioro clínico, herramientas de estratificación del riesgo y algoritmos de detección precoz de enfermedades son algunos de los dominios en los que el aprendizaje automático ha alcanzado, o incluso superado, el rendimiento de especialistas humanos [1]. Este progreso, no obstante, descansa sobre una premisa que raramente se discute con la atención que merece: todos estos modelos necesitan datos, y en medicina los datos de calidad son extraordinariamente difíciles de obtener.

Por qué los datos clínicos escasean. Los registros clínicos, incluyendo historiales electrónicos, constantes vitales, resultados de laboratorio, imágenes médicas y notas de enfermería, contienen información de una sensibilidad inigualable en otros dominios. Su gestión está regulada por marcos legales estrictos: la *Health Insurance Portability and Accountability Act* (HIPAA) en Estados Unidos y el Reglamento General de Protección de Datos (RGPD) en Europa establecen obligaciones muy precisas sobre quién puede acceder a qué información, bajo qué condiciones y con qué salvaguardas [2]. El resultado práctico es que los datos clínicos de alta calidad quedan en gran medida confinados dentro de los sistemas de información de los centros sanitarios, inaccesibles para la investigación sin un largo proceso burocrático e institucional [3]. Esta restricción no solo frena el avance científico: también genera asimetrías de poder profundas, pues

mientras las instituciones académicas navegan procesos de acceso que pueden durar meses, actores tecnológicos privados acumulan capacidades de inferencia sobre salud a través de fuentes no reguladas.

Por qué la anonimización no basta. La respuesta técnica más intuitiva a esta restricción ha sido la **anonimización**: eliminar o enmascarar los identificadores directos (nombre, número de historia clínica, fecha de nacimiento exacta) para desligar los registros de los pacientes a los que pertenecen. Sin embargo, la investigación ha demostrado de forma reiterada que esta solución es insuficiente. Sweeney [4] mostró que una combinación de apenas tres atributos aparentemente inocuos (código postal, fecha de nacimiento y sexo) permite identificar de forma única al 87 % de la población estadounidense. En datos de salud de alta dimensionalidad, donde cada registro contiene decenas o cientos de variables correlacionadas, el riesgo de re-identificación es aún más elevado: Rocher et al. [5] demostraron que es posible re-identificar a individuos con alta probabilidad incluso en datasets fuertemente muestreados. La historia está salpicada de casos en que registros clínicos teóricamente anonimizados fueron vinculados a individuos reales mediante fuentes de datos auxiliares de acceso público [6]. La anonimización ofrece, en definitiva, una protección aparente pero no formal, y su aplicación en entornos de alta dimensionalidad como los EHR de UCI resulta insuficiente.

1.2. Síntesis de datos clínicos

Ante las limitaciones estructurales de la anonimización, la comunidad investigadora ha explorado una alternativa conceptualmente diferente: en lugar de modificar los datos reales para proteger a los pacientes, **generar datos sintéticos** que preserven las propiedades estadísticas de los originales sin corresponder a ningún paciente real. Si los datos sintéticos son estadísticamente indistinguibles de los reales y no permiten inferir información sobre individuos concretos, pueden compartirse sin comprometer la privacidad. Esta perspectiva ha impulsado una línea de investigación activa durante la última década.

Los primeros enfoques: reglas y modelos estadísticos. Las primeras aproximaciones a la síntesis de datos clínicos se apoyaron en modelos estadísticos paramétricos o en reglas definidas por expertos. Synthea [7] es el ejemplo más representativo: un simulador que genera pacientes sintéticos siguiendo modelos de progresión de enfermedades codificados manualmente por clínicos. Aunque produce registros estructuralmente realistas, los datos generados no capturan las correlaciones complejas y los patrones latentes presentes en registros reales de UCI, lo que limita su utilidad para entrenar modelos predictivos de alto rendimiento.

La irrupción de los modelos generativos profundos. La aparición de las redes generativas adversariales (GAN) [8] y los autoencoders variacionales (VAE) [9] abrió una vía radicalmente distinta: modelos capaces de aprender la distribución de los datos de entrenamiento y muestrear nuevas instancias que siguen esa misma distribución, sin requerir modelado explícito por parte de expertos. Su aplicación al dominio médico fue casi inmediata. Choi et al. [10] propusieron medGAN, una de las primeras arquitecturas GAN diseñadas específicamente para generar registros clínicos discretos de alta dimensionalidad. Beaulieu-Jones et al. [11] demostraron sobre datos del dataset MIMIC-III [12] que las GAN pueden generar datos clínicos sintéticos que preservan la utilidad para modelos predictivos mientras reducen el riesgo de re-identificación. En paralelo, Xu et al. [13] abordaron los retos específicos de los datos tabulares, como las distribuciones multimodales, la mezcla de tipos de variables y el desequilibrio de clases, con CTGAN y TVAE, modelos generativos adaptados explícitamente a esta estructura. Más recientemente, los modelos de difusión [14, 15] han extendido estos resultados, mostrando ventajas de estabilidad de entrenamiento y cobertura de la distribución que los posicionan como una alternativa competitiva frente a las arquitecturas adversariales.

La privacidad diferencial como garantía formal. El marco teórico de la **privacidad diferencial** (DP) [16] ha aportado algo que los enfoques anteriores no podían ofrecer: una garantía matemática sobre la cantidad máxima de información que un modelo puede filtrar sobre cualquier individuo del conjunto de entrenamiento. Jordon et al. [17] propusieron PATE-GAN, integrando DP en la síntesis de datos con garantías formales verificables. La combinación de modelos generativos con DP-SGD [18], implementada mediante librerías como Opacus [19], ha permitido extender las garantías formales de privacidad a arquitecturas arbitrarias, abriendo la posibilidad de cuantificar el coste en calidad de síntesis que supone imponer distintos niveles de protección.

1.3. Un problema todavía abierto

A pesar del notable avance de los últimos años, la generación de datos clínicos sintéticos de alta calidad sigue siendo un **problema sin resolver** en varios frentes relevantes.

La evaluación carece de estándares consolidados. Uno de los déficits más evidentes en la literatura es la ausencia de un marco de evaluación unificado. Los trabajos existentes miden distintas combinaciones de métricas —estadísticas univariantes, matrices de correlación, rendimiento en tareas *downstream*, ataques de inferencia— sin que exista consenso sobre cuáles son necesarias y suficientes para certificar que unos datos sintéticos son adecuados para un uso concreto [20]. Esta fragmentación dificulta la comparación entre modelos y hace que los resultados de un estudio sean difícilmente trasladables a otro contexto.

El tradeoff privacidad–utilidad no está bien caracterizado. Aunque la privacidad diferencial ofrece una garantía formal, su efecto sobre la calidad de los datos generados en escenarios clínicos reales no ha sido sistemáticamente cuantificado. En entornos de UCI, con la alta dimensionalidad, el desbalance de clases y las distribuciones multimodales que caracterizan los registros clínicos, la pregunta de cuánta utilidad analítica se pierde al reducir el presupuesto de privacidad de $\varepsilon = 10$ a $\varepsilon = 1$, o en qué medida el parámetro formal ε se traduce en una reducción real y medible del riesgo inferencial, no tiene respuesta consolidada en la literatura.

La comparación sistemática entre familias de modelos sigue pendiente. La mayor parte de los trabajos existentes evalúan un único modelo generativo, o comparan modelos dentro de una misma familia, sobre conjuntos de datos y métricas heterogéneos. Una comparativa rigurosa que enfrente representantes de las tres familias generativas principales —redes adversariales, autoencoders variacionales y modelos de difusión— sobre el mismo dataset, con el mismo protocolo de evaluación y en las tres dimensiones de calidad (fidelidad, utilidad y privacidad) de forma simultánea, está aún por realizarse en el contexto específico de los datos clínicos de UCI.

La validación clínica sigue siendo una asignatura pendiente. La mayoría de los trabajos evalúan la calidad de los datos sintéticos en términos estadísticos o de rendimiento predictivo, pero raramente someten los datos generados a una validación clínica real: ¿reconocerían médicos especialistas estos registros como clínicamente plausibles? ¿Preservan los patrones que tienen significado diagnóstico? La distancia entre la validación estadística y la validación clínica es uno de los escollos no resueltos del campo.

En conjunto, la generación de datos clínicos sintéticos que sean simultáneamente fieles estadísticamente, útiles para modelos predictivos y privados de forma verificable, evaluados con rigor en las tres dimensiones sobre datos reales de UCI, continúa siendo un reto abierto de primera magnitud, tanto para la investigación en inteligencia artificial como para su transferencia a la práctica médica.

1.4. Estructura de la memoria

El presente trabajo aborda este reto de forma sistemática a lo largo de seis capítulos. El **Capítulo 2** revisa el estado del arte en generación de datos sintéticos, con especial atención a las arquitecturas generativas adaptadas al dominio tabular y a los marcos formales de privacidad diferencial. El **Capítulo 3** concreta los objetivos específicos del trabajo y describe el marco metodológico que articula el diseño experimental. El **Capítulo 4** detalla la construcción de la cohorte a partir de MIMIC-III, el pipeline de preprocesamiento y la implementación de los cuatro modelos generativos evaluados (CTGAN, TVAE, TabDDPM y DP-CTGAN). El **Capítulo 5** presenta los resultados experimentales organizados en tres dimensiones independientes: fidelidad estadística de

las distribuciones generadas, utilidad analítica medida mediante el protocolo TSTR y cuantificación del riesgo de privacidad mediante ataques de inferencia de pertenencia. Finalmente, el **Capítulo 6** sintetiza las conclusiones por objetivo específico, discute las limitaciones del trabajo e identifica las líneas de extensión más prometedoras.

2. Estado del arte

La investigación biomédica contemporánea se enfrenta a una paradoja fundamental: mientras que la disponibilidad de registros electrónicos de salud (EHR) ha crecido exponencialmente, el acceso a estos datos para el entrenamiento de modelos de aprendizaje automático permanece severamente restringido por preocupaciones legítimas sobre la privacidad del paciente y marcos regulatorios estrictos como el Reglamento General de Protección de Datos (GDPR) en Europa y la Health Insurance Portability and Accountability Act (HIPAA) en los Estados Unidos. En este escenario, la generación de datos sintéticos (SDG) ha emergido no solo como una técnica de preservación de la privacidad, sino como un pilar metodológico para la democratización de la ciencia de datos en salud [20]. El objetivo central de la SDG es producir conjuntos de datos artificiales que mantengan la fidelidad estadística y la utilidad analítica de los datos reales sin contener información que permita la re-identificación de individuos. El presente capítulo revisa el estado del arte de los modelos generativos, desde sus fundamentos teóricos hasta su aplicación específica en la síntesis de datos tabulares y temporales sobre el dataset MIMIC-III [12], estableciendo el marco conceptual y la justificación bibliográfica del trabajo.

2.1. Barreras de acceso y disponibilidad de datos clínicos

El uso de datos clínicos reales en investigación no solo plantea dificultades éticas y legales, sino que resulta extraordinariamente costoso y complejo incluso cuando se siguen todos los procedimientos regulatorios establecidos. Esta sección analiza las barreras estructurales que limitan el acceso a los datos biomédicos y justifican la necesidad de alternativas sintéticas.

Data Deluge. En la actualidad, el sector sanitario así como tantos otros se enfrenta a lo que se conoce como "diluvio de datos", una explosión que hace necesario la reconfiguración de la arquitectura de la medicina moderna. Basta con observar distintas métricas para dimensionar este fenómeno. Según estimaciones de IDC citadas por Dash et al. [1], el volumen de datos creció de 130 exabytes (EB) en 2005 a aproximadamente 16.000 EB en 2017, con una proyección que alcanzó los 40.000 EB en 2020. Esta masa crítica de información, caracterizada por las cuatro Vs (Volumen, Velocidad, Variedad y Veracidad), constituye el combustible indispensable para la medicina de precisión. El

ecosistema se nutre de una heterogeneidad de fuentes que incluye Registros de Salud Electrónicos (EHR), datos ómicos (genómica de alta resolución mediante NGS y estudios GWAS), información del Internet de las Cosas (IoT) a través de biosensores, y el flujo constante de dispositivos móviles (*mHealth*). La transformación de este "ruido" masivo en conocimiento clínico accionable depende de un flujo analítico riguroso que transita desde la Analítica Descriptiva (qué ocurre) y Diagnóstica (por qué ocurre), hacia la Analítica Predictiva y, finalmente, la Prescriptiva. Esta última es la que permite optimizar la toma de decisiones clínicas mediante algoritmos que sugieren intervenciones personalizadas. Sin embargo, existe una brecha ontológica entre el potencial teórico de la analítica avanzada y la utilidad clínica real; la inercia infraestructural actual y la complejidad en el manejo de estos volúmenes impiden que la medicina personalizada sea hoy una norma generalizada. Esta incapacidad técnica para gestionar la escala de datos nos conduce directamente a analizar las barreras de infraestructura que fragmentan el conocimiento.

La Barrera de la Gestión. Desde una perspectiva de la gobernanza del dato, la disponibilidad de información para la investigación clínica avanzada está supeditada a la robustez de la infraestructura tecnológica. Para su aprovechamiento real, no basta con almacenar; es imperativo procesar. A pesar de las herramientas que se presentan para ello, la falta de una arquitectura estandarizada en los centros de salud actúa como un primer gran filtro que asfixia la disponibilidad de datos. Los desafíos de gestión son profundos:

- **Volumen y Almacenamiento.** A medida que la tecnología y la medicina avanzan, nuevos registros han de ser considerados a la hora de almacenar. El escalado de redes locales resulta prohibitivo frente a la naturaleza exponencial que presenta el progreso.
- **Estructura.** La mayoría de los datos clínicos no son estructurados. Los formatos tradicionales en los EHR son insuficientes para capturar la complejidad fenotípica. La riqueza diagnóstica suele quedar sepultada en texto libre, dificultando la interoperabilidad semántica.
- **Calidad.** La integridad del dato exige un proceso de depuración riguroso. Un registro con inconsistencias puede invalidar cualquier hallazgo posterior que dependa de él.

Esta fragmentación, intensificada por la falta de interoperabilidad entre proveedores de EHR, crea silos de información que encarecen la innovación y privan al investigador de una visión holística del paciente. Sin embargo, incluso si resolviéramos la interoperabilidad técnica, nos enfrentaríamos a un muro aún más complejo: la naturaleza ultrasensible de la información clínica y los dilemas éticos asociados a su flujo.

2.1.1. La Cuestión Ético-Legal de la Privacidad de los Datos

La privacidad en salud no debe entenderse como un concepto estático, sino contextual. Siguiendo a Price & Cohen [2], la licitud del flujo de información depende de los actores, los procesos y, fundamentalmente, el propósito del acceso. En este marco, las preocupaciones éticas se bifurcan en dos dimensiones:

Preocupaciones consecuencialistas. Centradas en daños tangibles como la discriminación laboral o en seguros, el estigma social y la angustia emocional derivada de brechas de seguridad.

Preocupaciones deontológicas. El daño reside en la pérdida de control sobre los datos como una violación de la autonomía *per se*, incluso si el paciente no sufre un perjuicio material o desconoce el acceso.

Estos riesgos alimentan una desconfianza sistémica. El concepto de "equidad actuarial" (donde los seguros ajustan primas basándose en predicciones de riesgo hiperprecisas) choca con la visión solidaria de los sistemas de salud pública, amenazando con excluir a los individuos más vulnerables. Un ejemplo saliente de este riesgo de uso imprevisto es el caso de **GEDmatch**, donde bases de datos genéticas fueron utilizadas para identificar al "Golden State Killer", demostrando cómo la información compartida por un individuo compromete irreversiblemente la privacidad de sus familiares biológicos (privacidad relacional). Esta tensión evidencia que las herramientas de protección tradicionales, basadas en la desidentificación, son hoy peligrosamente insuficientes.

Para evidenciarlo, basta con observar la arquitectura legal vigente. En EE. UU., la **ley HIPAA** de 1996 se ha visto condenada a la obsolescencia con la irrupción del ecosistema del Big Data. HIPAA, actualmente, opera sobre una falsa sensación de seguridad al centrarse exclusivamente en entidades cubiertas, dejando desprotegida en el proceso la mayor parte de información que define el estado de salud de un individuo. Esta legislación únicamente recae sobre los datos generados en hospitales. Esto es un intento de protección que, si bien puede haber sido efectivo décadas atrás, presenta actualmente un peligro inequívoco para toda la población. Detrás de los datos generados en hospitales, en el área no regulada, reside la masa crítica de los datos: búsquedas en Google, LLMs, etc sobre síntomas, compras en Amazon y demás que podrían inferir estados como el embarazo, o el registro de la actividad en aplicaciones de bienestar, como la que incorporan de fábrica sistemas como Apple.

Esta rigidez regulatoria impone una asimetría competitiva: mientras los investigadores académicos están limitados por procesos de consentimiento exhaustivos, gigantes tecnológicos como Google, Apple o IBM operan fuera de HIPAA, acumulando un poder de inferencia masivo. Además, la desidentificación erosiona la utilidad científica: al fragmentar registros para proteger la privacidad, se pierde la capacidad de realizar estudios longitudinales, reduciendo el valor del dato para descubrimientos de largo plazo.

Nos encontramos, por tanto, ante un *trade-off* crítico: el exceso de celo en la privacidad puede asfixiar la innovación médica, mientras que su ausencia vulnera derechos fundamentales. Este escenario ha dado lugar a prácticas de **”Information Blocking”** [3], donde las corporaciones utilizan la privacidad del paciente como un escudo retórico para mantener los datos como secretos comerciales, impidiendo la validación externa y el avance de la ciencia abierta. El caso de **Myriad Genetics**, que mantuvo bases de datos propietarias sobre variantes genéticas BRCA1/2, ejemplifica cómo el secreto justificado en la privacidad puede perjudicar el diagnóstico clínico global. Para el investigador, este panorama de bloqueos estratégicos, riesgos de reidentificación y costos de cumplimiento hace que el acceso a datos clínicos reales sea extremadamente limitado y éticamente complejo. Ante este bloqueo sistémico, la **generación de datos sintéticos** emerge no solo como una alternativa técnica, sino como el camino más viable para realizar investigación de alta fidelidad sin comprometer la privacidad del paciente ni quedar paralizado por la obsolescencia normativa. Esta necesidad de preservar la utilidad analítica del dato sin exponer información individual constituye la motivación central del presente TFG.

2.1.2. ¿Por qué no simplemente anonimizar?

Se ha comentado anteriormente que el paradigma dominante para la protección de datos a la hora de liberar datos ha sido la anonimización. Tradicionalmente, las organizaciones han operado bajo la premisa de que eliminar identificadores directos (nombres o seguridad social) garantiza el anonimato. Debemos corregir esta confusión: la seguridad informática (control de acceso y autenticación) no es equivalente a la protección de la privacidad. Mientras que la primera asegura que solo el receptor autorizado acceda a los datos, la segunda debe garantizar que dicho receptor no pueda realizar inferencias re-identificadoras a partir de la información recibida.

Si bien es cierto que aparentemente pueda parecer que eliminando los identificadores directos de un sujeto, sus datos puedan parecer anónimos, lo realmente preocupante es que ni de esta manera podríamos asegurar la privacidad real de estos.

Quasi-identificadores. Latanya Sweeney [6] formalizó esta vulnerabilidad mediante el concepto de quasi-identificador. Se define como el conjunto de atributos que, sin ser identificadores directos (nombre, DNI, etc) pueden vincularse con fuentes de datos externas para reducir el conjunto de candidatos hasta un solo individuo. Estos atributos actúan como una huella digital debido a su presencia ubicua en registros públicos. La magnitud de esta vulnerabilidad se comprende mediante la “unicidad” poblacional. Sweeney demostró que combinaciones de atributos triviales son altamente discriminatorias; el 87% de la población estadounidense es única y re-identificable atendiendo exclusivamente al código postal, género y fecha de nacimiento [4].

Esto supone un problema ya que en múltiples instituciones se asume una confianza desmedida al liberar esta información, ya que se está ignorando que el receptor puede

cruzar los microdatos con registros de votantes, censos o bases de datos comerciales. Esta fragilidad teórica se materializó históricamente en ataques de vinculación que han ido transformando nuestras creencias acerca de la seguridad y la privacidad médica.

El caso de William Weld. El caso del gobernador William Weld en Massachusetts (1997) marcó un hito en la bioinformática forense. La Group Insurance Commission (GIC) liberó registros médicos "anonimizados" de 135,000 empleados estatales. Sweeney demostró la nulidad de esta protección mediante un ataque de vinculación (*linking attack*) utilizando la lista de votantes de Cambridge, adquirida por apenas 20 dólares [6]. El procedimiento técnico se basó en un "embudo" lógico de atributos compartidos. En la lista de votantes, Sweeney identificó que:

1. Seis personas compartían la fecha de nacimiento del gobernador.
2. De esas seis, solo tres eran hombres.
3. De esos tres, solo **uno** residía en su código ZIP de 5 dígitos.

Este conteo 6-3-1 permitió aislar el registro médico de Weld, exponiendo diagnósticos y prescripciones de una figura pública en un conjunto de datos supuestamente seguro. Este caso evidenció que el riesgo persiste incluso en condiciones restrictivas, impulsando la creación de modelos formales de privacidad como la k -anonimidad.

2.1.3. K-anonimidad, ¿Solución?

En este contexto, la k -anonimidad surgió como el estándar para mitigar ataques de vinculación en sistemas.

La **k -anonimidad** fue formalizada por Samarati y Sweeney [21] como el primer modelo formal de privacidad concebido para mitigar sistemáticamente los ataques de vinculación descritos en la sección anterior. Su principio rector establece que un conjunto de datos T con quasi-identificadores QI satisface la k -anonimidad si y solo si, para cada combinación de valores de QI que aparece en T , dicha combinación se repite en al menos k registros distintos. Formalmente:

$$\forall t \in T, \quad |\{t' \in T \mid t'[QI] = t[QI]\}| \geq k \quad (2.1)$$

La intuición es directa: si cada registro es indistinguible de otros $k - 1$, un atacante que conoce los quasi-identificadores de un individuo no puede reducir el conjunto de candidatos por debajo de k , garantizando una "denegación plausible" mínima.

Las dos operaciones clásicas empleadas para alcanzar el umbral son:

- **Generalización:** Los valores de los quasi-identificadores se reemplazan por representaciones menos específicas en una taxonomía predefinida. Por ejemplo, la edad exacta "34 años" se sustituye por el intervalo "30–40 años", o el código

postal "28080" por el prefijo "280**". La generalización preserva la semántica del atributo a costa de granularidad.

- **Supresión:** Los registros cuya combinación de quasi-identificadores es tan singular que no puede generalizarse hasta k sin destruir irreparablemente la utilidad analítica se eliminan del conjunto publicado.

Aplicado retroactivamente al caso Weld, una protección con $k = 3$ habría exigido que al menos dos individuos más compartiesen idéntica combinación de código postal, sexo y fecha de nacimiento, elevando significativamente el coste del ataque de vinculación.

A pesar de resultar un avance, la k -anonimidad ha demostrado ser vulnerable a ataques que pueden resultar en la re-identificación de los sujetos presentes en los registros que los sufren [6].

Evaluación de Riesgos de Inferencia. Han sido varios los métodos utilizados por los receptores para poder rescatar la información completa y personal detrás de los datos [6].

1. Unsorted Matching: Si el orden de los registros en la versión protegida mantiene una correlación con la fuente original, un atacante puede deducir identidades comparando la posición de los registros.
2. Complementary Release: Ocurre al liberar múltiples versiones del mismo dataset con diferentes atributos generalizados. Al unir las tablas, las protecciones se anulan, revelando registros únicos en la intersección de estos.
3. Temporal Attack: En bases de datos dinámicas, donde existe la necesidad de ser actualizadas en tiempo real, la adición de nuevas instancias permite inferencias mediante la comparación de versiones sucesivas. El fallo crítico reside en que la segunda liberación no tiene el requerimiento de respetar las distorsiones de la primera, permitiendo que los cambios revelen la identidad de los sujetos.

La investigación contemporánea cuestiona si el muestreo ofrece realmente la "denegación plausible" que muchos investigadores defienden como método de defensa.

El Desafío de la Alta Dimensionalidad en la Re-identificación. La explosión de datos generados por individuos (dispositivos IoT, registros electrónicos, aplicaciones móviles) ha terminado de invalidar el modelo clásico. En entornos de alta dimensionalidad, la probabilidad de que un individuo sea único es casi absoluta.

El estudio llevado a cabo por Rocher et al. [5] demostró que el 99,98 % de los estadounidenses podrían ser re-identificados en cualquier conjunto de datos usando solo 15 atributos demográficos, los cuales pueden encontrarse en registros públicos. La problemática se agrava al constatar que esta tasa de éxito se mantiene incluso cuando el dataset es parcial o está fuertemente muestreado. Para la demostración se utilizaron cópulas gaussianas para estimar el éxito de la re-identificación. Esta técnica es fundamental porque permite modelar las distribuciones marginales de forma separada a la estructura de la dependencia. Se distinguen dos métricas claves:

- x (Uniqueness): Probabilidad de que el individuo x sea único en la población total.
- x (Correctness): Probabilidad de que un *match* sea una re-identificación correcta, dado que el dataset es incompleto. Si el registro es único, $x = 1$. Si no lo es, la probabilidad disminuye según el número de personas que compartan los mismos atributos.

El desafío principal al evaluar el riesgo de reidentificación en conjuntos de datos fuertemente muestreados o incompletos es la imposibilidad de calcular directamente la distribución de probabilidad conjunta empírica, $p(x)$, debido a la escasez de datos. Para resolver esto, los autores modelan la distribución conjunta de los atributos $X_1, X_2, \dots, X_d$ utilizando una cópula gaussiana latente.

El uso de cópulas es fundamental porque permite modelar la densidad multivariante separando el problema en dos partes más manejables: las distribuciones marginales (que resultan fáciles de inferir incluso con muestras limitadas) y la estructura de dependencia global entre los atributos. Además, para un espacio muestral grande y un número pequeño de registros disponibles, las cópulas gaussianas proporcionan una buena aproximación de la densidad utilizando únicamente $d(d-1)/2$ parámetros para la matriz de covarianza, sin requerir hiperparámetros adicionales.

Formulación matemática de la cópula. La densidad de una cópula gaussiana, denotada como c_Σ , se define matemáticamente mediante la siguiente expresión:

$$c_\Sigma(u) = \frac{1}{\sqrt{\det \Sigma}} \exp \left(-\frac{1}{2} \Phi^{-1}(u)^T \cdot (\Sigma^{-1} - I) \cdot \Phi^{-1}(u) \right) \quad (2.2)$$

Donde:

- Σ es la matriz de covarianza que captura la dependencia entre los atributos.
- $u \in [0, 1]^d$ representa el vector de variables en el espacio uniforme.
- Φ es la función de distribución acumulativa (CDF, por sus siglas en inglés) de una distribución normal estándar univariante.

Adaptación a datos demográficos discretos. Un aspecto técnico crucial del modelo es la transición del espacio continuo de la cópula al espacio discreto de los atributos demográficos (como el código postal, el género o la edad). En la práctica, la distribución de la cópula es continua en el cubo unitario, pero la probabilidad $p(x)$ que se busca modelar es su contraparte discreta.

Para obtener la probabilidad de un registro específico $q(x|\Sigma, \Psi)$ (donde Ψ representa los parámetros marginales), el modelo integra la densidad continua latente dentro de un hiper-rectángulo definido por las componentes discretas del registro $(x_1, x_2, \dots, x_d)$. Matemáticamente, esto se formula como:

$$q(x|\Sigma, \Psi) = \int_{F_1^{-1}(x_1-1|\Psi)}^{F_1^{-1}(x_1|\Psi)} \cdots \int_{F_d^{-1}(x_d-1|\Psi)}^{F_d^{-1}(x_d|\Psi)} c_\Sigma(u) du \quad (2.3)$$

Dado que la función de distribución acumulativa de una cópula gaussiana no tiene una expresión de forma cerrada, esta integración se evalúa numéricamente. Específicamente, los autores utilizan un método cuasi-Monte Carlo aleatorizado propuesto por Genz y Bretz [22] para estimar esta densidad discreta.

2.1.4. Probabilidad de una Reidentificación Exitosa

Una vez definida la base matemática del modelo generativo, los autores demuestran empíricamente su capacidad para cuantificar el riesgo real de que un intento de reidentificación sea exitoso, incluso partiendo de un conjunto de datos altamente incompleto. Esta sección resulta crítica, ya que traslada el debate teórico a un escenario de amenaza práctico [5].

Estimación del riesgo individual en la práctica. Para ilustrar la aplicación del modelo, se plantea el caso de un individuo (hipotéticamente llamado "John Doe") diagnosticado con cáncer de mama. Dado un registro individual x , el modelo entrenado calcula la probabilidad $\hat{\xi}_x$ de que dicho registro sea único en la población total. Esta probabilidad se define como:

$$\hat{\xi}_x = (1 - q(x|\Sigma, \Psi))^{n-1} \quad (2.4)$$

El aspecto fundamental de esta estimación es que el modelo toma en cuenta tanto la prevalencia marginal (la frecuencia general del cáncer de mama) como la asociación global de los atributos (la rareza estadística del cáncer de mama específicamente en hombres). Dado que la función de distribución acumulativa de una cópula gaussiana no posee una expresión de forma cerrada, el término $q(x|\Sigma, \Psi)$ se evalúa mediante la integración numérica de la densidad conjunta continua latente dentro del hiper-rectángulo definido por los componentes del registro [5].

Capacidad predictiva y fiabilidad del modelo. Los resultados experimentales demuestran que el modelo es altamente preciso incluso en condiciones de escasez extrema de datos.

- **Alta precisión con datos mínimos:** Al entrenar el modelo utilizando únicamente una muestra del 1% de la población de EE. UU., este logra predecir de manera sobresaliente la unicidad individual, alcanzando un Área Bajo la Curva (AUC) ROC media de 0.89. Al evaluar el resto de las poblaciones del estudio, el AUC medio asciende a 0.93.
- **Baja Tasa de Falsos Descubrimientos (FDR):** La fiabilidad de las predicciones de alto riesgo es notable. Para aquellas reidentificaciones que el modelo predice como correctas con un umbral de confianza superior al 95% ($\hat{\xi}_x > 0.95$), la probabilidad de que la predicción sea incorrecta (Tasa de Falsos Descubrimientos) es de apenas el 5.26% en la población de EE. UU. , con un promedio del 6.67% en todas las poblaciones analizadas.

Superioridad frente a métricas poblacionales tradicionales. Finalmente, el estudio expone las deficiencias de los enfoques tradicionales que evalúan la privacidad basándose de manera uniforme en la unicidad poblacional global. Los autores comparan el rendimiento de su modelo frente a la mejor predicción teóricamente alcanzable utilizando únicamente la unicidad de la población, es decir, asignando una puntuación $\xi_x^{(pop)} = \Xi_x$ a cada individuo. Para medir la calibración de estas predicciones probabilísticas, se utiliza el *Brier Score* (BS)[5]. Los resultados revelan que el modelo basado en cópulas gaussianas obtiene puntuaciones de error un 39% más bajas que el mejor estimador a nivel poblacional. Esto subraya la necesidad crítica de modelar las características individuales de manera específica en lugar de depender de métricas de riesgo agregadas para garantizar la anonimización.

Actualización del caso William Weld [5]: El modelo determinó que, con los atributos básicos de Sweeney, el gobernador tenía una probabilidad de corrección $x=77\%$. Sin embargo, la inclusión de un solo atributo adicional (disponible en fuentes públicas) como el **número de hijos** (5 en el caso de Weld), eleva la probabilidad de una re-identificación exitosa y certera (x) al **99.8%**. Esto demuestra que la "denegación plausible" basada en el muestreo es estadísticamente insignificante frente a modelos generativos modernos.

Los hallazgos de Sweeney y Rocher fuerzan una redefinición del *dato personal*. Bajo el GDPR, los datos seudonimizados permanecen bajo el ámbito de la ley precisamente porque el riesgo de re-identificación es un resultado estadístico predecible, no un evento aleatorio.

2.1.5. La agregación como nuevo frente de vulnerabilidad

Los ataques de vinculación descritos anteriormente podrían sugerir que la publicación de estadísticas agregadas (en lugar de registros individuales) constituye una barrera suficiente para proteger la privacidad. Sin embargo, esta premisa también ha sido refutada. Los métodos convencionales de agregación son incapaces de mitigar la vulnerabilidad residual intrínseca a la información biológica, como demostró de forma definitiva el estudio de Homer et al. [23].

El caso de estudio. El artículo “*Resolving Individuals Contributing Trace Amounts of DNA to Highly Complex Mixtures Using High-Density SNP Genotyping Microarrays*” marcó un hito al demostrar que las estadísticas de nivel de resumen son insuficientes para evitar la re-identificación. Hasta su publicación, se creía que las frecuencias alélicas de un estudio de asociación genómica no contenían rastro suficiente para identificar a un participante individual. Sin embargo, el estudio demostró la capacidad de determinar, con confianza estadística irrefutable, la presencia de un individuo específico dentro de mezclas de ADN compuestas de miles de personas, probando que estadísticas de agregación como las frecuencias alélicas no enmascaran la identidad y permiten a un atacante con el genotipo del individuo inferir su participación en un estudio concreto.

La metodología del estudio tuvo su foco en un refinamiento estadístico basado en polimorfismos de nucleótido único (SNP). El estadístico se basa en la medida de distancia:

$$D(Y_{i,j}) = |Y_{i,j} - Pop_j| - |Y_{i,j} - M_j|$$

donde se compara al individuo (Y_i) con la mezcla (M) y una población de referencia (Pop). Debido al Teorema del Límite Central (CLT), la distribución de $D(Y_{i,j})$ a través de miles de SNPs tiende a la normalidad, permitiendo realizar una prueba t de una muestra (*one-sample t-test*).

El impacto fue tal que obligó a diversas instituciones a retirar de inmediato el acceso público a los datos agregados de sus bases de datos genómicas, demostrando la invalidez de esta metodología como protección ante ataques.

En un conjunto de datos sintéticos, no existen individuos reales. Por tanto, la distancia $|Y_{i,j} - M_j|$ se convierte en un valor nulo para cualquier sujeto físico. Los datos sintéticos ofrecen utilidad fuera de la muestra (*out-of-sample utility*), permitiendo que los modelos de investigación aprendan patrones sin memorizar identidades. A diferencia de la anonimización tradicional, los modelos generativos pueden ser diseñados para romper el ligamiento familiar excesivo, protegiendo la privacidad de los parientes mientras se mantiene la estructura de desequilibrio de ligamiento necesaria para el GWAS.

La industria enfrenta una división insalvable: garantizar el anonimato mediante supresión o ruido (destruyendo la utilidad científica) o mantener la fidelidad de los datos (exponiendo la identidad). Ante esta **Amenaza de la Re-identificación**, la generación de datos sintéticos mediante modelos generativos profundos aparece como la única

arquitectura viable.

2.2. Fundamentos de modelos generativos profundos

Para abordar el problema de la síntesis de datos, es necesario comprender el marco teórico que distingue los modelos generativos del paradigma discriminativo dominante en el aprendizaje automático supervisado, así como revisar las arquitecturas que han definido el estado del arte en esta área.

2.2.1. Modelos Discriminativos frente a Modelos Generativos

La taxonomía clásica del aprendizaje automático, formalizada por Ng y Jordan [24], distingue dos paradigmas fundamentales en función de la distribución que el modelo aprende a estimar.

Modelos Discriminativos. Aprenden directamente la distribución condicional $p(y | x)$, es decir, la probabilidad de una etiqueta y dado un vector de observaciones x . Su objetivo es trazar la frontera de decisión óptima en el espacio de características. Ejemplos arquetípicos son la regresión logística, las máquinas de soporte vectorial (SVM) y las redes neuronales de clasificación. Son altamente eficaces cuando el único objetivo es la predicción, pero por construcción no pueden generar nuevas muestras x .

Modelos Generativos. Aprenden la distribución conjunta $p(x, y)$ o, en el caso no supervisado, la distribución marginal $p(x)$ de los datos. Una vez aprendida esta distribución, es posible obtener nuevas muestras mediante el proceso de generación $x' \sim p_{\text{gen}}(x)$. Este paradigma habilita la síntesis de datos: el modelo captura la estructura estadística subyacente del espacio real y puede producir instancias nuevas que respetan dicha estructura sin corresponder a ningún individuo concreto.

En el contexto de este TFG, los modelos generativos son el mecanismo central: su objetivo es aprender $p_{\text{real}}(x)$ a partir de los registros de UCI del dataset MIMIC-III para después muestrear datos sintéticos clínicamente plausibles.

2.2.2. Redes Generativas Antagónicas (GANs)

Goodfellow et al. [8] propusieron las **Generative Adversarial Networks (GANs)** como un marco de entrenamiento basado en la teoría de juegos. La arquitectura define dos redes que compiten en un juego de suma cero:

- **Generador G :** mapea un vector de ruido latente $z \sim p_z(z)$ (típicamente gaussiano) al espacio de datos, generando muestras $\hat{x} = G(z; \theta_G)$.

- **Discriminador** D : clasifica si una muestra proviene de la distribución real $p_{\text{data}}(x)$ o del generador, produciendo un escalar $D(x; \theta_D) \in [0, 1]$.

El objetivo de entrenamiento es el minimax:

$$\min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p_z} [\log(1 - D(G(z)))] \quad (2.5)$$

En el equilibrio de Nash, el generador produce muestras indistinguibles de los datos reales ($D(x) = 0.5 \forall x$) y la distribución generada converge a la real. En la práctica, el entrenamiento GAN es notoriamente inestable: el **mode collapse** (el generador colapsa hacia un subconjunto de modos de la distribución real) y el desvanecimiento de gradientes son los problemas más frecuentes, abordados parcialmente por variantes como Wasserstein GAN [25], que sustituye la divergencia JS por la distancia de Wasserstein y garantiza gradientes más estables.

2.2.3. Autoencoders Variacionales (VAEs)

Kingma y Welling [9] introdujeron los **Variational Autoencoders (VAEs)** como una alternativa fundamentada en inferencia variacional bayesiana. La arquitectura consta de dos redes:

- **Encoder** $q_\phi(z | x)$: aproxima la distribución posterior del espacio latente dado un dato de entrada x .
- **Decoder** $p_\theta(x | z)$: reconstruye el dato original desde el vector latente z .

El entrenamiento maximiza la cota inferior de evidencia (*Evidence Lower BOund*, ELBO):

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x | z)] - D_{\text{KL}}(q_\phi(z | x) \| p(z)) \quad (2.6)$$

donde el primer término penaliza la pérdida de reconstrucción y el segundo la divergencia KL entre la posterior aproximada y la previa $p(z) = \mathcal{N}(0, I)$. Los VAEs producen espacios latentes continuos e interpolables, lo que facilita la generación condicional. Su principal limitación es la tendencia a generar muestras con menor nitidez estadística que las GANs, consecuencia de la optimización directa de la verosimilitud media.

2.2.4. Modelos de Difusión

Los **Denoising Diffusion Probabilistic Models (DDPM)**, propuestos por Ho et al. [14], han desplazado a las GANs como estado del arte en generación de alta fidelidad. Su formulación se articula en dos fases:

Proceso de difusión hacia delante (*forward*). Añade ruido gaussiano progresivamente a una muestra real x_0 a lo largo de T pasos, produciendo una cadena de Markov $x_0, x_1, \dots, x_T$ que converge hacia $\mathcal{N}(0, I)$:

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I) \quad (2.7)$$

donde $\{\beta_t\}_{t=1}^T$ es un calendario de ruido predefinido (lineal o cosenoidal). La propiedad de marginales permite muestrear x_t directamente desde x_0 :

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I), \quad \bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s) \quad (2.8)$$

Proceso de denoising inverso (*reverse*). Una red neuronal $\epsilon_\theta(x_t, t)$ aprende a estimar el ruido añadido en cada paso, permitiendo reconstruir x_{t-1} desde x_t . La función de pérdida simplificada es:

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{x_0, \epsilon \sim \mathcal{N}(0, I), t} [\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t)\|^2] \quad (2.9)$$

Este paradigma evita la inestabilidad del entrenamiento GAN y la tendencia suavizante del VAE. Su principal limitación es el coste computacional del muestreo, que en formulación estándar requiere T evaluaciones de la red.

2.2.5. Modelos para Datos Secuenciales: TimeGAN

Los EHR de UCI incluyen series temporales de medidas fisiológicas (frecuencia cardíaca, presión arterial, SpO₂...) donde el orden temporal y las dependencias entre pasos son parte esencial de la información clínica. Yoon et al. [26] propusieron **TimeGAN**, que combina un marco GAN con un autoencoder de secuencias basado en GRU, organizando el entrenamiento en tres fases:

1. **Pre-entrenamiento del autoencoder (Embedder + Recovery):** aprende una representación latente comprimida h_t que preserva la fidelidad de reconstrucción de las series reales.
2. **Pre-entrenamiento del Supervisor:** entrena una red GRU a predecir h_{t+1} desde h_t , forzando al espacio latente a capturar la dinámica temporal.
3. **Entrenamiento conjunto adversarial:** un Generador produce trayectorias latentes sintéticas, un Discriminador discrimina en el espacio latente, y el Supervisor regula la coherencia temporal. La función de pérdida combina los cuatro términos (reconstrucción, supervisión, adversarial y momentos estadísticos) en un balance ponderado.

Esta arquitectura ha demostrado capturar correlaciones temporales complejas en series médicas, superando a RNN-GAN clásicos en métricas de fidelidad distribucional.

2.3. Uso de datos sintéticos en investigación biomédica

La generación de datos sintéticos no es un fin en sí mismo, sino un habilitador para un conjunto amplio de aplicaciones en investigación clínica y desarrollo de modelos de aprendizaje automático. Esta sección revisa los principales casos de uso y el marco de evaluación que permite cuantificar la calidad de los datos generados.

2.3.1. Aplicaciones Principales

Preservación de la privacidad y compartición de datos. El caso de uso primario en el contexto biomédico es la publicación de conjuntos de datos sintéticos que permitan la reproducibilidad científica sin exponer registros reales. Un organismo que no puede compartir sus EHR bajo HIPAA/GDPR sí puede publicar un dataset sintético estadísticamente equivalente, permitiendo que equipos externos repliquen análisis, validen metodologías o entrenen modelos. Esta modalidad ha sido explorada en el proyecto *Synthea* [7] y en la liberación sintética de subconjuntos de MIMIC [12].

Aumento de datos (*data augmentation*). En problemas con desequilibrio severo de clases, como la predicción de mortalidad hospitalaria (13,8% en MIMIC-III), los modelos predictivos tienden a sesgar sus predicciones hacia la clase mayoritaria. La generación condicional de instancias de la clase minoritaria puede mejorar la calibración del clasificador sin incurrir en el sesgo de sobremuestreo simple (SMOTE).

Democratización del acceso a datos clínicos. La disponibilidad de datos sintéticos de alta fidelidad permite a investigadores de países o instituciones sin acceso a grandes bases de datos clínicas desarrollar y validar metodologías que luego pueden transferirse a entornos con datos reales. Contribuye así a reducir la brecha de innovación sanitaria global.

Generación de escenarios inusuales o raros. Los eventos clínicos de baja prevalencia (complicaciones raras, interacciones farmacológicas infrecuentes) están inevitablemente infrarrepresentados en los datos reales. Los modelos generativos condicionales pueden producir instancias sintéticas de estos escenarios para entrenar modelos de alerta temprana.

2.3.2. Marco de Evaluación de Datos Sintéticos

La calidad de los datos sintéticos se evalúa en tres dimensiones ortogonales, formalizadas por Jordon et al. [20] en el marco *syntheval*:

Fidelidad estadística (*fidelity*). Mide en qué medida la distribución del dataset sintético p_{gen} coincide con la del dataset real p_{data} . Las métricas más empleadas son:

- Divergencia de Jensen-Shannon (JSD) sobre distribuciones marginales.
- Distancia de Wasserstein (o Earth Mover's Distance) para variables continuas.
- Maximum Mean Discrepancy (MMD) en espacios de kernel.
- Correlación de matrices de correlación: Frobenius distance entre $\hat{\Sigma}_{\text{real}}$ y $\hat{\Sigma}_{\text{synth}}$.

Utilidad analítica (*utility*). Mide si los datos sintéticos son funcionalmente intercambiables con los reales para entrenar modelos predictivos. El paradigma estándar es **TSTR** (*Train on Synthetic, Test on Real*): un clasificador entrenado únicamente sobre datos sintéticos es evaluado sobre datos reales. La métrica de referencia es el gap de rendimiento respecto al caso **TRTR** (*Train on Real, Test on Real*).

Privacidad (*privacy*). Cuantifica el riesgo de que los datos sintéticos revelen información sobre individuos del conjunto de entrenamiento. Las métricas incluyen:

- **DCR** (*Distance to Closest Record*): distancia media entre cada registro sintético y su vecino más próximo en el dataset real. Un DCR bajo indica posible memorización.
- **Membership Inference Attack (MIA)**: un adversario entrena un clasificador para determinar si un registro concreto perteneció al conjunto de entrenamiento. Si el AUC del adversario supera $0.5 + \epsilon$, el modelo memoriza información privada.
- **ϵ -DP garantizado**: en modelos con privacidad diferencial formal (como DP-CTGAN), el epsilon acumulado proporciona una cota superior sobre la capacidad de distinción del adversario más poderoso.

El objetivo de la síntesis de datos de alta calidad es maximizar simultáneamente la fidelidad y la utilidad minimizando el riesgo de privacidad, lo que constituye un *trade-off* inherentemente conflictivo: los mecanismos de privacidad más estrictos degradan las distribuciones generadas. Cuantificar esta frontera de Pareto es uno de los objetivos centrales de este TFG.

2.4. Modelos para generación de datos médicos sintéticos

Los modelos generativos descritos en la sección anterior no nacieron en el ámbito biomédico, pero la urgencia por superar las barreras de acceso a datos clínicos ha

impulsado una línea de investigación específica centrada en su adaptación y evaluación sobre EHR. Esta sección revisa los trabajos más relevantes que definen el estado del arte en síntesis de datos clínicos tabulares y temporales.

2.4.1. Síntesis de Registros Tabulares

medGAN [10]. Fue uno de los primeros trabajos en aplicar GANs a EHR, utilizando un autoencoder para comprimir la alta dimensionalidad de registros de diagnósticos ICD-9 antes de entrenar la GAN en el espacio latente. Demostró que los datos sintéticos conservaban las frecuencias marginales de diagnóstico y las co-ocurrencias, validando la viabilidad del paradigma GAN para datos clínicos.

CTGAN y TVAE [13]. La librería SDV (*Synthetic Data Vault*) formalizó el problema de síntesis tabular heterogénea y propuso CTGAN como arquitectura estándar para datos mixtos. Su evaluación sobre múltiples benchmarks tabulares estableció CTGAN y TVAE como los baselines de referencia en el campo, siendo los modelos que este TFG utiliza como punto de partida para la síntesis de variables clínicas de UCI.

CTAB-GAN [27]. Este trabajo extendió CTGAN incorporando pérdidas auxiliares de clasificación y regresión que permiten al generador preservar mejor las relaciones entre variables objetivo y el resto de características tabulares. Introdujo además un tratamiento específico para variables logarítmicas y mixtas (valor cero con distribución continua), mejorando la síntesis de biomarcadores de laboratorio con alta proporción de valores fisiológicamente normales. Representa la extensión de referencia de la familia CTGAN en el período 2020–2022.

TabDDPM [15]. Este trabajo sistemáticamente evaluó los modelos de difusión sobre más de 15 datasets tabulares de diversas disciplinas, demostrando que TabDDPM supera a CTGAN y TVAE en utilidad predictiva (TSTR) en la mayoría de benchmarks. Para datos clínicos con distribuciones multimodales como la inflación de ceros en las escalas GCS, la difusión ofrece mayor capacidad de representación que la normalización por modos de CTGAN.

2.4.2. Síntesis de Series Temporales Clínicas

TimeGAN [26]. Aplicado al dataset MIMIC-III [12] y a datos de urgencias, TimeGAN mostró que los datos temporales sintéticos generados preservaban tanto las correlaciones entre variables fisiológicas como la dinámica longitudinal intra-paciente, medida mediante *discriminative score* (capacidad de un clasificador de distinguir real de sintético) y *predictive score* (utilidad en predicción de siguiente paso).

RTSGAN y EHR-Safe. Trabajos posteriores han explorado arquitecturas transformer-based para capturar dependencias de largo alcance en series de EHR, mejorando la coherencia clínica de los registros sintéticos en estancias prolongadas. Sin embargo, su mayor coste computacional y menor interpretabilidad los hacen menos adecuados como punto de partida en un entorno académico con recursos limitados.

2.4.3. Privacidad Diferencial en Síntesis de Datos Clínicos

PATE-GAN [17]. Propuso el primer framework GAN con garantías formales de privacidad diferencial para datos clínicos, basado en el mecanismo PATE (*Private Aggregation of Teachers' Ensembles*). Aunque conceptualmente elegante, su requerimiento de múltiples subconjuntos disjuntos de datos lo hace impracticable cuando el dataset de entrenamiento es limitado.

DP-GAN vía DP-SGD [11]. Este trabajo, publicado en *Circulation: Cardiovascular Quality and Outcomes*, aplicó DP-SGD [18] directamente al discriminador de una GAN sobre datos de UCI, evaluando el *privacy-utility tradeoff* sobre un subconjunto de MIMIC-III [12]. Sus resultados mostraron que con $\varepsilon = 1$ los datos sintéticos seguían siendo útiles para predicción de mortalidad, aunque con un gap de rendimiento TSTR de aproximadamente 3-5 puntos de AUC respecto al baseline sin privacidad. Este trabajo es el antecedente más directo del componente DP-CTGAN de este TFG.

Opacus [19]. La librería de PyTorch que implementa DP-SGD de forma modular y compatible con arquitecturas arbitrarias ha sido el habilitador técnico de la mayoría de trabajos de DP-GAN posteriores a 2020. Su uso en este TFG permite aislar el mecanismo de privacidad en el Discriminador y calcular automáticamente el σ óptimo para un ε objetivo, facilitando el barrido de configuraciones de privacidad $\{1, 5, 10, \infty\}$ que cuantifica la frontera de Pareto privacidad-utilidad en datos reales de UCI.

2.4.4. Síntesis comparativa

La revisión anterior evidencia que, a pesar del progreso significativo, ningún trabajo ha realizado una comparativa sistemática de múltiples familias de modelos generativos (GAN tabular, VAE, difusión, GAN temporal, GAN con DP) sobre el mismo subconjunto de MIMIC-III, evaluando simultáneamente fidelidad estadística, utilidad analítica y riesgo de privacidad. Cabe señalar que los modelos fundacionales del campo emergieron principalmente entre 2017 y 2019; el período 2020–2022 se caracterizó por refinamientos incrementales de estas arquitecturas base (p. ej., CTAB-GAN, 2021), sin propuestas arquitectónicas de primer orden comparables; la siguiente ola de innovación relevante llegó en 2023 con la aplicación sistemática de los modelos de difusión a datos tabulares (TabDDPM). Este vacío justifica la contribución diferencial del presente TFG.

Tabla 2.1: Comparativa de los principales trabajos de síntesis de datos clínicos revisados en este capítulo. DP: privacidad diferencial.

Modelo	Año	Familia	Datos	DP	Aportación principal
medGAN [10]	2017	GAN	Tabular	No	Primer GAN para EHR discretos de alta dimensionalidad
CTGAN [13]	2019	GAN	Tabular	No	Normalización por moda (VGM) y muestreo condicional para variables mixtas
TVAE [13]	2019	VAE	Tabular	No	Autoencoder variacional con transformación VGM; <i>baseline</i> tabular de referencia
CTAB-GAN [27]	2021	GAN	Tabular	No	Extiende CTGAN con pérdidas auxiliares de clasificación/regresión y soporte para variables logarítmicas y mixtas
TabDDPM [15]	2023	Difusión	Tabular	No	Supera GAN/VAE en utilidad TSTR; difusión multinomial para variables categóricas
TimeGAN [26]	2019	GAN+RNN	Temporal	No	GAN con autoencoder GRU para series temporales clínicas (MIMIC-III)
PATE-GAN [17]	2019	GAN+PATE	Tabular	Sí	Primer framework GAN con garantías DP formales para datos clínicos
DP-GAN [11]	2019	GAN+DP-SGD	Tabular	Sí	Cuantifica el <i>tradeoff</i> privacidad-utilidad en UCI (MIMIC-III); antecedente de DP-CTGAN

2.5. MIMIC-III como banco de pruebas estándar

Entre los conjuntos de datos disponibles para la investigación en síntesis de registros clínicos, **MIMIC-III** (*Medical Information Mart for Intensive Care III*) [12] se ha consolidado como el banco de pruebas de referencia de la comunidad. Desarrollado por el MIT Laboratory for Computational Physiology, contiene registros clínicos desidentificados de más de 40.000 pacientes de UCI del Beth Israel Deaconess Medical Center (Boston, MA) entre 2001 y 2012, y es accesible de forma controlada a través de PhysioNet [28] previa superación de un curso de ética en investigación y firma de un acuerdo de uso de datos.

Su posición de referencia responde a tres factores complementarios. El primero es su **escala y riqueza**: es uno de los pocos datasets de UCI de acceso público que integra constantes vitales, resultados de laboratorio, diagnósticos ICD-9, medicación y notas

clínicas en un esquema relacional coherente. El segundo es su **adopción extendida en la literatura**: desde medGAN [10] hasta los experimentos de privacidad diferencial de Beaulieu-Jones et al. [11] y TimeGAN [26], la mayor parte de los trabajos revisados en este capítulo lo han empleado como dataset de evaluación, lo que permite comparaciones metodológicas directas. El tercero es su **complejidad representativa**: los datos de UCI presentan distribuciones multimodales, valores extremos clínicamente significativos, desequilibrio de clases pronunciado y patrones de missingness no aleatorios, reproduciendo con fidelidad los retos reales de la síntesis clínica.

Este trabajo emplea una cohorte de 22.520 estancias extraída de MIMIC-III mediante criterios de inclusión estándar (primera estancia por paciente, duración ≥ 48 horas, edad ≥ 18 años), cuya construcción y características se describen en detalle en la Sección 4.1.1.

3. Objetivos y Metodología

3.1. Objetivo general

El objetivo de este Trabajo Fin de Grado es la propuesta y evaluación un marco experimental de generación de datos clínicos sintéticos mediante modelos generativos profundos. El trabajo abarca el diseño del pipeline de preprocesamiento, la implementación y entrenamiento de cuatro arquitecturas generativas pertenecientes a las familias GAN, VAE y modelos de difusión, y una evaluación sistemática experimental con la base de datos MIMIC-III [12] de los datos generados en tres dimensiones complementarias: fidelidad estadística respecto a los datos reales, utilidad analítica para tareas clínicas *downstream* y cuantificación formal del riesgo de privacidad, con especial atención al compromiso entre calidad de síntesis y garantías de privacidad diferencial.

3.2. Subobjetivos

En relación con el objetivo general, el trabajo se articula en torno a cinco subobjetivos específicos y medibles:

OE1. Construir una cohorte UCI representativa y un pipeline de preprocesamiento reproducible. Definir los criterios de inclusión y exclusión sobre MIMIC-III para obtener una cohorte de pacientes adultos en UCI con estancias de al menos 48 horas, implementar el pipeline de extracción, limpieza e imputación de constantes vitales y biomarcadores de laboratorio, y generar las representaciones de datos necesarias para el entrenamiento de los modelos generativos.

OE2. Seleccionar, implementar y entrenar los modelos generativos. Seleccionar, configurar, entrenar y validar modelos generativos representativos de las principales familias identificadas en el estado del arte (redes generativas adversariales, autoencoders variacionales y modelos de difusión), incluyendo al menos una variante con garantías formales de privacidad diferencial. El entrenamiento de todos los modelos seleccionados debe realizarse sobre la misma representación tabular de la cohorte de forma reproducible y trazable.

OE3. Evaluar la fidelidad estadística de los datos sintéticos generados. Medir con qué precisión los datos sintéticos reproducen las propiedades estadísticas de los

datos reales, evaluando tanto la similitud en las distribuciones de cada variable individualmente como la preservación de las relaciones entre variables. El análisis se complementará con técnicas de visualización en baja dimensionalidad y pruebas de discriminación entre datos reales y sintéticos.

OE4. Validar la utilidad analítica de los datos sintéticos. Cuantificar en qué medida los datos sintéticos pueden sustituir o complementar los datos reales para tareas clínicas predictivas, mediante el protocolo *Train on Real, Test on Real* (TRTR) frente a *Train on Synthetic, Test on Real* (TSTR), aplicado a la predicción de mortalidad intrahospitalaria y a la detección de sepsis como tarea secundaria.

OE5. Cuantificar el compromiso entre privacidad y utilidad en los modelos generativos. Auditar el riesgo de privacidad de los datos generados por todos los modelos mediante métricas de distancia y ataques de inferencia de pertenencia, y analizar el compromiso entre calidad de síntesis y nivel de protección formal de la privacidad en los modelos que incorporen privacidad diferencial, variando el presupuesto de privacidad para trazar la frontera de Pareto privacidad-utilidad sobre la cohorte de UCI.

3.3. Metodología

El trabajo se estructura en cuatro fases metodológicas secuenciales, representadas en la Figura 3.1, en las que los resultados de cada fase alimentan la siguiente.




Figura 3.1: Fases metodológicas del trabajo. Los resultados de cada fase alimentan la siguiente.

3.3.1. Fuente de datos y construcción de la cohorte

Los datos empleados proceden exclusivamente de MIMIC-III (*Medical Information Mart for Intensive Care III*), una base de datos de acceso controlado que recoge registros clínicos desidentificados de más de 40.000 pacientes de UCI del Beth Israel Deaconess Medical Center [12]. Su acceso requiere la superación del curso de ética CITI y la firma de un *Data Use Agreement* con PhysioNet [28].

La cohorte de trabajo se define aplicando tres criterios de inclusión sobre las 61.532 estancias originales: (i) primera estancia UCI por paciente para garantizar indepen-

dencia estadística, (ii) duración mínima de 48 horas para permitir la construcción de la ventana de observación y (iii) edad mayor o igual a 18 años para excluir la población pediátrica. Los criterios resultan en una cohorte de **22.520 estancias** con una tasa de mortalidad del 13,8 %.

3.3.2. Pipeline de preprocesamiento

El preprocesamiento transforma los datos crudos de MIMIC-III en representaciones aptas para el entrenamiento de modelos generativos. El pipeline se implementa en Python 3.12 utilizando `pandas` y `numpy`, y comprende las siguientes etapas: (i) extracción filtrada por *chunks* de las tablas `CHARTEVENTS` y `LABEVENTS` para 10 constantes vitales y 18 biomarcadores de laboratorio, con mapeo explícito de *ITEMID* entre los sistemas CareVue y MetaVision; (ii) validación por rangos fisiológicos máximos; (iii) imputación de valores ausentes mediante *forward-fill*, *backward-fill* y mediana poblacional; y (iv) agregación estadística (media, mínimo, máximo y desviación típica) para construir la representación tabular **22.520 × 127 columnas** que constituye la entrada de los modelos generativos.

3.3.3. Selección y diseño de los modelos generativos

La selección de modelos responde al criterio de representar los tres paradigmas generativos con mayor presencia en la literatura de datos clínicos sintéticos [20]: redes generativas adversariales, autoencoders variacionales y modelos de difusión. Los cuatro modelos elegidos (CTGAN, TVAE, TabDDPM y DP-CTGAN) incorporan además adaptaciones específicas al dominio tabular que los distinguen de sus contrapartes de propósito general, en particular la normalización por moda mediante modelos de mezcla gaussiana y el tratamiento diferenciado de variables categóricas. La variante DP-CTGAN añade DP-SGD [18] al entrenamiento del discriminador mediante la librería Opacus [19], permitiendo entrenar bajo presupuestos de privacidad formalmente garantizados y comparables entre configuraciones.

Todos los modelos se entrenan sobre el mismo snapshot tabular, con semilla aleatoria fija (`random_state=42`), en el servidor GPU de la Facultad de Informática de la Universidad de Murcia (GPU RTX A4500, 20 GB VRAM).

3.3.4. Marco de evaluación

La evaluación de los datos sintéticos se organiza en tres dimensiones complementarias, cada una orientada a responder una pregunta distinta sobre la calidad de la síntesis:

Fidelidad estadística. Mide con qué exactitud los datos sintéticos reproducen la distribución de los datos reales. Se emplean métricas de distribución marginal (diver-

gencia Jensen-Shannon por columna), de distribución conjunta (MMD, distancia de Wasserstein-1 y matrices de correlación), análisis visual mediante proyecciones UMAP y t-SNE, y un test de discriminación con clasificador XGBoost real vs. sintético cuyo AUC objetivo es próximo a 0,5 (indistinguibilidad).

Utilidad analítica. Evalúa si los datos sintéticos mantienen el valor predictivo de los datos reales para tareas clínicas concretas. El protocolo TRTR establece la línea base de rendimiento entrenando y evaluando sobre datos reales; el protocolo TSTR mide la degradación al entrenar sobre datos sintéticos y evaluar sobre datos reales. La tarea principal es la predicción de mortalidad intrahospitalaria (variable binaria con desbalance 86/14 %); la tarea secundaria es la detección de sepsis. Los modelos *downstream* evaluados son regresión logística, *random forest*, XGBoost y MLP, con métricas AUROC, AUPRC y F1.

Privacidad. Cuantifica el riesgo de re-identificación o inferencia de pertenencia a partir de los datos sintéticos. Se emplean ataques de inferencia de pertenencia (MIA) para detectar memorización de registros individuales, y métricas de distancia al registro más cercano (DCR y NNDR) para medir la proximidad entre datos sintéticos y reales en el espacio de *features*. El análisis de DP-CTGAN con cuatro valores de ε permite trazar la frontera de Pareto privacidad-útilidad para la cohorte MIMIC-III.

4. Desarrollo




Figura 4.1: Pipeline experimental del trabajo: desde los datos crudos de MIMIC-III hasta las tres dimensiones de evaluación de los datos sintéticos generados.

La Figura 4.1 resume el flujo experimental completo del trabajo, desde la extracción de la cohorte sobre MIMIC-III hasta las tres dimensiones de evaluación de los datos sintéticos generados.

4.1. Dataset y Preprocesamiento

4.1.1. El dataset MIMIC-III

MIMIC-III (*Medical Information Mart for Intensive Care III*) es una base de datos de acceso abierto controlada por el MIT Laboratory for Computational Physiology, que comprende registros clínicos desidentificados de más de 40.000 pacientes ingresados en las unidades de cuidados intensivos (UCI) del Beth Israel Deaconess Medical Center (Boston, MA) entre 2001 y 2012 [12]. Su acceso requiere la superación de un curso de ética en investigación (CITI Program) y la firma de un Data Use Agreement (DUA) con PhysioNet [28], que prohíbe explícitamente cualquier intento de re-identificación de pacientes.

Estructura relacional

La base de datos se distribuye como un esquema relacional de 26 tablas en formato CSV comprimido. Para este trabajo, las tablas de mayor relevancia son:

- **ICUSTAYS:** registro de cada estancia en UCI (*icustay_id*), con tiempos de entrada y salida, unidad de cuidados y *length of stay* (LOS).

- **ADMISSIONS**: información del ingreso hospitalario (*hadm_id*), incluyendo el *hospital_expire_flag* que define la variable objetivo de mortalidad intrahospitalaria.
- **PATIENTS**: demografía del paciente (*subject_id*), fecha de nacimiento anonimizada y género.
- **CHARTEVENTS**: tabla de mayor volumen (330 millones de filas), contiene todas las mediciones de constantes vitales registradas por enfermería a lo largo de la estancia, indexadas por *ITEMID*.
- **LABEVENTS**: resultados de analíticas de laboratorio (27 millones de filas), indexados por *ITEMID* del diccionario *D_LABITEMS*.
- **D_ITEMS** y **D_LABITEMS**: diccionarios de ítems que mapean cada *ITEMID* a su etiqueta clínica, unidad y fuente.
- **DIAGNOSES_ICD**: diagnósticos codificados en ICD-9 por ingreso, empleados para derivar comorbilidades.

CareVue frente a MetaVision

MIMIC-III integra datos procedentes de dos sistemas de información clínica distintos: **CareVue** (utilizado hasta 2008) y **MetaVision** (implantado a partir de entonces). Ambos sistemas codifican las mismas magnitudes fisiológicas con *ITEMID* diferentes, lo que requiere un mapeo explícito de equivalencias para cada variable. Por ejemplo, la frecuencia cardíaca está registrada bajo el *ITEMID* 211 en CareVue y el 220045 en MetaVision. Este mapeo se realizó sistemáticamente para las 10 constantes vitales y 18 biomarcadores de laboratorio seleccionados en este trabajo (véase la Sección 4.1.3).

4.1.2. Definición de la cohorte

El punto de partida son las 61.532 estancias UCI registradas en MIMIC-III. A partir de ellas se aplica una cadena de filtros para obtener una cohorte homogénea y sin duplicidad de pacientes.

Criterios de inclusión y exclusión

1. **Primera estancia UCI por paciente.** MIMIC-III incluye reingresos a UCI del mismo paciente. Para evitar fugas de información entre registros del mismo individuo y garantizar la independencia estadística de las muestras, se retiene únicamente la primera estancia cronológica de cada *subject_id*.

2. **Duración de la estancia ≥ 48 horas.** El diseño experimental requiere una ventana temporal de 48 horas de observación para construir tanto el snapshot tabular como la serie temporal horaria. Las estancias inferiores a este umbral no permiten completar dicha ventana y son excluidas.
3. **Edad ≥ 18 años.** Se excluyen pacientes pediátricos, cuya fisiología y patrones clínicos difieren sustancialmente de la población adulta.
4. **Corrección de la anonimización de edades extremas.** MIMIC-III protege la identidad de pacientes mayores de 89 años desplazando su fecha de nacimiento hacia el pasado, produciendo edades calculadas superiores a 200 años. Estos registros son detectados (edad > 200) y corregidos asignándoles una edad representativa de 91,4 años, siguiendo la convención estándar de la literatura sobre MIMIC [12].

Cohorte resultante

Tras aplicar los filtros anteriores, la cohorte queda compuesta por **22.520 estancias UCI** correspondientes a 22.520 pacientes únicos. Las características principales se resumen en la Tabla 4.1.

Tabla 4.1: Estadísticas descriptivas de la cohorte final.

Característica	Valor
Estancias UCI totales en MIMIC-III	61.532
Estancias tras filtrado	22.520
Mortalidad intrahospitalaria	13,8%
Edad media (años)	65,1

La tasa de mortalidad del 13,8% refleja el desequilibrio de clases característico de los entornos de UCI, que constituye uno de los retos metodológicos abordados en los modelos generativos condicionales de este trabajo.

4.1.3. Selección de variables clínicas

La selección de variables se guía por dos criterios complementarios: relevancia clínica contrastada en la literatura de UCI y disponibilidad suficiente en MIMIC-III a lo largo del periodo 2001–2012. Se distinguen dos grupos: constantes vitales (registradas en CHARTEVENTS) y biomarcadores de laboratorio (registradas en LABEVENTS).

Constantes vitales

Se seleccionan 10 señales fisiológicas directamente extraídas de CHARTEVENTS que constituyen el núcleo del monitoreo continuo en UCI y son los componentes de esca-

las de severidad clínica ampliamente utilizadas como SOFA (*Sequential Organ Failure Assessment*) y APACHE II [29]. Dado que CareVue y MetaVision asignan *ITEMID* distintos a la misma magnitud, se mantiene un mapeo explícito de equivalencias (Tabla 4.2).

Tabla 4.2: Mapeo de *ITEMID* entre CareVue y MetaVision para constantes vitales.

Variable	Unidad	CareVue	MetaVision
Frecuencia cardíaca	lpm	211	220045
Presión arterial sistólica (PAS)	mmHg	51, 442, 455, 6701	220179, 220050
Presión arterial diastólica (PAD)	mmHg	8368, 8440, 8441, 8555	220180, 220051
Presión arterial media (PAM)	mmHg	456, 52, 6702, 443	220052, 220181, 225312
Saturación de oxígeno (SpO ₂)	%	646	220277
Temperatura	°C	676, 678, 679*	223762, 223761*
Frecuencia respiratoria	rpm	615, 618	220210, 224690
GCS ocular (<i>eye</i>)	1–4	184	220739
GCS verbal	1–5	723	223900
GCS motor	1–6	454	223901

* Registros en Fahrenheit convertidos a Celsius: $T_C = (T_F - 32) \times 5/9$.

A partir de los tres componentes GCS se deriva el **GCS total** como su suma aritmética (rango 3–15). Esta undécima señal no tiene *ITEMID* propio en CHARTEVENTS y no forma parte del tensor de series temporales, pero sí se incluye en el snapshot tabular como indicador sintetizado del nivel de consciencia.

Biomarcadores de laboratorio

Se incluyen 18 biomarcadores que cubren los principales sistemas orgánicos evaluados en UCI: función renal (creatinina, BUN), función hepática (bilirrubina, albúmina), metabolismo (lactato, glucosa, base excess), equilibrio ácido-base (pH arterial, PaO₂, PaCO₂, bicarbonato), electrolitos (sodio, potasio), hematología (hemoglobina, plaquetas, leucocitos, INR) y marcadores de daño miocárdico (troponina). El lactato merece mención especial: es el marcador bioquímico de referencia para el diagnóstico y monitoreo del shock séptico [30], uno de los diagnósticos más prevalentes en la cohorte (15,2% de los pacientes).

En total, el proceso de extracción y limpieza recupera **9.850.890 registros de constantes vitales** y **1.394.837 registros de laboratorio** dentro de la ventana de 48 horas, cubriendo el 98,7% y el 99,2% de las estancias de la cohorte respectivamente.

4.1.4. Pipeline de preprocesamiento

El preprocesamiento de MIMIC-III para este trabajo requiere resolver tres retos técnicos de naturaleza distinta: el volumen extremo de las tablas de eventos (CHARTE-

VENTS supera los 330 millones de filas), la heterogeneidad de los valores faltantes, con patrones de missingness que reflejan procesos clínicos reales y no aleatoriedad simple, y la necesidad de producir dos representaciones de distinto nivel de abstracción a partir de los mismos datos crudos. El pipeline se implementa íntegramente en el notebook `02_preprocessing.ipynb` y su corrección se verifica en `03_data_validation.ipynb`.

Extracción filtrada de CHARTEVENTS y LABEVENTS

La carga completa de CHARTEVENTS en memoria es inviable en un entorno local estándar. Se adopta una estrategia de lectura por *chunks* de 500.000 filas sobre la que se aplican cuatro filtros en cascada antes de acumular los resultados: (i) descarte de filas con `ERROR = 1` o valor numérico nulo, que representan mediciones explícitamente marcadas como inválidas por el sistema de monitorización; (ii) retención exclusiva de los 38 *ITEMID* de constantes vitales identificados en la Sección 4.1.3; (iii) retención exclusiva de las 22.520 *icustay_id* de la cohorte; y (iv) filtrado temporal, conservando únicamente los registros cuyo *CHARTTIME* cae dentro de la ventana $[\text{intime}_i, \text{intime}_i + 48 \text{ h}]$ de la estancia *i*. El filtro temporal se implementa de forma vectorizada mediante diccionarios de búsqueda rápida, evitando el coste de un *merge* completo por cada *chunk*.

Para LABEVENTS, la ausencia de *icustay_id* directo en la tabla obliga a resolver el vínculo mediante *hadm_id*: a partir del cruce previo entre ICUSTAYS y ADMISSIONS, se construye un diccionario *hadm_id* $\rightarrow$ *icustay_id* que permite aplicar los mismos filtros. El proceso extrae en total **9.850.890 registros de constantes vitales** (cubriendo el 98,7 % de las estancias de la cohorte) y **1.394.837 registros de laboratorio** (99,2 % de cobertura). La Figura 4.2 muestra la cobertura por vital: todas las señales superan el 80 % de estancias con al menos un registro en las 48h, a excepción de la temperatura, cuya cobertura es inferior debido a la menor frecuencia de registro en algunos turnos de enfermería.

Limpieza por rango fisiológico

Tras el filtro de error de CHARTEVENTS, se aplica una segunda capa de validación basada en rangos fisiológicos máximos definidos por criterio clínico (Tabla 4.3). El objetivo es eliminar errores de transcripción o de unidades que no fueron marcados explícitamente como inválidos en el sistema fuente. Las temperaturas registradas en grados Fahrenheit (identificadas por su *ITEMID*) se convierten previamente a Celsius mediante $T_C = (T_F - 32) \times 5/9$ antes de aplicar el rango de validación. En total, el filtro elimina 2.627 registros, equivalente al 0,03 % del total extraído, lo que confirma la alta calidad de los datos tras el descarte inicial por `ERROR = 1`.

Imputación de valores ausentes

La presencia de valores faltantes en datos de UCI tiene, en buena parte, una explicación clínica: las constantes vitales no se miden con frecuencia uniforme a lo largo




Figura 4.2: Porcentaje de estancias de la cohorte sin ningún registro para cada constante vital dentro de la ventana de 48h. Valores calculados sobre los datos crudos extraídos de CHARTEVENTS, antes de imputación.

Tabla 4.3: Rangos fisiológicos máximos aplicados en la validación de constantes vitales.

Variable	Límite inferior	Límite superior
Frecuencia cardíaca (lpm)	0	300
PAS (mmHg)	0	300
PAD (mmHg)	0	200
PAM (mmHg)	0	250
SpO ₂ (%)	50	100
Temperatura (°C)	25	45
Frecuencia respiratoria (rpm)	0	80
GCS ocular	1	4
GCS verbal	1	5
GCS motor	1	6

del día, y ciertas analíticas solo se solicitan cuando el médico lo considera indicado. Tratar este missingness como puramente aleatorio y aplicar una única estrategia de imputación ignoraría estas diferencias. Por este motivo, la estrategia difiere entre las dos representaciones que se construyen a partir de los mismos datos crudos.

Para la **representación de series temporales**, el objetivo es rellenar los huecos de la grilla horaria preservando la continuidad temporal de cada estancia. Se aplica en primer lugar un *forward-fill* dentro de cada estancia (propagación del último valor registrado hacia adelante), seguido de un *backward-fill* (propagación hacia atrás para las primeras horas sin dato). Ambas operaciones se realizan de forma independiente para cada *icustay_id*. Los huecos que permanecen tras este doble pase, correspondientes

a estancias donde un vital nunca fue registrado en la ventana de 48h, se rellenan con la mediana poblacional de esa combinación (hora h , vital v), lo que introduce la información de la distribución típica de la cohorte sin fabricar tendencias individuales. La tasa de NaN antes de la imputación es del 32,4%; tras aplicar las tres etapas, desciende al 0,00 %.

Para el **snapshot tabular**, el missingness refleja ausencia total de mediciones de una variable durante las 48h completas, por lo que el *forward-fill* no es aplicable. Se imputa con la mediana poblacional por columna, estrategia robusta frente a los valores extremos frecuentes en UCI. El resultado es igualmente un dataset sin valores ausentes.

Normalización

Las series temporales se normalizan con escalado Min-Max por canal vital, proyectando cada señal al intervalo $[0, 1]$:

$$x_{\text{norm}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

donde $x_{\min}$ y $x_{\max}$ se calculan sobre el conjunto completo de valores del canal tras la imputación. Los parámetros de normalización se almacenan en `data/processed/timeseries_norm_p` de modo que las muestras sintéticas generadas puedan desnormalizarse al espacio original para su evaluación clínica. El rango final del tensor normalizado es exactamente $[0,000, 1,000]$, confirmado en la validación.

El snapshot tabular no se normaliza en esta etapa. CTGAN y TVAE (librería SDV) aplican internamente transformaciones específicas por tipo de columna (cuantiles para variables continuas, *one-hot encoding* para categóricas), y TabDDPM incorpora su propio esquema de normalización durante el entrenamiento.

4.1.5. Dos representaciones del mismo dato

Una decisión de diseño central de este trabajo es construir, a partir de la misma cohorte y la misma ventana temporal de 48h, dos representaciones con distinto nivel de abstracción, cada una orientada a una familia diferente de modelos generativos. Esta dualidad permite evaluar de forma diferenciada la capacidad de síntesis de datos tabulares frente a datos temporales, y constituye en sí misma una contribución metodológica del proyecto.

Snapshot tabular (48h)

El **snapshot tabular** comprime la actividad clínica de las primeras 48h de cada estancia en un único vector de características. Para cada variable cuantitativa (tanto constantes vitales como biomarcadores de laboratorio) se calculan cuatro estadísticos

de agregación sobre todos los registros de la ventana: media, mínimo, máximo y desviación típica. A estos se añaden variables demográficas (edad numérica, género codificado binariamente), características del ingreso (tipo de admisión, seguro médico, etnia, *length of stay*) y cinco *flags* binarios de comorbilidades derivados de `DIAGNOSES_ICD`. Las columnas de conteo de mediciones, que representan la densidad de muestreo y no la fisiología del paciente, se descartan para evitar que los modelos generativos aprendan artefactos del proceso de registro. El dataset resultante tiene dimensiones **22.520 × 127 columnas** y constituye la entrada para CTGAN, TVAE y TabDDPM.

Series temporales horarias (48h)

La **representación temporal** preserva la evolución de las 10 constantes vitales a lo largo de las primeras 48h con resolución horaria, agrupando los registros de cada hora mediante la media aritmética. El resultado es un tensor de dimensiones **(22.235, 48, 10)**: número de estancias × horas × vitales.

Las 285 estancias presentes en el snapshot tabular pero ausentes del tensor temporal son aquellas para las que el proceso de extracción no recuperó ningún registro de constantes vitales en CHARTEVENTS, a pesar de cumplir el criterio de estancia $\geq 48h$. Su LOS medio (6,9 días) es superior a la cohorte general, pero su tasa de mortalidad (7,4 %) es notablemente inferior, lo que sugiere que corresponden a pacientes clínicamente estables cuyo monitoreo fue documentado de forma menos sistemática en el sistema fuente.

Un aspecto que merece atención específica es la **zero-inflation** observada en los componentes del GCS dentro del tensor temporal: el GCS verbal presenta el 39,8 % de horas con valor normalizado 0 (equivalente al valor bruto 1, el mínimo de la escala), el GCS ocular el 15,5 % y el GCS motor el 8,9 %. Este patrón no es un artefacto del preprocesamiento, sino un reflejo clínico directo de la elevada proporción de pacientes intubados en UCI: un paciente bajo ventilación mecánica no puede emitir respuesta verbal y se puntúa con $GCS V = 1$.

Coherencia entre representaciones

Dado que ambas representaciones se derivan de los mismos datos crudos, se verifica su coherencia antes de proceder al entrenamiento. Sobre las 22.235 estancias comunes, el número de discrepancias en la variable objetivo `hospital_expire_flag` entre el snapshot tabular y los metadatos del tensor temporal es **cero**, y las edades calculadas coinciden exactamente. Este control garantiza que cualquier diferencia de rendimiento entre los modelos no pueda atribuirse a inconsistencias en los datos de entrenamiento.




Figura 4.3: Evolución temporal de cuatro constantes vitales durante las primeras 48h para una muestra de cinco estancias. Las trayectorias en azul corresponden a supervivientes y en rojo a pacientes fallecidos.

4.1.6. Análisis exploratorio

Variable objetivo: distribución y desbalance de clases

La variable objetivo del trabajo es `hospital_expire_flag`, un indicador binario que toma el valor 1 si el paciente falleció durante el ingreso hospitalario y 0 en caso contrario. En la cohorte final, **3.108 estancias corresponden a fallecidos (13,8%)** frente a 19.412 supervivientes (86,2%), reproduciendo el desequilibrio de clases característico de los entornos de UCI de alta complejidad. Este desbalance es intrínseco a la epidemiología de la UCI y no es un artefacto del filtrado de la cohorte: la tasa de mortalidad del 13,8% es coherente con la literatura sobre MIMIC-III en poblaciones adultas con estancias prolongadas [12]. Su implicación para los modelos generativos es directa: un modelo que genere datos sin condicionamiento de clase tenderá a producir una proporción de fallecidos similar a la real, lo que es deseable para mantener la fidelidad estadística pero insuficiente si el objetivo es aumentar la representación de la clase minoritaria para tareas predictivas. Esta tensión se aborda mediante *conditional sampling* en CTGAN y DP-CTGAN (Sección 4.2).

Comorbilidades y características demográficas

La Tabla 4.4 recoge la prevalencia de las cinco comorbilidades derivadas de `DIAGNOSES_ICD`. La insuficiencia cardíaca congestiva (29,4 %) y la diabetes mellitus (27,0 %) son las más frecuentes, en línea con el perfil epidemiológico típico de las UCI de hospitales de tercer nivel en Estados Unidos. La sepsis, codificada bajo ICD-9 038.x, afecta al 15,2 % de los pacientes y es especialmente relevante para este trabajo: constituye una de las tareas de validación de utilidad analítica planificadas en el Capítulo 5, donde se evaluará si los datos sintéticos preservan la señal predictiva necesaria para clasificar episodios sépticos. La edad media de la cohorte es de 65,1 años, con una distribución que muestra una asimetría positiva (cola hacia edades avanzadas), y la proporción de hombres es superior a la de mujeres, coherente con los patrones de ingreso en UCI reportados en la literatura.

Tabla 4.4: Prevalencia de comorbilidades en la cohorte final (N = 22.520), derivadas de `DIAGNOSES_ICD` mediante códigos ICD-9.

Comorbilidad	Código ICD-9	N	Prevalencia
Insuficiencia cardíaca congestiva (ICC)	428.x	6.632	29,4 %
Diabetes mellitus	250.x	6.091	27,0 %
EPOC	491–496	4.280	19,0 %
Sepsis	038.x	3.422	15,2 %
Enfermedad renal crónica (ERC)	585.x	2.644	11,7 %

Distribuciones de variables clínicas y relaciones con la mortalidad

Las distribuciones de las constantes vitales son consistentes con poblaciones UCI documentadas en la literatura: frecuencia cardíaca media de 86,9 lpm, PAS media de 119,4 mmHg, SpO₂ media del 97,2 %, temperatura media de 36,9 °C, frecuencia respiratoria media de 19,2 rpm y GCS total medio de 11,8 (sobre un máximo de 15). El lactato medio es de 2,0 mmol/L, con un rango que alcanza los 24,9 mmol/L en los casos más graves, reflejando la distribución de cola larga propia de los marcadores de hipoperfusión tisular y característica del shock séptico.

El análisis de correlaciones entre variables cuantitativas y la variable objetivo (Figura 4.5) revela relaciones coherentes con la evidencia clínica establecida y proporciona una línea de base para la evaluación de fidelidad del Capítulo 5: los datos sintéticos deben preservar estas correlaciones para ser considerados estadísticamente válidos. El GCS total presenta la correlación negativa más fuerte con la mortalidad ($r = -0,284$), reflejo directo de que la alteración del nivel de consciencia es uno de los predictores más robustos de desenlace adverso en UCI. El BUN ($r = +0,202$) y el lactato ($r = +0,194$) son las dos variables con mayor correlación positiva, capturando respectivamente el deterioro de la función renal y la hipoperfusión sistémica que preceden al fracaso mul-

tiorgánico. La frecuencia respiratoria ($r = +0,137$) y la edad ($r = +0,113$) siguen en importancia, mientras que el pH arterial ($r = -0,079$) y la PAS ($r = -0,077$) muestran correlaciones negativas de magnitud moderada, coherentes con la acidosis metabólica y la hipotensión asociadas a los cuadros críticos.




Figura 4.4: Distribuciones de seis variables clínicas clave segmentadas por la variable objetivo (azul: supervivientes, rojo: fallecidos).

4.2. Modelos Generativos: Diseño e Implementación

4.2.1. Diseño experimental y decisiones arquitectónicas

La construcción del marco experimental exige, antes de cualquier decisión técnica, responder a una pregunta de alcance: ¿qué familia de modelos generativos es más adecuada para sintetizar datos clínicos tabulares y qué configuración permite cuantificar de forma rigurosa el compromiso entre fidelidad estadística y privacidad? La respuesta a esta pregunta determina no solo los modelos seleccionados, sino también el diseño de los experimentos comparativos y la estructura de la evaluación que se desarrolla en los capítulos siguientes.

Criterios de selección. La elección de los modelos obedece a tres criterios complementarios. El primero es la **representatividad de familias generativas**: se ha bus-




Figura 4.5: Mapa de correlaciones de Pearson entre variables clínicas clave y la variable objetivo en el snapshot tabular.

cado cubrir los tres paradigmas que han dominado la generación de datos sintéticos en la última década (redes generativas adversariales [8], autoencoders variacionales [9] y modelos de difusión [14]) con al menos un representante de cada familia adaptado al dominio tabular. El segundo criterio es la **adecuación al dominio**: los datos tabulares presentan retos específicos (mezcla de variables continuas y categóricas, distribuciones multimodales, alta dimensionalidad con covariables correlacionadas) que los modelos generativos de propósito general no resuelven bien sin adaptaciones explícitas [13]. El tercer criterio es la **extensibilidad a privacidad diferencial**: uno de los objetivos específicos del trabajo es analizar el efecto de las garantías formales de privacidad sobre la calidad de los datos generados, lo que requiere que al menos un modelo disponga de una variante entrenada con *differentially private* stochastic gradient descent (DP-SGD) [18].

Modelos seleccionados. A partir de estos criterios se seleccionan cuatro modelos, resumidos en la Tabla 4.5. **CTGAN** (*Conditional Tabular GAN*) [13] es el modelo

adversarial de referencia para datos tabulares: introduce una normalización específica por moda (*mode-specific normalization*) para manejar distribuciones multimodales y un esquema de muestreo condicional que mitiga el desequilibrio de clases presente en la cohorte. **TVAE** (*Tabular Variational Autoencoder*), introducido en el mismo trabajo [13], aplica el marco variacional de Kingma y Welling [9] sobre datos tabulares con las mismas transformaciones de preprocesamiento que CTGAN, lo que permite una comparación directa entre el paradigma adversarial y el variacional manteniendo constantes el resto de variables. **TabDDPM** [15] es el representante de los modelos de difusión: opera sobre el proceso de difusión y desnaturalización de Ho et al. [14] e incorpora tratamiento diferenciado para columnas numéricas y categóricas, mostrando ventajas de estabilidad de entrenamiento frente a los enfoques adversariales en benchmarks de datos tabulares estándar. Por último, **DP-CTGAN** extiende CTGAN con DP-SGD mediante la librería Opacus [19], añadiendo ruido gaussiano calibrado a los gradientes durante el entrenamiento para proporcionar garantías (ϵ, δ) -DP. La elección de CTGAN como base para la variante con privacidad (frente a TVAe o TabDDPM) responde a su mayor prevalencia en la literatura de datos clínicos sintéticos con privacidad diferencial [11], lo que facilita la comparación con trabajos previos.

Tabla 4.5: Modelos generativos entrenados en este trabajo, familia a la que pertenecen y su rol en el marco experimental.

Modelo	Familia	Privacidad	Rol
CTGAN	GAN adversarial	No	Referencia tabular adversarial
TVAE	Autoencoder variacional	No	Referencia tabular variacional
TabDDPM	Modelo de difusión	No	Referencia tabular difusión
DP-CTGAN	GAN adversarial + DP-SGD	Sí ($\epsilon \in \{1, 5, 10, \infty\}$)	Análisis privacidad-fidelidad

Alcance temporal y trabajo futuro. El análisis se circunscribe deliberadamente a la representación tabular (snapshot 48h, 22.520×127). La representación temporal, el tensor ($22.235 \times 48 \times 10$) construido en la Sección 4.1, queda fuera del alcance experimental de este trabajo. El modelo natural para este caso, TimeGAN [26], presenta un entrenamiento en tres fases con convergencia sensible a los hiperparámetros y requiere recursos de cómputo que exceden el ámbito de un TFG de estas características. Su inclusión como extensión futura permitiría evaluar si la evolución dinámica de las constantes vitales puede sintetizarse con fidelidad temporal.

Entorno de experimentación. Todos los modelos se entrenan sobre el mismo dataset tabular procesado y con semilla aleatoria fija (`random_state=42`) para garantizar la reproducibilidad. Los experimentos se ejecutan en el servidor GPU de la Facultad de Informática de la Universidad de Murcia (GPU RTX A4500, 20 GB VRAM).

4.2.2. Modelos tabulares: CTGAN y TVAE

CTGAN y TVAE fueron introducidos conjuntamente por Xu et al. [13] como las dos primeras propuestas de generación de datos tabulares dentro de la librería SDV (*Synthetic Data Vault*). Comparten un mismo *pipeline* de transformación de datos de entrada, lo que permite aislar el efecto de la arquitectura generativa (adversarial frente a variacional) sobre la calidad de las muestras sintéticas producidas.

Transformación de datos: normalización por moda

Los datos tabulares reales presentan características que dificultan su modelado con las técnicas de normalización estándar. En particular, variables continuas como la creatinina, el lactato o la frecuencia cardíaca exhiben distribuciones multimodales, con varios picos diferenciados que reflejan subpoblaciones clínicas, que no se capturan bien con una normalización gaussiana simple. Para resolver este problema, Xu et al. proponen la **mode-specific normalization** basada en un *Variational Gaussian Mixture Model* (VGM).

El procedimiento es el siguiente: para cada columna continua x_i , se ajusta un VGM con hasta $K = 10$ componentes gaussianas usando el criterio de la verosimilitud marginal variacional, lo que determina automáticamente el número efectivo de modas $\hat{K}_i \leq K$. Cada valor observado v de la columna se transforma en un par $(\tilde{v}, \mathbf{d})$, donde $\tilde{v}$ es el valor normalizado dentro de su componente gaussiana más probable (calculado como $\tilde{v} = (v - \mu_k)/(4\sigma_k)$ para la componente k) y $\mathbf{d} \in \{0, 1\}^{\hat{K}_i}$ es un vector *one-hot* que indica dicha componente. El factor $4\sigma_k$ en el denominador garantiza que $\tilde{v} \in [-1, 1]$ con alta probabilidad, lo que facilita la convergencia de las capas de salida con activación tanh. Las variables categóricas se codifican directamente en *one-hot*. El vector de entrada resultante para cada estancia tiene dimensión $d_{\text{trans}} = \sum_i (1 + \hat{K}_i) + \sum_j C_j$, donde C_j es el número de categorías de la variable discreta j .

CTGAN: red generativa adversarial condicional

Esquema adversarial y problema de optimización. CTGAN sigue el marco GAN introducido por Goodfellow et al. [8]: un generador G y un discriminador D se entrenan de forma antagonista, donde G trata de producir muestras indistinguibles de los datos reales y D trata de separarlas. Formalmente, $G : \mathbb{R}^{d_z} \times \mathcal{C} \rightarrow \mathcal{X}_{\text{trans}}$ mapea un vector de ruido latente $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_{d_z})$ y un vector condicional $\mathbf{c} \in \mathcal{C}$ al espacio de datos transformado, produciendo muestras sintéticas $\tilde{\mathbf{x}} = G(\mathbf{z}, \mathbf{c}; \theta_G)$; el discriminador $D : \mathcal{X}_{\text{trans}} \times \mathcal{C} \rightarrow \mathbb{R}$ recibe una muestra y el vector condicional y devuelve un escalar que cuantifica si la muestra pertenece a la distribución real o a la generada. Para mitigar los problemas de inestabilidad y colapso de modos (*mode collapse*) del GAN original, CTGAN adopta la formulación de **WGAN-GP** (*Wasserstein GAN with Gradient Penalty*) [25], cuya función de pérdida es:

$$\mathcal{L}_{\text{WGAN-GP}} = \underbrace{\mathbb{E}_{\tilde{x} \sim P_G}[D(\tilde{x})] - \mathbb{E}_{x \sim P_{\text{data}}}[D(x)]}_{\text{distancia de Wasserstein}} + \lambda \mathbb{E}_{\hat{x} \sim P_{\hat{x}}}[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2] \quad (4.1)$$

donde $\tilde{x}$ son muestras generadas, x son muestras reales, $\hat{x}$ son interpolaciones lineales entre ambas y $\lambda = 10$ es el coeficiente de penalización del gradiente. La distancia de Wasserstein (a diferencia de la divergencia KL o Jensen-Shannon del GAN original) proporciona un gradiente de entrenamiento más suave y no colapsa cuando las distribuciones real y generada tienen soporte disjunto.

Vector condicional y muestreo balanceado. Un problema adicional en los datos clínicos es el **desequilibrio de clases**: variables discretas con distribución muy asimétrica (como la variable de mortalidad, con solo el 13,8 % de positivos) tienden a ser subrepresentadas si el generador aprende la distribución marginal empírica. CTGAN lo resuelve mediante un *conditional vector* $\mathbf{c}$: en cada paso de entrenamiento se muestrea uniformemente una columna discreta j y dentro de ella una categoría k , y se genera una condición $\mathbf{c}$ que indica (j, k) . El generador recibe $\mathbf{c}$ como entrada adicional y debe producir una muestra coherente con la condición. Simultáneamente, el discriminador recibe tanto la muestra como $\mathbf{c}$, forzando al generador a respetar la distribución condicional $P(\mathbf{x} \mid x_j = k)$ y no solo la marginal. Durante la síntesis, $\mathbf{c}$ se muestrea según la distribución real de las categorías, recuperando la distribución marginal original en la muestra sintética.

Arquitectura del generador. El generador G toma como entrada la concatenación del vector de ruido $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ de dimensión $d_z = 128$ y el vector condicional $\mathbf{c}$. La red es un perceptrón multicapa (MLP) con $L = 2$ capas ocultas de $h = 256$ neuronas cada una. Cada capa oculta aplica la transformación:

$$\mathbf{h}^{(l)} = \text{ReLU}(\text{BN}(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)})) + \mathbf{h}^{(l-1)} \quad (4.2)$$

donde BN denota *batch normalization* y el término residual $+\mathbf{h}^{(l-1)}$ (conexión de salto) estabiliza el flujo del gradiente en capas profundas. La capa de salida produce el vector transformado $\hat{\mathbf{x}}$ de dimensión d_{trans} : las componentes correspondientes a valores continuos pasan por tanh y las componentes de los vectores *one-hot* (tanto de modas como de variables categóricas) pasan por softmax, garantizando que cada grupo de categorías forme una distribución de probabilidad válida.

Arquitectura del discriminador y mecanismo PacGAN. El discriminador D emplea también un MLP de 2 capas ocultas de 256 neuronas con *LeakyReLU* ($\alpha = 0,2$) y *dropout* ($p = 0,5$) entre capas, produciendo una salida escalar sin activación final (requerido por la formulación WGAN). Para reducir el colapso de modos, CTGAN

incorpora el mecanismo **PacGAN**: en lugar de evaluar una muestra individual, el discriminador recibe la concatenación de $\text{pac} = 10$ muestras simultáneas, lo que aumenta su capacidad para detectar cuando el generador produce muestras redundantes o de baja diversidad.

Hiperparámetros y criterio de convergencia. La Tabla 4.6 recoge la configuración utilizada. El número de épocas se fija en 300: con 22.520 muestras y un *batch size* de 500, cada época equivale a 45 actualizaciones del generador, resultando en 13.500 pasos de gradiente en total, suficientes para la convergencia observada en datasets de tamaño comparable [13]. El *embedding* de 128 dimensiones ofrece capacidad representacional adecuada para los 127 atributos de entrada sin sobreparametrizar el espacio latente. Las dos capas de 256 neuronas en generador y discriminador son simétricas por diseño, siguiendo la práctica habitual en GANs para evitar que una red domine a la otra durante el entrenamiento [8].

TVAE: autoencoder variacional tabular

Marco variacional. TVAE aplica el autoencoder variacional de Kingma y Welling [9] al dominio tabular utilizando la misma transformación VGM descrita anteriormente. El modelo aprende una distribución a posteriori aproximada $q_\phi(\mathbf{z} | \mathbf{x})$ sobre un espacio latente continuo de dimensión d_z y una distribución generativa $p_\theta(\mathbf{x} | \mathbf{z})$ que permite muestrear nuevas instancias. A diferencia de CTGAN, el entrenamiento es completamente estable por construcción, al no depender de un equilibrio adversarial.

Arquitectura del codificador. El codificador q_ϕ es un MLP de 2 capas ocultas de $h = 128$ neuronas con activación *ReLU* que mapea el vector de entrada transformado $\mathbf{x} \in \mathbb{R}^{d_{\text{trans}}}$ a los parámetros de la distribución a posteriori:

$$\boldsymbol{\mu}_\phi(\mathbf{x}), \log \boldsymbol{\sigma}_\phi^2(\mathbf{x}) = \text{Codificador}_\phi(\mathbf{x}) \quad (4.3)$$

La muestra latente se obtiene mediante el **truco de la reparametrización**:

$$\mathbf{z} = \boldsymbol{\mu}_\phi(\mathbf{x}) + \boldsymbol{\epsilon} \odot \boldsymbol{\sigma}_\phi(\mathbf{x}), \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (4.4)$$

que permite propagar gradientes a través de la operación de muestreo, haciendo el modelo entrenable de extremo a extremo.

Arquitectura del decodificador y función de pérdida. El decodificador p_θ es un MLP simétrico al codificador (2 capas de 128 neuronas con *ReLU*) que reconstruye el vector transformado $\hat{\mathbf{x}}$ a partir de $\mathbf{z}$, con las mismas activaciones de salida que el generador de CTGAN (tanh para continuas, softmax para categóricas). El entrenamiento minimiza

la cota inferior de la evidencia (*Evidence Lower Bound*, ELBO):

$$\mathcal{L}_{\text{ELBO}}(\theta, \phi; \mathbf{x}) = \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x} | \mathbf{z})]}_{\text{término de reconstrucción}} - \underbrace{D_{\text{KL}}(q_\phi(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z}))}_{\text{regularización del espacio latente}} \quad (4.5)$$

donde $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ es la distribución a priori del espacio latente. El término de reconstrucción mide con qué fidelidad el decodificador recupera la muestra original, mientras que el término KL actúa como regularizador que fuerza la distribución a posteriori a no alejarse demasiado de la a priori, estructurando el espacio latente y previniendo el sobreajuste. Una regularización ℓ_2 adicional con coeficiente $\lambda_{\ell_2} = 10^{-5}$ sobre los pesos del decodificador completa la función de pérdida.

Hiperparámetros. La Tabla 4.6 recoge la configuración de TVAE. Las capas ocultas del codificador y decodificador son más estrechas que las de CTGAN (128 frente a 256 neuronas) porque el objetivo del codificador es comprimir la representación hacia el espacio latente, no generar diversidad a partir del ruido, por lo que una mayor anchura no aporta beneficio y aumenta el riesgo de sobreajuste. El número de épocas y el *batch size* se mantienen iguales a CTGAN para garantizar la comparabilidad del coste computacional de entrenamiento.

Tabla 4.6: Hiperparámetros de CTGAN y TVAE. Los valores marcados con (†) son comunes a ambos modelos.

Hiperparámetro	CTGAN	TVAE	Justificación
epochs [†]	300	300	Convergencia estable en datasets de tamaño comparable
batch_size [†]	500	500	≈2,2% del dataset por paso; equilibrio sesgo-varianza
embedding_dim [†]	128	128	Espacio latente suficiente para 127 atributos de entrada
generator_dim	(256, 256)	—	Dos capas simétricas al discriminador
discriminator_dim	(256, 256)	—	Paridad con el generador para evitar dominancia
compress_dims	—	(128, 128)	Compresión progresiva hacia el espacio latente
decompress_dims	—	(128, 128)	Simétrico al codificador
pac	10	—	PacGAN: agrupa 10 muestras para detectar mode collapse
l2scale	—	10 ⁻⁵	Regularización ligera del decodificador

4.2.3. Modelo de difusión: TabDDPM

TabDDPM [15] adapta el marco de los modelos de difusión probabilística denoising (*Denoising Diffusion Probabilistic Models*, DDPM) [14] al dominio de los datos tabulares. A diferencia de CTGAN y TVAE, cuya arquitectura está orientada a aprender directamente una transformación desde un espacio latente al espacio de datos, TabDDPM modela implícitamente la distribución de los datos a través de un proceso iterativo de añadir y eliminar ruido. Esta perspectiva, de raíces en la termodinámica del no equilibrio [31], conduce a un modelo cuyo entrenamiento es inherentemente estable (al no depender de ningún equilibrio adversarial) y cuya cobertura de la distribución es sistemáticamente superior a la de los enfoques adversariales en benchmarks de datos tabulares [15].

Proceso de difusión hacia adelante

El proceso de difusión hacia adelante define una cadena de Markov de T pasos que destruye progresivamente la información de los datos mediante la adición de ruido gaussiano. Dado un dato real $\mathbf{x}_0 \sim q(\mathbf{x})$, la transición en el paso t es:

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}) \quad (4.6)$$

donde $\{\beta_t\}_{t=1}^T$ es la **agenda de ruido** (*noise schedule*), una secuencia creciente de varianzas que controla cuánto ruido se añade en cada paso. Se emplea la **agenda coseno** de Nichol y Dhariwal [32], que define los productos acumulados $\bar{\alpha}_t$ mediante una función coseno suavizada:

$$\bar{\alpha}_t = \frac{f(t)}{f(0)}, \quad f(t) = \cos^2\left(\frac{t/T + s}{1 + s} \cdot \frac{\pi}{2}\right) \quad (4.7)$$

donde $s = 0,008$ es un pequeño desplazamiento que evita que β_t sea demasiado grande cerca de $t = 0$. Los coeficientes β_t se derivan como $\beta_t = 1 - \bar{\alpha}_t/\bar{\alpha}_{t-1}$, recortados al intervalo $[10^{-5}, 0,999]$ para estabilidad numérica. Frente a la agenda lineal estándar de Ho et al. [14], la agenda coseno produce una transición señal-ruido más gradual al final de la cadena, lo que mejora la generación en distribuciones con colas largas como las habituales en datos clínicos de UCI. Una propiedad clave de este proceso es que la distribución marginal en el paso t puede calcularse en forma cerrada sin simular los t pasos intermedios:

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}) \quad (4.8)$$

donde $\alpha_t = 1 - \beta_t$ y $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ es el producto acumulado de los factores de señal. En consecuencia, $\mathbf{x}_t$ puede escribirse de forma explícita como:

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (4.9)$$

Para $t = T = 1000$, $\bar{\alpha}_T \approx 0$, de modo que $\mathbf{x}_T \approx \mathcal{N}(\mathbf{0}, \mathbf{I})$: la información original queda completamente destruida y la distribución converge a ruido puro.

Proceso de denoising inverso y arquitectura de la red

El proceso inverso aprende a revertir la cadena de Markov, recuperando gradualmente $\mathbf{x}_0$ a partir de $\mathbf{x}_T$. Bajo la suposición de que las transiciones inversas son también gaussianas, se parametriza:

$$p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \sigma_t^2 \mathbf{I}) \quad (4.10)$$

donde $\sigma_t^2 = \beta_t$ es fija y $\boldsymbol{\mu}_\theta$ es la única cantidad aprendida. Ho et al. [14] demuestran que parametrizar $\boldsymbol{\mu}_\theta$ en términos del ruido predicho $\boldsymbol{\varepsilon}_\theta(\mathbf{x}_t, t)$ conduce a la función de pérdida simplificada:

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{t, \mathbf{x}_0, \boldsymbol{\varepsilon}} \left[\left\| \boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}_\theta(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\varepsilon}, t) \right\|^2 \right] \quad (4.11)$$

que equivale a un objetivo MSE sobre el ruido: la red aprende, dado un dato corrompido $\mathbf{x}_t$ y el instante t , a predecir el ruido $\boldsymbol{\varepsilon}$ que fue añadido.

Arquitectura de la red de denoising. A diferencia de las aplicaciones de difusión sobre imágenes, que emplean arquitecturas U-Net con capas de convolución para explotar la estructura espacial, los datos tabulares carecen de ordenación espacial entre variables, por lo que TabDDPM emplea un **MLP con bloques residuales** como red de denoising $\boldsymbol{\varepsilon}_\theta$. La entrada a la red es la concatenación del dato corrompido $\mathbf{x}_t$ con la *embedding* del instante de tiempo t . El instante $t \in \{1, \dots, T\}$ se codifica mediante **codificación posicional sinusoidal** de dimensión 128, análoga a la empleada en los *transformers* [14], proyectada después a través de dos capas lineales con activación SiLU (*Sigmoid Linear Unit*):

$$\text{emb}(t) = \text{Linear}(\text{SiLU}(\text{Linear}(\text{PE}(t)))) \in \mathbb{R}^{128} \quad (4.12)$$

Cada bloque residual de la red aplica la transformación:

$$\mathbf{h}^{(l)} = \text{SiLU} \left(\text{BN} \left(\mathbf{W}_2^{(l)} \text{SiLU} \left(\mathbf{W}_1^{(l)} \mathbf{h}^{(l-1)} + \text{emb}(t) \right) \right) \right) + \mathbf{h}^{(l-1)} \quad (4.13)$$

La activación SiLU, definida como $\text{SiLU}(x) = x \cdot \sigma(x)$, ofrece gradientes más suaves que ReLU y resulta empíricamente más efectiva en redes de denoising [15]. La red se configura con 4 capas ocultas de 512 neuronas, y su salida tiene la misma dimensión que el vector de entrada d_{trans} .

Tratamiento de variables categóricas: difusión multinomial

La formulación gaussiana de las ecuaciones (4.6)–(4.11) es adecuada para variables continuas, pero no se puede aplicar directamente a variables categóricas codificadas en *one-hot*, ya que añadir ruido gaussiano a un vector *one-hot* produce vectores que no corresponden a ninguna categoría válida. TabDDPM resuelve esto aplicando **difusión multinomial** [33] de forma independiente a cada columna categórica.

En la difusión multinomial, el proceso hacia adelante opera sobre la distribución de probabilidad de cada categoría. Para una variable con K clases representada como $\mathbf{x}_0 \in \{0, 1\}^K$, la transición en el paso t es:

$$q(\mathbf{x}_t \mid \mathbf{x}_{t-1}) = \text{Cat}(\mathbf{x}_t; \mathbf{Q}_t \mathbf{x}_{t-1}) \quad (4.14)$$

donde $\mathbf{Q}_t$ es una matriz de transición estocástica que mezcla la distribución original con la distribución uniforme sobre las K clases. Conforme $t \rightarrow T$, la distribución converge a $\text{Uniform}(K)$, borrando la información de la categoría original. La red de denoising aprende a predecir directamente $\hat{\mathbf{x}}_0$ a partir de $\mathbf{x}_t$ para las columnas categóricas, optimizando un objetivo de entropía cruzada en lugar de MSE. La función de pérdida total es la suma ponderada de los objetivos gaussiano y multinomial sobre todas las columnas.

Hiperparámetros y comparativa con CTGAN y TVAE

Ventajas frente a CTGAN y TVAE. La principal ventaja de TabDDPM sobre los modelos adversariales y variacionales es la **estabilidad de entrenamiento**: al no existir competencia entre redes, el proceso de optimización converge de forma monótona y reproducible. Además, la formulación de denoising iterativo fuerza al modelo a aprender la estructura de la distribución en múltiples escalas de resolución (desde el ruido fino hasta la estructura global), lo que se traduce en una **mejor cobertura de los modos** y menor tendencia al colapso. La contrapartida es el **coste de inferencia**: generar N muestras requiere ejecutar los $T = 1000$ pasos de denoising para cada una, lo que hace la síntesis considerablemente más lenta que CTGAN o TVAE, donde una sola pasada por el generador produce una muestra. Este coste es asumible en el contexto de este trabajo, donde la generación se realiza una única vez para producir el dataset sintético de evaluación.

4.2.4. Privacidad diferencial: fundamentos y aplicación

Los tres modelos descritos en las secciones anteriores generan datos sintéticos con alta fidelidad estadística, pero sin ofrecer ninguna garantía formal sobre la privacidad de los individuos del conjunto de entrenamiento. Un modelo que haya memorizado casos particulares puede revelar información sensible de pacientes reales a través de las muestras que genera. La **privacidad diferencial** (DP) [16] proporciona una definición

Tabla 4.7: Hiperparámetros de TabDDPM y comparativa con CTGAN/TVAE.

Hiperparámetro	Valor	Justificación
T (pasos de difusión)	1000	Agenda estándar DDPM; convergencia a ruido puro garantizada
noise_schedule	Coseno [32]	Transición señal-ruido más gradual; mejor para distribuciones con colas largas
hidden_dims	$(512) \times 4$	4 bloques residuales de 512 neuronas; mayor capacidad que CTGAN/TVAE
time_emb_dim	128	Codificación posicional sinusoidal de dimensión estándar
dropout	0,0	El proceso de difusión actúa como regularizador implícito
batch_size	4096	Estabilidad de entrenamiento sin restricción adversarial
epochs	1000	5.000 pasos de gradiente ($\lfloor 22520/4096 \rfloor \times 1000$)
lr	3×10^{-4}	Adam con decaimiento coseno; estándar en modelos de difusión
Función de pérdida	MSE sobre ruido	$\mathcal{L}_{\text{simple}}$ de Ho et al. [14]
Normalización numérica	QuantileTransformer (<i>output</i> ='normal', <i>n</i> =1000)	Mapeo exacto a $\mathcal{N}(0, 1)$; evita divergencia del proceso inverso

matemática precisa de privacidad que cuantifica esta fuga de información y establece garantías formales sobre ella, convirtiéndose en el estándar de referencia para el análisis de privacidad en aprendizaje automático [18].

Definición formal y parámetros

Definición (ε, δ) -DP. Dos datasets D y D' se denominan **adyacentes** si difieren en exactamente un registro, es decir, si D' se obtiene añadiendo o eliminando la información de un único individuo. Un mecanismo aleatorio $\mathcal{M} : \mathcal{D} \rightarrow \mathcal{R}$ satisface (ε, δ) -**privacidad diferencial** si para todo par de datasets adyacentes D, D' y para todo subconjunto de resultados posibles $S \subseteq \mathcal{R}$:

$$\Pr[\mathcal{M}(D) \in S] \leq e^\varepsilon \cdot \Pr[\mathcal{M}(D') \in S] + \delta \quad (4.15)$$

El parámetro $\varepsilon > 0$ (*privacy budget*) controla cuánto puede cambiar la distribución de salida del mecanismo al añadir o eliminar un individuo: valores pequeños implican que la presencia de cualquier paciente es prácticamente indetectable en el modelo entrenado, mientras que $\varepsilon \rightarrow \infty$ equivale a no ofrecer ninguna protección. El parámetro $\delta \geq 0$ permite una pequeña probabilidad de violación de la garantía; en la práctica se fija en un valor despreciable respecto al tamaño del dataset, típicamente $\delta = 1/N$. En este trabajo se emplea $\delta = 1/22520 \approx 4,4 \times 10^{-5}$.

Mecanismo gaussiano y sensibilidad. La forma más directa de hacer privado un cálculo es añadir ruido aleatorio calibrado a la **sensibilidad** ℓ_2 de la función que se computa. La sensibilidad $\Delta_2 f$ de una función $f : \mathcal{D} \rightarrow \mathbb{R}^d$ mide el máximo cambio en su salida al modificar un único registro:

$$\Delta_2 f = \max_{D, D' \text{ adyacentes}} \|f(D) - f(D')\|_2 \quad (4.16)$$

El **mecanismo gaussiano** añade ruido $\mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ con $\sigma \geq \Delta_2 f \cdot \sqrt{2 \ln(1,25/\delta)} / \varepsilon$ para garantizar (ε, δ) -DP [16]. La relación inversa entre σ y ε es la expresión formal del compromiso privacidad–fidelidad: menos presupuesto de privacidad exige más ruido, que degrada la calidad del modelo aprendido.

DP-SGD: descenso por gradiente con privacidad diferencial

El algoritmo **DP-SGD** de Abadi et al. [18] extiende el descenso por gradiente estocástico estándar para satisfacer (ε, δ) -DP aplicando el mecanismo gaussiano sobre los gradientes de cada paso de entrenamiento. El procedimiento en cada iteración es:

1. **Muestreo aleatorio del minibatch:** se muestrea un subconjunto $\mathcal{B} \subseteq D$ con probabilidad de inclusión $q = |\mathcal{B}|/N$ para cada registro (*subsampling de Poisson*). Este paso amplifica la privacidad por un factor $\approx q$, ya que un individuo solo contribuye al gradiente cuando es incluido en el minibatch.
2. **Cómputo de gradientes por muestra:** para cada $\mathbf{x}_i \in \mathcal{B}$ se calcula el gradiente individual $\mathbf{g}_i = \nabla_{\theta} \mathcal{L}(\theta; \mathbf{x}_i)$.
3. **Gradient clipping:** cada gradiente se recorta a norma ℓ_2 máxima C (*clipping threshold*):

$$\tilde{\mathbf{g}}_i = \mathbf{g}_i / \max\left(1, \frac{\|\mathbf{g}_i\|_2}{C}\right) \quad (4.17)$$

Esta operación acota la sensibilidad ℓ_2 del gradiente medio a $C/|\mathcal{B}|$, lo que establece la escala del ruido necesario.

4. **Adición de ruido gaussiano:** se suma ruido calibrado al gradiente agregado:

$$\tilde{\mathbf{g}} = \frac{1}{|\mathcal{B}|} \left(\sum_{i \in \mathcal{B}} \tilde{\mathbf{g}}_i + \mathcal{N}(\mathbf{0}, \sigma^2 C^2 \mathbf{I}) \right) \quad (4.18)$$

donde el *noise multiplier* σ determina la intensidad del ruido relativa al umbral de clipping.

5. **Actualización de parámetros:** $\theta \leftarrow \theta - \eta \tilde{\mathbf{g}}$, idéntica a SGD estándar.

Contabilidad de la privacidad. Cada paso de DP-SGD consume una fracción del presupuesto total ε . La composición ingenua de T pasos produciría un gasto lineal $\varepsilon_{\text{total}} \approx T \cdot \varepsilon_{\text{paso}}$, lo que hace impracticable el entrenamiento de redes neuronales con miles de pasos. Abadi et al. introdujeron el *moments accountant*, posteriormente formalizado como **privacidad diferencial de Rényi** (RDP) [34], que acumula el gasto de privacidad con precisión mucho mayor. La librería Opacus [19] implementa este contable automáticamente: dados el tamaño del dataset N , el batch size $|\mathcal{B}|$, el *noise multiplier* σ y el número de pasos T , calcula el ε exacto consumido al finalizar el entrenamiento bajo la restricción $\delta = 1/N$.

Aplicación sobre CTGAN: DP-CTGAN

Dónde se aplica DP-SGD. En el esquema adversarial de CTGAN, solo el discriminador D procesa datos reales; el generador G recibe únicamente gradientes procedentes de D , que ya han sido privatizados. Por tanto, DP-SGD se aplica **exclusivamente al optimizador del discriminador**, sin modificar el entrenamiento del generador. Esta asimetría es la que permite mantener garantías formales de privacidad sobre el dataset de entrenamiento sin alterar la arquitectura del generador. Para simplificar la integración con Opacus, la implementación prescinde de la normalización por moda (VGM) y del muestreo condicional propios de CTGAN; en consecuencia, el rendimiento de DP-CTGAN con $\varepsilon=\infty$ es ligeramente inferior al del CTGAN estándar, diferencia que no debe atribuirse a la privacidad diferencial.

Integración con Opacus. La implementación utiliza la librería Opacus [19], que envuelve el optimizador del discriminador con un **PrivacyEngine** que intercepta los gradientes tras la retropropagación, aplica el clipping por muestra y añade el ruido gaussiano antes de cada actualización. El *noise multiplier* σ no se fija directamente, sino que se calcula automáticamente mediante búsqueda binaria a partir del ε objetivo, δ , N , el batch size y el número de épocas, garantizando que el presupuesto de privacidad no sea superado al final del entrenamiento.

Barrido de ε y análisis del *tradeoff*. El objetivo central de DP-CTGAN no es obtener el mejor modelo generativo, sino **cuantificar el compromiso privacidad–fidelidad** como función de ε . Para ello se entrenan cuatro variantes con presupuestos crecientes: $\varepsilon \in \{1, 5, 10, \infty\}$, donde $\varepsilon = \infty$ corresponde al CTGAN estándar sin privacidad diferencial y actúa como cota superior de fidelidad alcanzable. Los parámetros de entrenamiento no relacionados con DP se mantienen idénticos entre las cuatro variantes para aislar el efecto de ε sobre la calidad de los datos sintéticos.

Tabla 4.8: Configuración de DP-CTGAN. Los hiperparámetros de arquitectura son idénticos a CTGAN (Tabla 4.6).

Hiperparámetro	Valor	Justificación
ε objetivo	$\{1, 5, 10, \infty\}$	Barrido para curva privacidad–fidelidad
δ	$4,4 \times 10^{-5}$	$1/N = 1/22520$; despreciable respecto al dataset
<code>max_grad_norm</code> C	1,0	Umbral estándar; equilibrio sensibilidad–ruido
σ (<i>noise multiplier</i>)	Calculado por Opacus	Derivado de ε , δ , N , batch size y épocas
<code>batch_size</code>	500	Igual que CTGAN para comparabilidad
<code>epochs</code>	300	Igual que CTGAN; Opacus garantiza ε al finalizar

La evaluación de las cuatro variantes en el Capítulo 5 permitirá trazar la curva ε –fidelidad para la cohorte MIMIC-III, cuantificando a qué coste en calidad de datos se obtiene cada nivel de garantía formal de privacidad.

5. Experimentación y Resultados

El objetivo de la experimentación realizada en este capítulo es evaluar de forma sistemática la capacidad de los modelos generativos implementados en el Capítulo 4 para la generación de datos clínicos sintéticos de registros en UCI, contrastando su comportamiento en tres dimensiones complementarias: fidelidad estadística respecto a los datos reales, utilidad analítica para tareas de predicción clínica y riesgo de privacidad. Los resultados permiten identificar qué modelos ofrecen el mejor equilibrio entre calidad de síntesis y garantías de protección del paciente, y cuantificar el compromiso entre ambas dimensiones cuando se incorpora privacidad diferencial.

Todos los experimentos descritos en este capítulo se ejecutaron en el servidor del grupo de investigación en Informática Médica e Inteligencia Artificial MedAI Lab la Facultad de Informática de la Universidad de Murcia, equipado con una GPU NVIDIA RTX A4500 (20 GB de VRAM). El entorno de software utilizado es Python 3.12 con PyTorch 2 y Opacus 1.4 para el entrenamiento de los modelos generativos, SDV/SD-Metrics para la generación y parte de la evaluación, y XGBoost y scikit-learn para los modelos *downstream*.

5.1. Evaluación de Fidelidad Estadística

5.1.1. Metodología de evaluación de fidelidad

La **fidelidad estadística** de un conjunto de datos sintéticos mide hasta qué punto su distribución de probabilidad reproduce la del conjunto de datos real del que procede [20]. Una fidelidad alta implica que cualquier análisis estadístico o modelo predictivo entrenado sobre los datos sintéticos obtendrá resultados equivalentes a los que produciría con los datos reales, lo que es condición necesaria, aunque no suficiente, para que los datos sintéticos sean útiles en la práctica.

La evaluación de la fidelidad presenta una dificultad fundamental: no existe una única métrica que capture todos los aspectos relevantes de la similitud distribucional. Las métricas de distribución marginal miden si cada variable se reproduce individualmente, pero son ciegas a las correlaciones entre variables. Las métricas de distribución conjunta capturan las relaciones multivariantes pero son difíciles de interpretar variable a variable. Los métodos visuales permiten una inspección global pero no cuantifican diferencias con precisión. El test de discriminación ofrece una perspectiva global pero no localiza qué variables o relaciones están mal capturadas. Por este motivo, la evaluación se articula en torno a un conjunto de métricas complementarias que, tomadas en

conjunto, ofrecen una caracterización rigurosa y multidimensional de la fidelidad.

El marco de evaluación se aplica de forma idéntica a los cuatro modelos (CTGAN, TVAE, TabDDPM y DP-CTGAN) sobre los mismos conjuntos de datos sintéticos de tamaño $N = 22.520$, lo que garantiza la comparabilidad de los resultados. En el caso de DP-CTGAN, la evaluación se realiza por separado para cada valor de $\varepsilon \in \{1, 5, 10, \infty\}$, de modo que las diferencias de fidelidad pueden atribuirse exclusivamente al presupuesto de privacidad.

5.1.2. Métricas de distribuciones marginales

Las métricas de distribución marginal evalúan cada variable de forma independiente, comparando su distribución empírica en el dataset real con la correspondiente distribución en el sintético.

Divergencia Jensen-Shannon (JSD). La divergencia Jensen-Shannon es una versión simétrica y acotada de la divergencia de Kullback-Leibler, lo que la hace especialmente adecuada para comparar distribuciones empíricas. Para dos distribuciones de probabilidad P (real) y Q (sintética), se define como:

$$\text{JSD}(P\|Q) = \frac{1}{2} D_{\text{KL}}\left(P \parallel M\right) + \frac{1}{2} D_{\text{KL}}\left(Q \parallel M\right), \quad M = \frac{P + Q}{2} \quad (5.1)$$

donde $D_{\text{KL}}(P\|M) = \sum_x P(x) \log \frac{P(x)}{M(x)}$ es la divergencia KL estándar. El valor de JSD está acotado en $[0, \log 2]$ (o en $[0, 1]$ si se emplea logaritmo en base 2): JSD = 0 indica distribuciones idénticas y JSD = 1 distribuciones con soporte completamente disjunto. Para variables continuas, las distribuciones se estiman mediante histogramas con 50 *bins* de anchura uniforme calculados sobre el rango del dataset real. Se computa una JSD por columna y se reporta tanto la mediana como la distribución completa de valores para identificar qué variables presentan mayor discrepancia.

Estadístico KS (Column Shapes). El test de Kolmogorov-Smirnov de dos muestras compara las funciones de distribución acumulada empíricas F_n (real) y G_m (sintética) mediante el estadístico:

$$D_{n,m} = \sup_x |F_n(x) - G_m(x)| \quad (5.2)$$

A diferencia de la JSD, el estadístico KS no requiere elección de *bins* y es sensible a diferencias en cualquier parte de la distribución, incluyendo las colas. Se calcula para cada columna numérica y se reporta el p -valor asociado; valores $p < 0,05$ indican que la hipótesis de distribuciones idénticas se rechaza al nivel de significación del 5 %.

5.1.3. Métricas de distribuciones conjuntas

Las métricas de distribución conjunta evalúan si el modelo generativo ha aprendido las relaciones multivariantes presentes en los datos reales, más allá de las distribuciones marginales individuales.

Maximum Mean Discrepancy (MMD). La *Maximum Mean Discrepancy* [35] es un test de dos muestras no paramétrico que compara las distribuciones P y Q a través de sus incrustaciones en un espacio de Hilbert con kernel reproductor. Dado un kernel $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$, el MMD al cuadrado se estima sobre muestras $\{x_i\}_{i=1}^n \sim P$ e $\{y_j\}_{j=1}^m \sim Q$ como:

$$\widehat{\text{MMD}}^2(P, Q) = \frac{1}{n^2} \sum_{i, i'} k(x_i, x_{i'}) - \frac{2}{nm} \sum_{i, j} k(x_i, y_j) + \frac{1}{m^2} \sum_{j, j'} k(y_j, y_{j'}) \quad (5.3)$$

Se emplea un kernel RBF (*Radial Basis Function*) $k(x, y) = \exp(-\|x - y\|^2 / (2\sigma^2))$ con anchura de banda σ fijada mediante la heurística de la mediana sobre las distancias entre pares de muestras del dataset real. El MMD captura diferencias en momentos de cualquier orden, siendo cero si y solo si $P = Q$.

Distancia de Wasserstein-1. La distancia de Wasserstein-1 (o *Earth Mover's Distance*) entre P y Q se interpreta como el coste mínimo de transportar la masa de una distribución a la otra:

$$W_1(P, Q) = \inf_{\gamma \in \Gamma(P, Q)} \mathbb{E}_{(x, y) \sim \gamma} [\|x - y\|] \quad (5.4)$$

donde $\Gamma(P, Q)$ es el conjunto de distribuciones conjuntas con marginales P y Q . A diferencia de la divergencia KL, W_1 está bien definida incluso cuando las distribuciones tienen soportes disjuntos, propiedad especialmente relevante para comparar distribuciones de alta dimensionalidad [25]. Para hacer el cómputo tratable, la distancia se calcula sobre las dos primeras componentes principales del espacio de *features* combinado (real + sintético).

Matrices de correlación. Se calculan las matrices de correlación de Pearson entre las variables cuantitativas del dataset real y del sintético, y se compara su similitud mediante el *Mean Absolute Error* entre los coeficientes correspondientes:

$$\Delta\rho = \frac{1}{|\mathcal{V}|^2} \sum_{i, j \in \mathcal{V}} \left| \rho_{ij}^{\text{real}} - \rho_{ij}^{\text{synth}} \right| \quad (5.5)$$

donde $\mathcal{V}$ es el conjunto de variables numéricas y ρ_{ij} es la correlación de Pearson entre las variables i y j . Un $\Delta\rho$ próximo a cero indica que el modelo generativo ha aprendido

la estructura de dependencia lineal entre variables. Como referencia clínica, se verifica específicamente que las correlaciones con mayor valor diagnóstico (GCS total con mortalidad, lactato con mortalidad, BUN con mortalidad) se preserven dentro de un margen de $\pm 0,05$.

5.1.4. Análisis visual: UMAP y t-SNE

Las proyecciones no lineales de alta dimensionalidad a dos dimensiones permiten una inspección visual directa de la superposición entre las distribuciones real y sintética, complementando las métricas cuantitativas anteriores con una perspectiva holística.


Protocolo de proyección conjunta. Para cada modelo generativo, se construye un dataset mixto concatenando $N/2$ muestras del dataset real y $N/2$ muestras del sintético, seleccionadas aleatoriamente, y se aplica la proyección sobre el dataset mixto completo. El origen de cada punto (real o sintético) se codifica mediante el color en la visualización resultante. Esta estrategia garantiza que la proyección capture la geometría conjunta de ambas distribuciones sin sesgar la representación hacia ninguna de las dos.

UMAP. UMAP (*Uniform Manifold Approximation and Projection*) [36] construye una representación en baja dimensión preservando tanto la estructura local como la global del espacio de alta dimensión, aproximando la variedad topológica de los datos mediante una triangulación fuzzy. Se emplea con $n_neighbors = 15$ y $min_dist = 0,1$, parámetros que equilibran la fidelidad local y global. Una proyección con alto solapamiento entre puntos reales y sintéticos indica indistinguibilidad distribucional; la presencia de regiones o *clusters* exclusivos de uno de los dos tipos revela modos de la distribución real que el modelo no ha aprendido (*mode dropping*) o modos espurios que el modelo ha generado sin correspondencia en los datos reales (*mode invention*).


t-SNE. t-SNE (*t-distributed Stochastic Neighbor Embedding*) [37] maximiza la preservación de las distancias locales entre puntos, siendo especialmente sensible a la estructura de *clusters* finos. Se emplea con $perplexity = 30$ y se aplica sobre las 50 primeras componentes principales para reducir el coste computacional. La comparación entre la proyección UMAP y la t-SNE permite discriminar si las diferencias observadas son de naturaleza local (estructura fina de *clusters*) o global (disposición general de la distribución).

5.1.5. Test de discriminación

El test de discriminación evalúa la fidelidad desde la perspectiva de un adversario que intenta distinguir muestras reales de sintéticas: si los datos sintéticos son esta-



(a) UMAP



(b) t-SNE

Figura 5.1: Proyecciones UMAP (arriba) y t-SNE (abajo) del espacio de *features* para cada modelo generativo. Los puntos grises representan muestras reales y los de color muestras sintéticas. El alto grado de solapamiento en CTGAN y TVAE indica indistinguibilidad distribucional global; la separación visible en TabDDPM es consecuencia directa de sus distribuciones marginales distorsionadas.

dísticamente indistinguibles, ningún clasificador debería ser capaz de separarlos con precisión superior al azar.

Protocolo experimental. Se construye un dataset balanceado de $2N$ muestras: N muestras del dataset real (etiqueta 1) y N muestras del sintético (etiqueta 0). El dataset se divide en entrenamiento (80 %) y test (20 %) mediante muestreo estratificado para garantizar el balance de clases en ambas particiones. Se entrena un clasificador **XGBoost** con hiperparámetros por defecto sobre el conjunto de entrenamiento y se evalúa sobre el conjunto de test. La elección de XGBoost responde a su capacidad para capturar relaciones no lineales y su robustez frente a distribuciones mixtas de variables continuas y categóricas, cualidades que lo hacen un adversario más exigente que un clasificador lineal.

Métrica e interpretación. La métrica principal es el **AUC-ROC** (*Area Under the Receiver Operating Characteristic Curve*). Su interpretación en este contexto difiere de la habitual en clasificación: el objetivo **no** es maximizar el AUC sino minimizarlo. Un AUC de 0,5 indica que el clasificador no puede distinguir muestras reales de sintéticas mejor que el azar, lo que equivale a una fidelidad perfecta desde la perspectiva adversarial. Un AUC próximo a 1 indica que el clasificador separa fácilmente los dos conjuntos, revelando que los datos sintéticos presentan diferencias sistemáticas respecto a los reales. Como umbral orientativo, se considera que un $\text{AUC} \leq 0,60$ corresponde a una fidelidad alta, mientras que $\text{AUC} > 0,75$ señala discrepancias distribucionales relevantes. Adicionalmente, se reporta la importancia de *features* del clasificador para identificar qué variables contribuyen más a la separación, lo que orienta el análisis de qué aspectos de la distribución el modelo generativo reproduce peor.


5.1.6. Discusión comparativa de fidelidad

La Tabla 5.1 consolida las métricas de las secciones anteriores para los siete modelos evaluados. Las columnas recogen, de izquierda a derecha, la mediana de la divergencia Jensen-Shannon por variable (JSD), la mediana del estadístico KS, el MMD², la distancia de Wasserstein-1 sobre las dos primeras componentes principales y la desviación media absoluta en la matriz de correlaciones ($\Delta\rho$). El AUC del test de discriminación se discute por separado en el párrafo final de esta sección.

Distribuciones marginales. CTGAN y TVAE presentan la mayor fidelidad marginal: ambos obtienen una JSD mediana de 0,008, muy por debajo del umbral orientativo de 0,05 que separa una distribución sintética aceptable de una problemática. El estadístico KS mediano de TVAE (0,082) es inferior al de CTGAN (0,117), lo que indica que TVAE reproduce las formas de las distribuciones individuales con mayor precisión, especialmente en las colas. Este resultado es coherente con el mecanismo de generación variacional, que aproxima la distribución completa mediante el ELBO, frente

Tabla 5.1: Métricas de fidelidad estadística por modelo generativo. Mejor valor en negrita.

Modelo	JSD med.	KS med.	MMD ²	W_1	$\Delta\rho$
CTGAN	0,0080	0,1165	0,0189	20,6	0,059
TVAE	0,0085	0,0819	0,0053	19,9	0,035
TabDDPM	0,6442	0,5301	0,5541	1359,3	0,056
DP-CTGAN $\varepsilon=\infty$	0,0229	0,1497	0,0151	36,3	0,060
DP-CTGAN $\varepsilon=10$	0,0424	0,1794	0,0233	40,9	0,147
DP-CTGAN $\varepsilon=5$	0,0506	0,2112	0,0569	21,8	0,196
DP-CTGAN $\varepsilon=1$	0,1057	0,2907	0,0734	56,0	0,375

**Figura 5.2:** Distribución de la JSD por variable para cada modelo generativo. La línea central de cada caja representa la mediana reportada en la Tabla 5.1; la caja muestra el rango intercuartílico sobre las 121 variables evaluadas. La diferencia de dos órdenes de magnitud entre TabDDPM y el resto de modelos refleja la distorsión sistemática de sus distribuciones marginales.

al entrenamiento adversarial de CTGAN, cuyo objetivo no garantiza directamente la preservación de las colas.

DP-CTGAN con $\varepsilon = \infty$ (equivalente a CTGAN sin privacidad) muestra una JSD de 0,023, ligeramente superior a CTGAN por diferencias estocásticas en la implementación DP—el entrenamiento con Opacus modifica la dinámica de actualización del discriminador incluso con ruido nulo—pero permanece claramente por debajo del umbral de 0,05. La degradación es estrictamente monotonica al reducir ε : $0,023 \rightarrow 0,042 \rightarrow 0,051 \rightarrow 0,106$, cuantificando de forma empírica el coste en fidelidad marginal de cada nivel de garantía de privacidad.

TabDDPM exhibe una JSD mediana de 0,644, dos órdenes de magnitud superior

a CTGAN y TVAE. Este resultado contrasta con los benchmarks reportados en el paper original [15]. Una hipótesis inicial atribuía la distorsión a la normalización global aplicada a las columnas numéricas y a la ausencia de tratamiento diferenciado por tipo de columna; sin embargo, un experimento de ablación posterior descartó esta explicación como causa principal, identificando en cambio una divergencia en el proceso de difusión inverso (véase el párrafo de ablación al final de esta sección). Pese a ello, el modelo genera datos clínicamente plausibles en escala, con valores de constantes vitales dentro de los rangos fisiológicos esperados.

Distribuciones conjuntas. El MMD² y la distancia de Wasserstein-1 confirman el patrón observado en las métricas marginales. TVAE obtiene el MMD² más bajo (0,005), seguido de CTGAN (0,019), lo que indica que TVAE reproduce con mayor fidelidad la distribución conjunta en el espacio de *features* completo. La distancia W_1 es similar para ambos modelos (19,9 y 20,6 respectivamente), coherente con una calidad de síntesis equivalente a nivel global.

Para DP-CTGAN, el W_1 no sigue una degradación perfectamente monotónica con ε ($36,3 \rightarrow 40,9 \rightarrow 21,8 \rightarrow 56,0$), a diferencia de la JSD. Esta irregularidad es esperable: W_1 se calcula sobre las dos primeras componentes PCA del espacio combinado y es sensible a la orientación de los ejes principales, que varía entre modelos. La JSD y el $\Delta\rho$, al operar variable a variable, son indicadores más estables del efecto del presupuesto ε .

TabDDPM presenta un W_1 de 1.359,3, lo que refleja un desplazamiento sistemático entre las distribuciones proyectadas. Sin embargo, el MMD² de 0,554 hay que interpretarlo con cautela: el kernel RBF utiliza un parámetro σ estimado sobre la distribución real, por lo que cuando la distribución sintética tiene soporte parcialmente fuera del rango del dataset real (como ocurre en TabDDPM para algunas variables) el kernel puede subestimar la discrepancia real.

Estructura de correlaciones ($\Delta\rho$). El resultado más llamativo en términos de correlaciones es el de TabDDPM: con un $\Delta\rho = 0,056$, es el tercer mejor modelo por detrás de TVAE (0,035) y CTGAN (0,059), y muy por delante de las variantes DP-CTGAN con ε restringido. Esto indica que el proceso de difusión aprende la estructura de dependencia lineal entre variables con notable precisión, aunque no logre reproducir las distribuciones marginales individuales. A nivel de pares diagnósticamente relevantes, TVAE y CTGAN preservan la correlación negativa GCS–mortalidad ($-0,239$ y $-0,225$ frente al valor real $-0,284$), mientras que TabDDPM la subestima ($-0,165$). La correlación lactato–mortalidad se preserva de forma similar en los tres modelos ($0,140$ – $0,160$ frente al real $0,194$).

El deterioro de $\Delta\rho$ en DP-CTGAN es la señal más clara del coste de la privacidad diferencial: $0,060 \rightarrow 0,147 \rightarrow 0,196 \rightarrow 0,375$. Con $\varepsilon = 1$, el ruido DP-SGD destruye prácticamente todas las correlaciones entre variables, lo que implica que los datos generados bajo este presupuesto no mantienen relaciones clínicas coherentes. Esto es

coherente con la teoría: el ruido gaussiano necesario para garantizar $\varepsilon = 1$ sobre un dataset de 22.520 muestras tiene un multiplicador de ruido muy elevado, que homogeneiza los gradientes del discriminador hasta el punto de impedir que el generador aprenda dependencias multivariantes.




Figura 5.3: Matrices de correlación de Pearson del dataset real y de cada modelo generativo. El color indica dirección e intensidad de la correlación (rojo: positiva, azul: negativa). TVAE y CTGAN reproducen fielmente la estructura de correlaciones del dataset original; DP-CTGAN $\varepsilon=1$ presenta una matriz casi uniforme, coherente con su $\Delta\rho = 0,376$.

Test de discriminación XGBoost. El clasificador XGBoost obtiene $AUC = 1,0$ para los siete modelos evaluados, lo que a primera vista sugeriría que ningún modelo produce datos estadísticamente indistinguibles de los reales. Sin embargo, este resultado no debe interpretarse como un fracaso generalizado de los modelos generativos, sino como una limitación del test de discriminación con clasificadores de alta capacidad. XGBoost con 300 estimadores y profundidad 4 sobre 125 *features* es un adversario extremadamente poderoso: puede detectar incluso diferencias distribucionales muy sutiles que no tienen relevancia clínica práctica. Este fenómeno es consistente con la literatura sobre evaluación de datos sintéticos tabulares, que advierte de que el AUC del clasificador tiende a saturar en 1,0 cuando el clasificador es suficientemente expresivo, independientemente de la calidad del generador [20]. Las métricas JSD, MMD² y $\Delta\rho$ son, en este contexto, indicadores más informativos de la calidad diferencial entre modelos.

Síntesis. Tomados en conjunto, los resultados posicionan a **TVAE** como el modelo con mayor fidelidad estadística global sobre esta cohorte, siendo el mejor o segundo mejor en todas las métricas excepto JSD marginal (donde empatía prácticamente con CTGAN). **CTGAN** ofrece resultados equivalentes y constituye la referencia natural para la comparación con las variantes DP. **DP-CTGAN con $\varepsilon = 10$** es la variante con privacidad formal que mejor equilibra fidelidad y garantías: su JSD (0,040) permanece cercana a la de CTGAN sin DP, con un coste en correlaciones ($\Delta\rho = 0,144$) moderado. **TabDDPM** captura bien la estructura de correlaciones conjuntas pero no logra reproducir las distribuciones marginales con la configuración utilizada, lo que limita su utilidad directa para tareas de síntesis tabular en datasets de tamaño moderado sin tratamiento diferenciado por tipo de columna.

Experimento de ablación: normalización por columna en TabDDPM. La distorsión marginal de TabDDPM motivó un experimento de ablación dirigido a identificar si la causa residía en la estrategia de normalización del preprocesador. El experimento (nb05b) sustituyó el único `QuantileTransformer` global del preprocesador original por un transformador independiente para cada una de las 115 columnas numéricas e incorporó una operación de *clipping* de las muestras generadas al rango observado durante el entrenamiento antes de aplicar la transformada inversa. La arquitectura del modelo, los hiperparámetros y el protocolo de entrenamiento permanecieron idénticos al experimento principal.

El resultado fue negativo: la JSD mediana pasó de 0,651 a 0,650 (variación de $-0,001$), estadísticamente indistinguible. El diagnóstico de los valores generados reveló la causa subyacente: en el espacio normalizado, el modelo producía muestras en el rango $[-24.282, +22.036]$, frente al rango de entrenamiento de aproximadamente $[-5,20, +5,20]$. El *clipping* elimina la extrapolación lineal del `QuantileTransformer` para valores extremos, pero no recupera la distribución correcta de las muestras dentro del rango recortado: el problema no es cómo se invierte la transformación, sino que el proceso de difusión inverso genera puntos que se alejan progresivamente del soporte de la distribución de entrenamiento durante los $T = 1.000$ pasos de denoising.

La conclusión de la ablación es que la distorsión marginal de TabDDPM sobre esta cohorte no es corregible mediante preprocesamiento. La causa es la divergencia del proceso de difusión inverso: la red denoiser no logra anclar las muestras generadas al soporte de la distribución de entrenamiento. Este diagnóstico es coherente con la paradoja $\Delta\rho$ observada: si el modelo aprende la estructura de correlaciones lineales con buena fidelidad ($\Delta\rho = 0,056$) pero no los valores absolutos de cada variable, el proceso converge en la dirección correcta en el espacio latente pero no al punto correcto en el espacio original. La corrección requiere intervenciones en la arquitectura del proceso de difusión o un tratamiento diferenciado por distribución de columna, lo que se identifica como línea de trabajo futuro en el Capítulo 6.

5.2. Validación de Utilidad Analítica

La fidelidad estadística, evaluada en la sección anterior, cuantifica en qué medida los datos sintéticos reproducen la distribución de los reales, pero no garantiza por sí sola que esos datos sean útiles para construir modelos predictivos. Una distribución sintética puede ser fiel a nivel marginal e individual y aun así no preservar las relaciones entre variables que los clasificadores clínicos explotan. Por ello, la utilidad analítica se evalúa de forma indirecta: se entrena un modelo predictivo sobre los datos sintéticos y se mide cuánto rinde sobre datos reales no vistos durante el entrenamiento. Este planteamiento, conocido como TSTR (*Train on Synthetic, Test on Real*), es el protocolo estándar en la literatura de síntesis de datos clínicos [11, 20].

5.2.1. Framework de validación TRTR/TSTR

El protocolo parte de una partición fija del dataset real: el 80 % de las estancias (18.016 registros) se usa como conjunto de entrenamiento de referencia y el 20 % restante (4.504 registros) como conjunto de test, con muestreo estratificado para mantener la proporción de mortalidad del 13,8 % en ambas partes. Este conjunto de test permanece invariado en todos los experimentos de la sección, lo que permite comparar directamente entre protocolos y modelos.

El experimento **TRTR** (*Train on Real, Test on Real*) entrena cada clasificador sobre el 80 % real y establece la cota superior de rendimiento alcanzable con datos reales. El experimento **TSTR** (*Train on Synthetic, Test on Real*) entrena el mismo clasificador sobre el dataset sintético completo ($N = 22.520$) y evalúa sobre el test fijo. El gap $\Delta\text{AUROC} = \text{AUROC}_{\text{TSTR}} - \text{AUROC}_{\text{TRTR}}$ cuantifica la pérdida de utilidad al sustituir datos reales por sintéticos; valores próximos a cero indican que los datos sintéticos son un sustituto efectivo.

Se emplean cuatro clasificadores *downstream*: regresión logística (LogReg), *random forest* con 200 árboles (RF), XGBoost y un perceptrón multicapa con capas ocultas (128, 64) (MLP). El desbalance de clases (86/14 %) se gestiona con `class_weight=balanced` para LogReg, RF y MLP, y con `scale_pos_weight=6,24` para XGBoost. Las métricas reportadas son AUROC, AUPRC y F1 con umbral 0,5, promediadas sobre los cuatro clasificadores. La AUPRC resulta especialmente informativa en este contexto porque penaliza fuertemente la clasificación incorrecta de la clase minoritaria (fallecidos), que es precisamente la de mayor relevancia clínica.

5.2.2. Tarea principal: predicción de mortalidad

Línea base TRTR. Los cuatro clasificadores entrenados sobre datos reales obtienen resultados coherentes, con AUROC entre 0,864 (LogReg) y 0,886 (XGBoost). La media sobre los cuatro es $\text{AUROC} = 0,873$, $\text{AUPRC} = 0,559$ y $\text{F1} = 0,459$. El F1 moderado es esperable con clases desbalanceadas y umbral fijo en 0,5; el AUROC confirma que todos los clasificadores discriminan razonablemente bien entre fallecidos y supervivientes cuando se permite variar el umbral. XGBoost es consistentemente el mejor clasificador individual, resultado habitual en tablas de tamaño moderado [38].

Resultados TSTR. La Tabla 5.2 recoge los resultados TSTR para los siete modelos generativos junto con el baseline TRTR. Todos los modelos experimentan cierta degradación respecto al baseline.

TVAE es el modelo con menor degradación ($\text{AUROC} 0,835$, $\Delta\text{AUROC} -0,038$), lo que resulta coherente con su mayor fidelidad estadística global en §5.1.6: mejores distribuciones marginales y menor desviación en la estructura de correlaciones se traducen en un menor impacto sobre el rendimiento predictivo.

CTGAN y **TabDDPM** presentan ΔAUROC similares ($-0,095$ y $-0,093$), pero

Tabla 5.2: Resultados TRTR y TSTR para predicción de mortalidad intrahospitalaria, promediados sobre cuatro clasificadores *downstream*. Δ AUROC mide la diferencia respecto al baseline TRTR. Los modelos DP-CTGAN se ordenan de menor a mayor privacidad (mayor a menor ε).

Condición	AUROC	AUPRC	F1	Δ AUROC
TRTR (baseline)	0,873	0,559	0,459	<i>ref.</i>
TVAE	0,835	0,456	0,353	−0,038
TabDDPM	0,780	0,391	0,005	−0,093
CTGAN	0,778	0,361	0,344	−0,095
DP-CTGAN $\varepsilon=\infty$	0,744	0,350	0,284	−0,129
DP-CTGAN $\varepsilon=10$	0,692	0,283	0,247	−0,181
DP-CTGAN $\varepsilon=5$	0,713	0,291	0,224	−0,160
DP-CTGAN $\varepsilon=1$	0,663	0,230	0,172	−0,210

el F1 de TabDDPM es prácticamente cero en todos los clasificadores. La interpretación de este resultado no es trivial: los modelos entrenados sobre datos TabDDPM aprenden relaciones ordinales correctas entre variables y mortalidad (de ahí el AUROC razonable), pero el umbral de decisión óptimo aprendido en el espacio sintético no se transfiere al espacio real. Este comportamiento es consecuencia directa de la distorsión de las distribuciones marginales documentada en §5.1.6, donde TabDDPM obtuvo una JSD mediana de 0,644 frente a los 0,008 de CTGAN y TVAE. En la práctica, un F1 cercano a cero implica que el modelo colapsaría ante cualquier despliegue clínico con umbral fijo, lo que lo descarta como generador útil para esta tarea sin un ajuste posterior del umbral de decisión.

Las variantes **DP-CTGAN** muestran una degradación general al reducir ε , aunque con una ligera irregularidad entre $\varepsilon=5$ y $\varepsilon=10$ (0,713 frente a 0,692), atribuible a la varianza del entrenamiento GAN más que a un efecto real del presupuesto de privacidad. La tendencia general de $\varepsilon=\infty$ a $\varepsilon=1$ (−0,129, −0,160/−0,181, −0,210) es consistente con lo esperado teóricamente. Es relevante señalar que DP-CTGAN $\varepsilon=\infty$ (sin ruido DP) obtiene un AUROC de 0,744, inferior al de CTGAN (0,778) a pesar de pertenecer a la misma familia generativa adversarial. Esta diferencia refleja las limitaciones de la arquitectura simplificada implementada en este trabajo, sin normalización por moda ni muestreo condicional, y no es atribuible a la privacidad diferencial. El coste real del mecanismo DP se mide como la diferencia entre DP-CTGAN $\varepsilon=\infty$ y las variantes con presupuesto finito: un deterioro adicional de 0,031 a 0,081 puntos de AUROC según el nivel de protección elegido.

5.2.3. Experimento de data augmentation clínico

Un escenario de uso frecuente en investigación biomédica es disponer de un conjunto de datos reales limitado que se quiere ampliar con datos sintéticos. Para evaluarlo, se diseña un experimento de *data augmentation*: el conjunto de entrenamiento aumen-

tado combina los 18.016 registros reales del split de entrenamiento con otros 18.016 registros sintéticos muestreados aleatoriamente del dataset generativo, resultando en 36.032 muestras (50 % real, 50 % sintético). El mismo test fijo se usa para la evaluación.

Tabla 5.3: Comparación de AUROC entre TSTR puro y TSTR con *data augmentation* (50 % real + 50 % sintético) para predicción de mortalidad. La columna “Ganancia” recoge la diferencia de AUROC entre augmentation y TSTR puro.

Modelo	AUROC TSTR	AUROC aug	Δ vs TRTR	Ganancia
TVAE	0,835	0,868	−0,005	+0,033
CTGAN	0,778	0,865	−0,008	+0,088
TabDDPM	0,780	0,865	−0,008	+0,085
DP-CTGAN $\varepsilon=\infty$	0,744	0,862	−0,011	+0,118
DP-CTGAN $\varepsilon=10$	0,692	0,858	−0,015	+0,166
DP-CTGAN $\varepsilon=5$	0,713	0,858	−0,015	+0,145
DP-CTGAN $\varepsilon=1$	0,663	0,863	−0,010	+0,200
TRTR (baseline)		0,873		

El resultado más destacable es que todos los modelos recuperan prácticamente el rendimiento de referencia TRTR con augmentation, con una caída máxima de tan solo 0,015 puntos de AUROC (Tabla 5.3). Esto ocurre incluso en los modelos con mayor degradación en TSTR puro: TabDDPM, cuyo F1 era prácticamente cero en TSTR, recupera un F1 de 0,448 con augmentation, y DP-CTGAN $\varepsilon=1$, el modelo más degradado (Δ AUROC −0,210 en TSTR puro), alcanza un Δ AUROC de tan solo −0,010 con augmentation.

Este resultado tiene implicaciones directas para el uso práctico de los modelos. La mayor ganancia del augmentation la obtienen precisamente los modelos con peor rendimiento en TSTR puro: las variantes DP-CTGAN $\varepsilon=1$ y $\varepsilon=10$ ganan 0,200 y 0,166 puntos de AUROC al combinarse con datos reales. Esto sugiere que los datos sintéticos con garantías formales de privacidad, aunque no sustituyan a los datos reales en calidad predictiva directa, sí son una herramienta válida para complementar colecciones de datos clínicos limitadas.

5.2.4. Tarea secundaria: detección de sepsis

Como tarea secundaria se evalúa la preservación de correlaciones clínicas mediante la detección de sepsis. El *ground truth* se construye aplicando el criterio **qSOFA** (Quick SOFA) de Sepsis-3 [39] sobre las variables del snapshot de 48 horas: presencia de taquipnea ($\text{resp_rate_mean} \geq 22$), hipotensión ($\text{sbp_mean} \leq 100$ mmHg) y alteración del estado mental ($\text{gcs_total_mean} \leq 14$). Un paciente se clasifica como caso de sepsis si cumple al menos dos de los tres criterios ($\text{qSOFA} \geq 2$), resultando en una prevalencia del 16,6 % (3.733 de 22.520 pacientes). La correlación entre el proxy de sepsis y la mortalidad intrahospitalaria es $r = 0,195$, en la dirección esperada clínicamente.

El experimento TSTR de sepsis funciona de forma diferente al de mortalidad: dado que el label qSOFA es una función determinista de tres variables del dataset, se puede calcular también sobre los datos sintéticos. El clasificador se entrena sobre los datos sintéticos con el qSOFA derivado de sus propias variables y se evalúa sobre el test real con el qSOFA real. Esto mide si el modelo generativo preserva las correlaciones clínicas que definen el síndrome séptico, más allá de reproducir el valor numérico de cada variable por separado.

El baseline TRTR sepsis alcanza un AUROC medio de 0,973 sobre los cuatro clasificadores (RF y XGBoost logran AUROC = 1,000 al aprender trivialmente la regla de umbral de tres variables). Los resultados TSTR se muestran a continuación:

Tabla 5.4: AUROC para detección de sepsis ($\text{qSOFA} \geq 2$) en el experimento TSTR. XGBoost como clasificador único. La columna de prevalencia indica el porcentaje de pacientes qSOFA+ en el dataset sintético.

Modelo	AUROC	ΔAUROC	Prev. sintética
TRTR (baseline)	0,973	<i>ref.</i>	16,6 %
CTGAN	1,000	+0,027	11,0 %
TVAE	1,000	+0,027	15,7 %
DP-CTGAN $\varepsilon=\infty$	1,000	+0,027	29,0 %
DP-CTGAN $\varepsilon=10$	1,000	+0,027	17,5 %
DP-CTGAN $\varepsilon=5$	1,000	+0,027	30,1 %
TabDDPM	0,974	+0,001	52,1 %
DP-CTGAN $\varepsilon=1$	0,868	-0,105	14,4 %

Seis de los siete modelos preservan las correlaciones clínicas que definen el síndrome séptico con $\text{AUROC} \geq 0,974$. El caso de TabDDPM merece atención: pese a que el 52,1 % de sus registros sintéticos cumplen $\text{qSOFA} \geq 2$ (frente al 16,6 % real), el clasificador entrenado sobre ellos alcanza un AUROC de 0,974 sobre el test real. Esto refuerza la interpretación ya avanzada en §5.2.2: TabDDPM preserva las relaciones ordinales y de correlación entre variables, pero desplaza sus valores absolutos de forma que los umbrales clínicos pierden vigencia en el espacio sintético. La distorsión marginal grave (JSD 0,644) no impide aprender que “pacientes con *resp_rate* alta, *sbp* baja y *gcs* bajo tienen mayor riesgo”, pero sí modifica los valores concretos en los que eso ocurre.

El único modelo con degradación significativa es **DP-CTGAN $\varepsilon=1$** , con AUROC de 0,868 ($\Delta\text{AUROC} -0,105$). Este es el primer resultado que muestra una ruptura cualitativa al nivel de protección de privacidad más alto: el ruido DP-SGD necesario para garantizar $\varepsilon=1$ sobre una cohorte de 22.520 pacientes es suficientemente grande como para que el generador deje de preservar relaciones clínicas elementales definidas por solo tres variables. Las variantes con $\varepsilon \geq 5$ mantienen intactas estas correlaciones, lo que sugiere que $\varepsilon=1$ representa el límite práctico a partir del cual el coste en coherencia clínica se vuelve relevante.

5.2.5. Discusión comparativa de utilidad

Los tres experimentos descritos permiten situar a cada modelo en relación con su utilidad analítica real. **TVAE** es el modelo con mayor utilidad directa: menor gap en TSTR de mortalidad ($\Delta\text{AUROC} -0,038$), buena preservación de correlaciones de sepsis y prevalencia sintética de mortalidad (5,1 %) aunque subestimada. **CTGAN** ofrece resultados comparables y constituye la referencia natural para las variantes DP dado que comparte familia generativa con DP-CTGAN.

TabDDPM presenta un perfil diferenciado: rendimiento de ranking razonable (AUROC 0,780) pero inutilizable con umbral fijo ($F1 \approx 0$). En un escenario de despliegue que permita ajustar el umbral de decisión sobre datos reales de validación, TabDDPM podría ser competitivo; en un escenario de uso directo de los datos sintéticos para entrenar y desplegar un clasificador, no lo es con la configuración aquí evaluada.

Las variantes **DP-CTGAN** confirman el tradeoff privacidad-utilidad de forma cuantitativa y consistente con lo predicho teóricamente: a menor ε , mayor degradación tanto en mortalidad como en sepsis. El análisis de augmentation añade una dimensión práctica importante: incluso bajo $\varepsilon=1$, los datos sintéticos combinados con un volumen moderado de datos reales recuperan el 99 % del rendimiento TRTR ($\Delta\text{AUROC} -0,010$). Esto indica que el uso adecuado de los datos sintéticos con privacidad diferencial no es la sustitución total de los datos reales, sino su complemento en escenarios donde el acceso a datos clínicos es parcial o restringido.

5.3. Análisis de Riesgos de Privacidad

5.3.1. Marco de auditoría de privacidad

La publicación de datos sintéticos genera dos categorías de riesgo de privacidad diferenciadas. La primera es el *riesgo de memorización*: el generador podría haber aprendido a reproducir registros concretos del dataset de entrenamiento, de forma que algunas muestras sintéticas sean copias o aproximaciones de pacientes reales. La segunda es el *riesgo inferencial*: aunque las muestras sintéticas no sean copias exactas, su distribución podría revelar qué registros participaron en el entrenamiento mediante ataques de inferencia de pertenencia [20].

Para cuantificar ambos riesgos se emplean tres métricas complementarias, calculadas en el espacio de *features* normalizado con el mismo StandardScaler de la evaluación de utilidad, de forma que variables con rangos muy distintos contribuyan equitativamente al cómputo de distancias [40].

DCR (Distance to Closest Record). Para cada muestra sintética s , se calcula la distancia euclídea al registro real más cercano en el dataset completo:

$$\text{DCR}(s) = \min_{r \in \mathcal{D}_{\text{real}}} \|s - r\|_2$$

La distribución de referencia se obtiene calculando el DCR del holdout real (4.504 registros) frente al training (18.016 registros). Si los generadores producen distribuciones DCR similares o más holgadas que esta referencia, no hay evidencia de memorización.

NNDR (Nearest Neighbor Distance Ratio). Detecta si una muestra sintética está cerca de un único registro real (indicador de copia) o se sitúa en una región de generalización entre varios:

$$\text{NNDR}(s) = \frac{d(s, \text{NN}_1)}{d(s, \text{NN}_2)}$$

Un NNDR próximo a 0 señala riesgo de memorización individual; próximo a 1 indica generalización [40].

MIA-advantage. Mide si las muestras sintéticas están sistemáticamente más cerca del conjunto de entrenamiento que del holdout, lo que indicaría retención de información sobre los registros vistos:

$$\text{MIA-adv} = P(d(s, \mathcal{D}_{\text{train}}) < d(s, \mathcal{D}_{\text{holdout}}) \mid s \in \mathcal{D}_{\text{synth}}) - 0,5$$

Un valor de 0 indica que no hay ventaja inferencial; valores positivos reflejan que los datos sintéticos están estadísticamente más próximos al training.

Dado que los generadores se entrenaron sobre el dataset completo, la partición 80/20 sirve únicamente como proxy para distinguir datos “vistos” de “no vistos” a efectos de la MIA. Todas las métricas se estiman sobre submuestras de $n_{\text{sub}} = 3\,000$ registros para acotar el coste computacional del cálculo de vecinos más próximos en 121 dimensiones.

5.3.2. Distancia al registro más cercano (DCR y NNDR)

La Tabla 5.5 recoge los resultados de las tres métricas para todos los modelos. La referencia del holdout real tiene una DCR mediana de 7,35: en el espacio normalizado de 121 dimensiones, un nuevo paciente real se sitúa, en mediana, a esa distancia del registro de entrenamiento más cercano.

La mayoría de los modelos generan datos con DCR mediana igual o superior a la del holdout real, lo que indica que las muestras sintéticas no están más cerca de los registros reales de lo esperado para datos nuevos de la misma distribución. **CTGAN** (9,47), las variantes **DP-CTGAN** con $\varepsilon \geq 5$ (8,03 a 8,59) y **DP-CTGAN** $\varepsilon=1$ (10,35) se sitúan todos por encima de la referencia.

TVAE es la excepción: su DCR mediana de 6,78 está por debajo del holdout real (ratio 0,922) y un 6 % de sus muestras cae bajo el percentil 5 de la referencia. Esto indica una tendencia a generar muestras relativamente próximas al espacio de entrenamiento, aunque el análisis NNDR que sigue descarta que se trate de memorización individual.

Tabla 5.5: Métricas de privacidad por modelo. DCR y NNDR calculados frente al dataset real completo (22.520 registros). MIA advantage: fracción de muestras sintéticas más cercanas al training que al holdout, menos 0,5. La fila de referencia corresponde al holdout real, cuyos valores representan el comportamiento esperado para datos nuevos de la misma distribución.

Modelo	DCR mediana	NNDR mediana	MIA advantage	AUROC TSTR
Holdout real (ref.)	7,353	0,974	+0,390	—
TVAE	6,782	0,978	+0,297	0,835
CTGAN	9,467	0,987	+0,271	0,778
TabDDPM	126,376	0,982	+0,199	0,780
DP-CTGAN $\varepsilon=\infty$	8,589	0,975	+0,300	0,744
DP-CTGAN $\varepsilon=10$	8,030	0,985	+0,284	0,692
DP-CTGAN $\varepsilon=5$	8,402	0,987	+0,274	0,713
DP-CTGAN $\varepsilon=1$	10,349	0,993	+0,221	0,663

TabDDPM registra un DCR mediana de 126,4, valor anómalamente alto que no refleja ninguna propiedad de privacidad por diseño, sino la consecuencia directa de las distribuciones marginales distorsionadas documentadas en §5.1.6: sus muestras se sitúan en regiones del espacio prácticamente ajenas al dataset real.

DP-CTGAN $\varepsilon=1$ presenta un comportamiento particular: mediana alta (10,35) pero percentil 5 bajo (4,61, el más bajo de todos los modelos). El ruido gaussiano de DP-SGD aleja a la mayoría de muestras del dataset real, pero una fracción pequeña queda empujada aleatoriamente hacia regiones próximas a algún registro concreto. Es el efecto esperado del ruido no estructurado y no implica memorización.

Los resultados NNDR son unánimes: todos los modelos presentan medianas entre 0,974 y 0,993, sin ningún caso por debajo del umbral de riesgo de 0,5. El holdout real tiene una mediana NNDR de 0,974, prácticamente idéntica a la de cualquier modelo. En espacios de alta dimensionalidad las distancias al primer y segundo vecino tienden a converger, elevando el NNDR hacia 1 de forma sistemática independientemente de si las muestras son reales o sintéticas. DCR y NNDR descartan en conjunto la hipótesis de memorización individual en todos los modelos evaluados.

5.3.3. Ventaja de inferencia de pertenencia (MIA)

El resultado más llamativo de la evaluación de privacidad es que todos los modelos generativos presentan una MIA advantage menor que la del propio holdout real (+0,390). A primera vista resulta contraintuitivo: ¿por qué los datos sintéticos parecen menos “identificables” con el training que los propios datos reales no vistos durante el entrenamiento?

La explicación es geométrica. Con 18.016 registros en el training y solo 4.504 en el holdout, cualquier muestra nueva de la misma distribución tiene mayor probabilidad de encontrar su vecino más cercano en el conjunto más grande, aunque no haya participado




Figura 5.4: Distribuciones DCR por modelo generativo. El panel superior izquierdo muestra el holdout real como referencia. La línea discontinua negra indica la mediana del holdout (7,35); la línea del color del modelo, su propia mediana. La distribución de DP-CTGAN $\epsilon=1$ exhibe una cola pronunciada hacia la derecha (mayoría de muestras muy alejadas del dataset real) junto con un pequeño peso en valores bajos, efecto característico del ruido gaussiano de DP-SGD.

en el entrenamiento. La MIA advantage del holdout real (+0,390) recoge este sesgo estructural, no memorización. Los datos sintéticos, al estar ligeramente desplazados respecto al training por el proceso generativo, puntúan por debajo de esta referencia de forma sistemática.

Con esta interpretación, **CTGAN** (+0,271), **TVAE** (+0,297) y las variantes **DP-CTGAN** (+0,221 a +0,300) se sitúan entre 0,079 y 0,169 puntos por debajo de la referencia del holdout. Ningún generador muestra evidencia de filtrar información sobre qué registros participaron en el entrenamiento de forma detectable con este protocolo. **TabDDPM** obtiene la MIA advantage más baja (+0,199), pero como en el caso del DCR, es consecuencia de la distorsión marginal y no de ninguna garantía de privacidad.




Figura 5.5: Ventaja de inferencia de pertenencia (MIA advantage) por modelo generativo. La línea discontinua gris indica la referencia del holdout real (+0,390); todos los modelos se sitúan por debajo, lo que indica que ningún generador revela más información sobre el conjunto de entrenamiento de la que revelaría un nuevo paciente real de la misma distribución. Las líneas de puntos naranja y roja marcan los umbrales orientativos de riesgo moderado (0,10) y alto (0,20).

5.3.4. Efecto de la privacidad diferencial sobre la MIA

Las cuatro variantes DP-CTGAN permiten comprobar si la garantía formal de (ϵ, δ) -privacidad diferencial se traduce en una reducción empírica y monótona del riesgo inferencial. Los valores de MIA advantage son:

$$\epsilon=\infty \rightarrow +0,300 \quad \epsilon=10 \rightarrow +0,284 \quad \epsilon=5 \rightarrow +0,274 \quad \epsilon=1 \rightarrow +0,221$$

La reducción total entre $\epsilon=\infty$ y $\epsilon=1$ es de 0,079 puntos, un 26 % de la ventaja inicial. El mecanismo es el descrito en §4.2.4: el ruido gaussiano introducido por DP-SGD en cada paso del gradiente difumina la distribución aprendida, haciendo que los datos generados sean progresivamente menos reconocibles como provenientes del conjunto de entrenamiento [18]. El parámetro teórico ϵ tiene por tanto interpretabilidad

práctica más allá de su definición formal: a menor ε , menor ventaja inferencial medida empíricamente.

5.3.5. Frontera Pareto privacidad-utilidad

La Figura 5.6 sintetiza los resultados en un espacio bidimensional que enfrenta la utilidad analítica (AUROC TSTR de §5.2.2) con el riesgo de privacidad (MIA advantage). El eje Y está invertido de forma que el vértice inferior representa mayor privacidad, y el objetivo ideal es la esquina inferior derecha.




Figura 5.6: Izquierda: frontera Pareto privacidad-utilidad. El eje X recoge el AUROC TSTR (utilidad, mayor es mejor) y el eje Y la MIA advantage (privacidad, menor es mejor; eje invertido). La línea discontinua gris indica la MIA advantage del holdout real como referencia. Derecha: curva de tradeoff ε para las variantes DP-CTGAN; eje izquierdo MIA advantage (morado), eje derecho AUROC TSTR (naranja).

TVAE domina el extremo de utilidad (AUROC 0,835, MIA 0,297) y **DP-CTGAN** $\varepsilon=1$ domina el extremo de privacidad (AUROC 0,663, MIA 0,221). Las variantes DP-CTGAN intermedias trazan una curva de compromiso a lo largo del eje ε : al reducir el presupuesto de privacidad de ∞ a 1, el AUROC baja 0,081 puntos mientras la MIA advantage se reduce 0,079. La tasa de intercambio es prácticamente simétrica, lo que indica que no existe ninguna configuración que ofrezca reducciones de riesgo sin coste equivalente en utilidad.

Ningún modelo sin DP alcanza la MIA advantage de DP-CTGAN $\varepsilon=1$ manteniendo utilidad competitiva, lo que confirma que la privacidad diferencial proporciona una garantía empírica adicional que no se obtiene solo por la naturaleza generativa del modelo. En escenarios donde la reducción del riesgo inferencial sea un requisito explícito, **DP-CTGAN** $\varepsilon=5$ ofrece un equilibrio razonable: AUROC 0,713 con MIA advantage de 0,274, inferior a la de cualquier modelo sin DP.

6. Conclusiones

6.1. Conclusiones

El objetivo de este Trabajo Fin de Grado ha sido desarrollar y evaluar un marco experimental de generación de datos clínicos sintéticos mediante modelos generativos profundos aplicados al dataset MIMIC-III [12], cuantificando de forma simultánea la fidelidad estadística de los datos generados, su utilidad analítica para tareas clínicas predictivas y el riesgo de privacidad que introducen, con especial atención al compromiso que impone la privacidad diferencial sobre la calidad de la síntesis. Los resultados obtenidos permiten concluir que este objetivo se ha alcanzado en sus cinco dimensiones específicas, aportando evidencia empírica sobre un conjunto de datos de UCI real de 22.520 pacientes.

OE1 — Construcción de la cohorte y pipeline de preprocesamiento. Se definió una cohorte de **22.520 estancias UCI** a partir de las 61.532 originales de MIMIC-III aplicando tres criterios de inclusión (primera estancia por paciente, duración ≥ 48 horas, edad ≥ 18 años), obteniendo una tasa de mortalidad del 13,8 % coherente con la literatura. El pipeline de preprocesamiento extrae y limpia 9.850.890 registros de constantes vitales y 1.394.837 de laboratorio, con una cobertura del 98,7 % y 99,2 % respectivamente, y produce dos representaciones reutilizables: un snapshot tabular de 22.520×127 columnas y un tensor de series temporales de $(22.235 \times 48 \times 10)$. El pipeline es reproducible y está verificado mediante un notebook de validación independiente.

OE2 — Implementación y entrenamiento de los modelos generativos. Se implementaron y entrenaron cuatro modelos generativos sobre el mismo snapshot tabular con semilla fija: **CTGAN** y **TVAE** como representantes de la familia adversarial y variacional, **TabDDPM** como modelo de difusión, y **DP-CTGAN** con cuatro presupuestos de privacidad $\varepsilon \in \{1, 5, 10, \infty\}$ mediante DP-SGD e integración con Opacus. Todos los modelos generan datasets sintéticos de tamaño $N = 22.520$ con valores dentro de los rangos fisiológicos esperados para los 127 atributos. La configuración de DP-CTGAN permite un barrido controlado del presupuesto de privacidad manteniendo constante el resto de hiperparámetros, lo que garantiza que cualquier diferencia de rendimiento sea atribuible exclusivamente al nivel de protección ε .

OE3 — Evaluación de la fidelidad estadística. La evaluación sobre cinco métricas complementarias (JSD marginal, KS, MMD², Wasserstein-1 y $\Delta\rho$) posiciona a **TVAE** como el modelo con mayor fidelidad global: JSD mediana de 0,0085, KS de 0,082, MMD² de 0,0053 y $\Delta\rho$ de 0,035, el mejor o segundo mejor en todas las métricas. **CTGAN** ofrece resultados equivalentes en la mayoría de métricas. **TabDDPM** reproduce bien la estructura de correlaciones conjuntas ($\Delta\rho = 0,056$) pero presenta una JSD de 0,644, dos órdenes de magnitud superior, lo que indica una distorsión sistemática de las distribuciones marginales con la configuración evaluada. Las variantes **DP-CTGAN** exhiben una degradación estrictamente monotónica en JSD y $\Delta\rho$ al reducir ε ($0,023 \rightarrow 0,042 \rightarrow 0,051 \rightarrow 0,106$ y $0,060 \rightarrow 0,147 \rightarrow 0,196 \rightarrow 0,375$), cuantificando empíricamente el coste en fidelidad de cada nivel de garantía formal de privacidad.

OE4 — Validación de la utilidad analítica. El protocolo TSTR sobre la tarea de predicción de mortalidad intrahospitalaria muestra que **TVAE** es el modelo con menor degradación respecto al baseline TRTR (AUROC 0,835, Δ AUROC $-0,038$), resultado coherente con su mayor fidelidad estadística. **CTGAN** obtiene un AUROC de 0,778 ($\Delta -0,095$). **TabDDPM** alcanza un AUROC de 0,780 pero con F1 prácticamente nulo, lo que lo descarta para despliegue con umbral fijo. Las variantes **DP-CTGAN** confirman la degradación monotónica esperada teóricamente (Δ AUROC entre $-0,129$ y $-0,210$). El experimento de *data augmentation* revela que todos los modelos, incluido **DP-CTGAN** $\varepsilon=1$, recuperan prácticamente el rendimiento TRTR cuando los datos sintéticos complementan un conjunto real (caída máxima de 0,015 puntos de AUROC), lo que establece el *augmentation* como el escenario de uso más eficaz. La tarea secundaria de detección de sepsis confirma que seis de los siete modelos preservan las correlaciones clínicas estructurales, con la única excepción de **DP-CTGAN** $\varepsilon=1$ (AUROC 0,868, $\Delta -0,105$).

OE5 — Cuantificación del compromiso privacidad-fidelidad en DP-CTGAN. La auditoría de privacidad mediante DCR, NNDR y MIA no detecta evidencia de memorización individual en ninguno de los modelos evaluados: todos presentan NNDR mediana entre 0,974 y 0,993, y ninguno supera la MIA advantage del propio holdout real ($+0,390$), que actúa como referencia de un nuevo paciente de la misma distribución. La secuencia de MIA advantage para **DP-CTGAN** es estrictamente decreciente con ε ($+0,300 \rightarrow +0,284 \rightarrow +0,274 \rightarrow +0,221$), una reducción del 26 % que confirma la interpretabilidad práctica del parámetro ε más allá de su definición formal. La frontera Pareto privacidad-utilidad es prácticamente simétrica: al reducir ε de ∞ a 1, el AUROC TSTR cae 0,081 puntos mientras la MIA advantage se reduce 0,079, sin ninguna configuración que ofrezca mejoras de privacidad sin coste equivalente en utilidad.

Limitaciones. Este trabajo presenta varias limitaciones que deben tenerse en cuenta al interpretar los resultados. En primer lugar, la cohorte proviene exclusivamente del

Beth Israel Deaconess Medical Center, un único hospital de Boston entre 2001 y 2012; la generalización de los modelos generativos y de las métricas de privacidad a otras poblaciones, sistemas sanitarios o periodos temporales no está garantizada. En segundo lugar, la **ventana de observación fija de 48 horas** no captura la evolución longitudinal completa de la estancia, lo que limita la representatividad de los datos generados para estudios de largo plazo. En tercer lugar, la implementación de **DP-CTGAN prescinde de la normalización por moda VGM y del muestreo condicional** por restricciones de compatibilidad con Opacus, lo que penaliza su rendimiento respecto al CTGAN estándar de forma independiente al nivel de privacidad. En cuarto lugar, **TabDDPM** presenta una limitación estructural en su proceso inverso de difusión: un experimento de ablación con normalización por columna independiente (QuantileTransformer por variable y clipping en espacio normalizado) confirmó que el origen de la distorsión marginal observada (JSD mediana de 0,644) no reside en el preprocesamiento global, sino en la divergencia del proceso generativo inverso, que produce muestras en rangos hasta cuatro órdenes de magnitud superiores al rango de entrenamiento normalizado ($[-24.282, +22.036]$ frente a $[-5, 20, +5, 20]$). Finalmente, la evaluación de la utilidad analítica se circunscribe a **dos tareas clínicas** (mortalidad y sepsis) sobre un único dataset; la capacidad de los datos sintéticos para sostener otras tareas predictivas o análisis observacionales más complejos no ha sido explorada.

Conclusión general. Los resultados obtenidos demuestran que es posible generar datos clínicos sintéticos de UCI con fidelidad estadística y utilidad analítica sustanciales a partir de MIMIC-III, y que la privacidad diferencial proporciona garantías empíricamente verificables con un coste en calidad simétrico y predecible. Entre los modelos evaluados, TVAE ofrece el mejor balance global entre fidelidad y utilidad en ausencia de requisitos formales de privacidad, mientras que DP-CTGAN con $\varepsilon=5$ representa un punto de equilibrio razonable cuando se requieren garantías formales: AUROC de 0,713 con MIA advantage de 0,274, inferior a cualquier modelo sin DP. El hallazgo más relevante desde el punto de vista práctico es que ningún modelo sirve de sustituto completo de los datos reales en tareas predictivas directas, pero todos son herramientas válidas para complementar colecciones de datos clínicos limitadas mediante *data augmentation*, recuperando prácticamente el rendimiento del baseline real con una fracción del coste de acceso a nuevos datos reales.

6.2. Trabajo futuro

Las limitaciones identificadas abren varias líneas de extensión natural para este trabajo. La más directa es la **incorporación de la representación temporal**: el tensor $(22.235 \times 48 \times 10)$ construido en este trabajo está listo para ser utilizado con modelos secuenciales como TimeGAN [26] o arquitecturas transformer, lo que permitiría evaluar si la síntesis de series temporales clínicas puede alcanzar una fidelidad comparable a

la tabular. En el plano de la privacidad diferencial, sería valioso reimplementar DP-CTGAN con **soporte completo para VGM y muestreo condicional** mediante una integración más profunda con Opacus, reduciendo la brecha de rendimiento respecto al CTGAN estándar que actualmente no es atribuible al mecanismo DP. Otra extensión relevante es la **exploración de presupuestos** $\varepsilon < 1$ con arquitecturas de mayor capacidad y datasets más grandes, para determinar el límite inferior del tradeoff privacidad-utilidad. La **generalización a otros datasets** (eICU Collaborative Research Database, MIMIC-IV) permitiría validar si los patrones observados son específicos de MIMIC-III o transferibles a otras poblaciones de UCI. En cuanto a **TabDDPM**, el experimento de ablación realizado descarta el preprocesamiento como causa principal de su alta JSD e identifica la divergencia del proceso inverso de difusión sobre distribuciones asimétricas y cero-infladas como el problema de fondo; abordar esta limitación requeriría modificaciones arquitectónicas al proceso de difusión, como schedules adaptativos por tipo de columna o la combinación con un autoencoder previo que proyecte los datos a un espacio latente gaussianizado antes de aplicar la difusión. Finalmente, una **validación clínica externa** por parte de especialistas en medicina intensiva, mediante protocolos de evaluación cualitativa de la plausibilidad de los registros sintéticos, dotaría de interpretabilidad clínica real a las métricas estadísticas aquí reportadas.

Bibliografía

- [1] Sabyasachi Dash, Sushil Kumar Shakyawar, Mohit Sharma, and Sandeep Kaur. Big data in healthcare: management, analysis and future prospects. *Journal of Big Data*, 6(1):1–25, 2019.
- [2] W Nicholson Price and I Glenn Cohen. Privacy in the age of medical big data. *Nature Medicine*, 25(1):37–43, 2019.
- [3] Julia Adler-Milstein and Eric Pfeifer. Information blocking: is it occurring and what policy strategies can address it? *The Milbank Quarterly*, 95(1):117–135, 2017.
- [4] Latanya Sweeney. Simple demographics often identify people uniquely. *Health (San Francisco)*, 671:1–34, 2000.
- [5] Luc Rocher, Julien M Hendrickx, and Yves-Alexandre De Montjoye. Estimating the success of re-identifications in incomplete datasets using generative models. *Nature Communications*, 10(1):3069, 2019.
- [6] Latanya Sweeney. k-anonymity: A model for protecting privacy. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 10(5):557–570, 2002.
- [7] Jason Walonoski, Mark Kramer, Joseph Nichols, Andre Quina, Chris Moesel, Dylan Hall, Carlton Duffett, Kudakwashe Dube, Thomas Gallagher, and Scott McLachlan. Synthea: An approach, method, and software mechanism for generating synthetic patients and the synthetic electronic health care record. *Journal of the American Medical Informatics Association*, 25(3):230–238, 2018.
- [8] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems*, volume 27, 2014.
- [9] Diederik P Kingma and Max Welling. Auto-encoding variational Bayes. In *International Conference on Learning Representations*, 2014.
- [10] Edward Choi, Siddharth Biswal, Bradley Malin, Jon Duke, Walter F Stewart, and Jimeng Sun. Generating multi-label discrete patient records using generative adversarial networks. In *Machine Learning for Healthcare Conference*, pages 286–305. PMLR, 2017.

- [11] Brett K Beaulieu-Jones, Zhiwei Steven Wu, Chris Williams, Ran Lee, Sanjeev P Bhavnani, James Brian Byrd, and Casey S Greene. Privacy-preserving generative deep neural networks support clinical data sharing. *Circulation: Cardiovascular Quality and Outcomes*, 12(7):e005122, 2019.
 - [12] Alistair E W Johnson, Tom J Pollard, Lu Shen, Li-Wei H Lehman, Mengling Feng, Mohammad Ghassemi, Benjamin Moody, Peter Szolovits, Leo Anthony Celi, and Roger G Mark. MIMIC-III, a freely accessible critical care database. *Scientific Data*, 3(1):160035, 2016.
 - [13] Lei Xu, Maria Skoularidou, Alfredo Cuesta-Infante, and Kalyan Veeramachaneni. Modeling tabular data using conditional GAN. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
 - [14] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, volume 33, pages 6840–6851, 2020.
 - [15] Akim Kotelnikov, Dmitry Baranchuk, Ivan Rubachev, and Artem Babenko. TabDDPM: Modelling tabular data with diffusion models. In *International Conference on Machine Learning*, pages 17564–17579. PMLR, 2023.
 - [16] Cynthia Dwork, Frank McSherry, Kobbi Nissim, and Adam Smith. Calibrating noise to sensitivity in private data analysis. In *Theory of Cryptography Conference*, pages 265–284. Springer, 2006.
 - [17] James Jordon, Jinsung Yoon, and Mihaela van der Schaar. PATE-GAN: Generating synthetic data with differential privacy guarantees. In *International Conference on Learning Representations*, 2019.
 - [18] Martin Abadi, Andy Chu, Ian Goodfellow, H Brendan McMahan, Ilya Mironov, Kunal Talwar, and Li Zhang. Deep learning with differential privacy. In *Proceedings of the ACM SIGSAC Conference on Computer and Communications Security*, pages 308–318, 2016.
 - [19] Ashkan Yousefpour, Igor Shilov, Alexandre Sablayrolles, Davide Testuggine, Karthik Prasad, Mani Malek, John Nguyen, Sayan Ghosh, Akash Bharati, Jessica Zhao, et al. Opacus: User-friendly differential privacy library in PyTorch. *arXiv preprint arXiv:2109.12298*, 2021.
 - [20] James Jordon, Luk Szpruch, Florimond Houssiau, Mirko Bottarelli, Giovanni Cherubin, Carsten Maple, Samuel N Cohen, and Adrian Wills. Synthetic data – what, why and how? *arXiv preprint arXiv:2205.03257*, 2022.
-

-
- [21] Pierangela Samarati and Latanya Sweeney. Protecting privacy when disclosing information: k-anonymity and its enforcement through generalization and suppression. Technical report, SRI International, 1998.
 - [22] Alan Genz and Frank Bretz. *Computation of Multivariate Normal and t Probabilities*. Springer, Berlin, Heidelberg, 2009.
 - [23] Nils Homer, Szabolcs Szelinger, Margot Redman, David Duggan, Waibhav Tembe, Jill Muehling, John V Pearson, Dietrich A Stephan, Stanley F Nelson, and David W Craig. Resolving individuals contributing trace amounts of DNA to highly complex mixtures using high-density SNP genotyping microarrays. *PLOS Genetics*, 4(8):e1000167, 2008.
 - [24] Andrew Y Ng and Michael I Jordan. On discriminative vs. generative classifiers: A comparison of logistic regression and naive Bayes. In *Advances in Neural Information Processing Systems*, volume 15, 2002.
 - [25] Martin Arjovsky, Soumith Chintala, and Léon Bottou. Wasserstein generative adversarial networks. In *International Conference on Machine Learning*, pages 214–223. PMLR, 2017.
 - [26] Jinsung Yoon, Daniel Jarrett, and Mihaela Van der Schaar. Time-series generative adversarial networks. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
 - [27] Zilong Zhao, Aditya Kumar, Robert Birke, and Lydia Y Chen. CTAB-GAN: Effective table data synthesizing. In *Asian Conference on Machine Learning*, pages 97–112. PMLR, 2021.
 - [28] Ary L Goldberger, Luis A N Amaral, Leon Glass, Jeffrey M Hausdorff, Plamen Ch Ivanov, Roger G Mark, Joseph E Mietus, George B Moody, Chung-Kang Peng, and H Eugene Stanley. PhysioBank, PhysioToolkit, and PhysioNet: components of a new research resource for complex physiologic signals. *Circulation*, 101(23):e215–e220, 2000.
 - [29] Jean-Louis Vincent, Rui Moreno, Jukka Takala, Sheila Willatts, Arnaldo De Mendonça, Hajo Bruining, C K Reinhart, P M Suter, and L G Thijs. The SOFA (Sepsis-related Organ Failure Assessment) score to describe organ dysfunction/-failure. *Intensive Care Medicine*, 22(7):707–710, 1996.
 - [30] Jean-Louis Vincent, Gareth Jones, Sabrina David, Elena Olariu, and Kimberley K Cadwell. Sepsis and septic shock: just the essentials. *Critical Care*, 22(1):116, 2018.
 - [31] Jascha Sohl-Dickstein, Eric A Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International Conference on Machine Learning*, pages 2256–2265. PMLR, 2015.
-

-
- [32] Alexander Quinn Nichol and Prafulla Dhariwal. Improved denoising diffusion probabilistic models. In *Proceedings of the 38th International Conference on Machine Learning*, pages 8162–8171. PMLR, 2021.
- [33] Jacob Austin, Daniel D Johnson, Jonathan Ho, Daniel Tarlow, and Rianne van den Berg. Structured denoising diffusion models in discrete state-spaces. In *Advances in Neural Information Processing Systems*, volume 34, pages 17981–17993, 2021.
- [34] Ilya Mironov. Rényi differential privacy. In *2017 IEEE 30th Computer Security Foundations Symposium*, pages 263–275. IEEE, 2017.
- [35] Arthur Gretton, Karsten M Borgwardt, Malte J Rasch, Bernhard Schölkopf, and Alexander Smola. A kernel two-sample test. *Journal of Machine Learning Research*, 13:723–773, 2012.
- [36] Leland McInnes, John Healy, and James Melville. UMAP: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426*, 2018.
- [37] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9:2579–2605, 2008.
- [38] Léo Grinsztajn, Edouard Oyallon, and Gaël Varoquaux. Why tree-based models still outperform deep learning on tabular data. In *Advances in Neural Information Processing Systems*, volume 35, pages 507–520, 2022.
- [39] Mervyn Singer, Clifford S Deutschman, Christopher W Seymour, Manu Shankar-Hari, Djillali Annane, Michael Bauer, Rinaldo Bellomo, Gordon R Bernard, Jean-Daniel Chiche, Craig M Coopersmith, et al. The third international consensus definitions for sepsis and septic shock (Sepsis-3). *JAMA*, 315(8):801–810, 2016.
- [40] Michael Platzer and Thomas Reutterer. Holdout-based fidelity and privacy assessment of mixed-type synthetic data. *Frontiers in Big Data*, 4:705084, 2021.
- [41] University College London. Transparency, authorship and generative AI in doctoral research. <https://www.ucl.ac.uk/study/doctoral-school/regulations/essential-procedures-and-policies/transparency-authorship-and-generative-ai-doctoral-research>, 2024. Consultado: mayo 2025.
- [42] Wageningen University & Research. How to document your GenAI use. <https://wur-studentsupport.screenstepslive.com/m/118226/1/1878197-how-to-document-your-genai-use>, 2024. Consultado: mayo 2025.
-

-
- [43] Norwegian School of Economics (NHH). Guidelines for use of AI tools in the work on master theses. <https://www.nhh.no/en/for-students/masters-thesis/guidelines-for-use-of-ai-tools-in-the-work-on-master-theses/>, 2024. Consultado: mayo 2025.
-

A. Variables del snapshot tabular (22.520 × 127)

El snapshot tabular construido en la Sección 4.1.5 contiene 127 columnas agrupadas en cinco categorías. La columna *Estadístico* indica qué agregaciones de la ventana de 48 horas se calculan para cada señal clínica (med: media, mn: mínimo, mx: máximo, sd: desviación típica). Las variables demográficas y de comorbilidad se incluyen directamente sin agregación temporal.

A.1 Variables administrativas y demográficas

Columna	Descripción	Tipo
icustay_id	Identificador único de estancia UCI	ID (excluido del entrenamiento)
age	Edad del paciente en años	Continua
gender	Género original (M/F)	Categórica
gender_male	Género codificado binariamente (1 = hombre)	Binaria
los	Duración de la estancia UCI (días)	Continua
admission_type	Tipo de ingreso (urgente, electivo...)	Categórica
insurance	Tipo de seguro médico	Categórica
ethnicity	Etnia del paciente	Categórica
hospital_expire_flag	Mortalidad intrahospitalaria (variable objetivo)	Binaria

Tabla A.1: Variables administrativas y demográficas (9 columnas).

A.2 Constantes vitales (CHARTEVENTS)

Para cada una de las 10 señales fisiológicas se calculan cuatro estadísticos sobre la ventana de 48 horas, resultando en 40 columnas. La columna `gcs_total_mean` es una undécima variable derivada (suma de los tres componentes GCS) para la que solo se computa la media.

Variable clínica	Columna base	Estadísticos	Unidad	Rango fisiológico
Frecuencia cardíaca	heart_rate	med, mn, mx, sd	lpm	0–300
Presión arterial sistólica	sbp	med, mn, mx, sd	mmHg	0–300
Presión arterial diastólica	dbp	med, mn, mx, sd	mmHg	0–200
Presión arterial media	mbp	med, mn, mx, sd	mmHg	0–250
Saturación de oxígeno	spo2	med, mn, mx, sd	%	50–100
Temperatura corporal	temp_c	med, mn, mx, sd	°C	25–45
Frecuencia respiratoria	resp_rate	med, mn, mx, sd	rpm	0–80
GCS ocular	gcs_eye	med, mn, mx, sd	1–4	1–4
GCS verbal	gcs_verbal	med, mn, mx, sd	1–5	1–5
GCS motor	gcs_motor	med, mn, mx, sd	1–6	1–6
GCS total (derivada)	gcs_total	med	3–15	3–15

Tabla A.2: Constantes vitales: 10 señales × 4 estadísticos + GCS total = 41 columnas.

A.3 Biomarcadores de laboratorio (LABEVENTS)

Para cada uno de los 18 biomarcadores se calculan los mismos cuatro estadísticos, resultando en 72 columnas.

Variable clínica	Columna base	Estad.	Unidad	Sistema orgánico
Creatinina	creatinine	med, mn, mx, sd	mg/dL	Renal
Nitrógeno ureico (BUN)	bun	med, mn, mx, sd	mg/dL	Renal
Bilirrubina	bilirubin	med, mn, mx, sd	mg/dL	Hepático
Albúmina	albumin	med, mn, mx, sd	g/dL	Hepático
Lactato	lactate	med, mn, mx, sd	mmol/L	Metabólico
Glucosa	glucose	med, mn, mx, sd	mg/dL	Metabólico
Exceso de base	base_excess	med, mn, mx, sd	mEq/L	Ácido-base
pH arterial	ph_arterial	med, mn, mx, sd	—	Ácido-base
PaO ₂	pao2	med, mn, mx, sd	mmHg	Ácido-base
PaCO ₂	paco2	med, mn, mx, sd	mmHg	Ácido-base
Bicarbonato	bicarbonate	med, mn, mx, sd	mEq/L	Ácido-base
Sodio	sodium	med, mn, mx, sd	mEq/L	Electrolitos
Potasio	potassium	med, mn, mx, sd	mEq/L	Electrolitos
Hemoglobina	hemoglobin	med, mn, mx, sd	g/dL	Hematología
Plaquetas	platelet	med, mn, mx, sd	×10 ³ /μL	Hematología
Leucocitos (WBC)	wbc	med, mn, mx, sd	×10 ³ /μL	Hematología
INR	inr	med, mn, mx, sd	—	Hematología
Troponina	troponin	med, mn, mx, sd	ng/mL	Cardíaco

Tabla A.3: Biomarcadores de laboratorio: 18 variables × 4 estadísticos = 72 columnas.

A.4 Comorbilidades derivadas (DIAGNOSES_ICD)

Columna	Comorbilidad	Código ICD-9	Prevalencia
comor_icc	Insuficiencia cardíaca congestiva	428.x	29,4 %
comor_diabetes	Diabetes mellitus	250.x	27,0 %
comor_epoc	EPOC	491-496	19,0 %
comor_sepsis	Sepsis	038.x	15,2 %
comor_erc	Enfermedad renal crónica	585.x	11,7 %

Tabla A.4: Comorbilidades binarias derivadas de DIAGNOSES_ICD (5 columnas).

Resumen: 9 (admin) + 41 (vitales) + 72 (laboratorio) + 5 (comorbilidades) = **127 columnas**.

B. Fidelidad estadística por variable

La Tabla 5.1 del Capítulo 5 reporta la mediana de la divergencia Jensen-Shannon (JSD) sobre las 121 variables numéricas evaluadas. Este anexo recoge las 20 variables con mayor JSD mediana a lo largo de los siete modelos, identificando qué señales clínicas resultan más difíciles de sintetizar. Los valores se calculan con histogramas de 50 *bins* sobre el rango del dataset real, del mismo modo que en el cuerpo principal.

Tabla B.1: Las 20 variables con mayor JSD mediana entre los siete modelos. Las celdas sombreadas corresponden a $\text{JSD} > 0,30$.

Variable	CTGAN	TVAE	TabDDPM	e= ∞	e=10	e=5	e=1
gcs_eye_min	0,004	0,000	0,133	gray!200,469	gray!200,469	gray!200,482	gray!200,519
gcs_motor_min	0,001	0,007	0,109	gray!200,408	gray!200,451	gray!200,464	gray!200,469
gcs_verbal_min	0,001	0,006	0,061	gray!200,388	gray!200,479	gray!200,508	gray!200,497
gcs_verbal_max	0,003	0,003	0,043	gray!200,377	gray!200,445	gray!200,455	gray!200,474
gcs_eye_max	0,001	0,004	0,131	gray!200,308	gray!200,385	gray!200,578	gray!200,470
gcs_verbal_std	0,031	0,019	gray!200,328	0,207	0,250	0,244	0,270
gcs_motor_max	0,002	0,003	0,129	0,231	gray!200,394	gray!200,485	gray!200,460
troponin_max	0,002	0,006	0,228	0,053	gray!200,344	gray!200,312	gray!200,366
albumin_min	0,008	0,012	gray!200,677	0,125	0,222	0,253	0,236
albumin_max	0,004	0,016	gray!200,680	0,119	0,222	0,234	0,221
troponin_std	0,002	0,005	0,242	0,072	0,206	0,223	0,288
albumin_std	0,070	0,200	gray!200,653	0,158	0,232	0,193	0,235
bilirubin_min	0,002	0,004	0,234	0,059	0,196	0,224	gray!200,300
troponin_mean	0,002	0,006	0,196	0,026	0,216	0,264	gray!200,351
albumin_mean	0,013	0,036	gray!200,678	0,117	0,213	0,227	0,194
gcs_verbal_mean	0,012	0,016	0,228	0,174	0,173	0,236	0,183
bilirubin_max	0,002	0,004	0,217	0,061	0,170	0,231	0,269
gcs_motor_std	0,010	0,017	gray!200,376	0,168	0,169	0,206	gray!200,389
bilirubin_std	0,006	0,011	gray!200,562	0,067	0,166	0,237	0,146
troponin_min	0,003	0,006	0,142	0,130	0,167	gray!200,349	0,266

Interpretación. Dos patrones dominan la tabla. El primero es la dificultad estructural de las **componentes mínimo y máximo de GCS**: las variables `gcs_eye_min`, `gcs_motor_min` y `gcs_verbal_min` acumulan JSD muy altas en las variantes DP-CTGAN (entre 0,39 y 0,52), mientras que CTGAN y TVAE las reproducen con JSD prácticamente nula. Esta asimetría refleja que la distribución de los mínimos de GCS está fuertemente concentrada en el valor mínimo de la escala (pacientes intubados), lo que resulta fácil de aprender para CTGAN y TVAE pero queda destruido por el ruido DP-SGD. El segundo patrón es el **fracaso de TabDDPM en biomarcadores de distribución muy asimétrica**: `albumin` (JSD 0,65–0,68) y `bilirubin_std` (JSD

0,56) presentan valores muy elevados, coherentes con la JSD mediana de 0,644 de ese modelo. CTGAN y TVAE reproducen estos biomarcadores con $JSD < 0,07$ en todos los casos.




Figura B.1: Divergencia Jensen-Shannon por variable y por modelo generativo. Cada punto representa una de las 121 variables numéricas evaluadas. Las variables con mayor JSD corresponden a los componentes GCS (en DP-CTGAN) y a los biomarcadores con distribuciones de cola larga como albúmina, troponina y bilirrubina (en TabDDPM).

C. Glosario de términos técnicos y clínicos

Este anexo recoge los términos técnicos y clínicos empleados a lo largo de la memoria cuya definición no se desarrolla en el cuerpo principal del texto o que, por su frecuencia de uso, se incluyen aquí como referencia rápida para el lector.

Términos clínicos

Biomarcador de laboratorio Parámetro bioquímico medido en sangre, orina u otros fluidos biológicos que refleja el estado funcional de un órgano o sistema. En este trabajo se emplean 18 biomarcadores que cubren la función renal, hepática, metabólica, respiratoria, electrolítica, hematológica y cardíaca.

Constante vital Medición fisiológica continua registrada por monitorización en UCI: frecuencia cardíaca, presión arterial sistólica/diastólica/media, saturación de oxígeno, temperatura, frecuencia respiratoria y escala de coma de Glasgow.

Escala de coma de Glasgow (GCS) Escala neurológica que evalúa el nivel de consciencia mediante tres componentes: respuesta ocular (1–4), verbal (1–5) y motora (1–6). La puntuación total varía entre 3 (coma profundo) y 15 (consciencia normal). En UCI, los pacientes intubados reciben GCS verbal = 1 por imposibilidad física de respuesta.

Mortalidad intrahospitalaria Variable binaria que indica si el paciente falleció durante el ingreso hospitalario, independientemente de si el fallecimiento ocurrió en UCI o en planta. En la cohorte de este trabajo, su prevalencia es del 13,8 %.

qSOFA (*Quick SOFA*) Criterio clínico simplificado para la identificación de pacientes con sospecha de sepsis fuera de UCI, definido por Sepsis-3 [39]. Puntúa tres variables: frecuencia respiratoria ≥ 22 rpm, presión arterial sistólica ≤ 100 mmHg y alteración del estado mental (GCS ≤ 14). Un qSOFA ≥ 2 indica riesgo elevado.

SOFA (*Sequential Organ Failure Assessment*) Escala de disfunción orgánica utilizada en UCI para cuantificar el deterioro progresivo de seis sistemas orgánicos. Es la base del diagnóstico formal de sepsis según los criterios Sepsis-3 [29].

UCI (Unidad de Cuidados Intensivos) Unidad hospitalaria especializada en la monitorización y tratamiento de pacientes con disfunciones orgánicas graves. En este trabajo, todos los pacientes proceden de las UCI del Beth Israel Deaconess Medical Center recogidas en MIMIC-III.

Términos de aprendizaje automático y síntesis de datos

Data augmentation Técnica que combina datos reales con datos sintéticos para aumentar el tamaño efectivo del conjunto de entrenamiento de un modelo predictivo. En este trabajo se evalúa un escenario con 50 % datos reales y 50 % datos sintéticos.

Distribución marginal Distribución de probabilidad de una única variable, obtenida integrando sobre el resto. Las métricas JSD y KS evalúan la fidelidad de las distribuciones marginales de cada columna por separado.

Fidelidad estadística Medida de la similitud entre la distribución del dataset sintético y la del dataset real. Una fidelidad alta implica que las distribuciones marginales, las correlaciones y la estructura conjunta se preservan.

Frontera de Pareto Conjunto de soluciones para las que ningún objetivo puede mejorarse sin empeorar otro. En el contexto de este trabajo, la frontera Pareto privacidad-utilidad recoge las configuraciones de DP-CTGAN para las que no es posible ganar privacidad sin perder utilidad analítica.

Mode collapse Fallo de entrenamiento de una GAN en el que el generador aprende a producir muestras de un subconjunto reducido de la distribución real, ignorando los modos restantes.

Privacidad diferencial (DP) Marco matemático que garantiza que la presencia o ausencia de cualquier individuo en el dataset de entrenamiento tiene un efecto acotado sobre la distribución de salida del modelo, cuantificado por el parámetro ϵ .

Re-identificación Proceso por el cual un individuo es vinculado a sus datos en un dataset supuestamente anonimizado, a partir de la combinación de quasi-identificadores con fuentes de datos externas.

Snapshot tabular Representación de la actividad clínica de las primeras 48 horas de cada estancia UCI como un único vector de características, calculado mediante estadísticos de agregación (media, mínimo, máximo, desviación típica) sobre los registros de constantes vitales y laboratorio dentro de esa ventana.

TSTR (*Train on Synthetic, Test on Real*) Protocolo de evaluación de utilidad analítica en el que un clasificador se entrena sobre datos sintéticos y se evalúa sobre datos reales. El gap de rendimiento respecto al caso TRTR (entrenamiento sobre datos reales) cuantifica la degradación debida a la sustitución de datos reales por sintéticos.

Utilidad analítica Medida de si los datos sintéticos son funcionalmente intercambiables con los datos reales para entrenar modelos predictivos. Se evalúa mediante el protocolo TSTR sobre tareas clínicas concretas (mortalidad, sepsis).

D. Declaración de uso de herramientas de IA generativa

Este anexo documenta el uso de herramientas de inteligencia artificial generativa (IAG) en la elaboración de este Trabajo Fin de Grado, de acuerdo con el principio de transparencia en la autoría promovido por las directrices académicas de instituciones europeas de referencia [41, 42, 43]. La declaración sigue el formato recomendado por el *Norwegian School of Economics* (NHH) y la *Wageningen University & Research* (WUR), adaptado al contexto de un TFG de grado.

El uso de herramientas de IAG en este trabajo se realizó con el conocimiento y la autorización expresa de los tutores desde el inicio del proyecto, bajo las siguientes condiciones acordadas: (i) asistencia en tareas de programación en las que el autor asumió en todo momento la comprensión, verificación y responsabilidad del código resultante; (ii) asistencia puntual en la redacción en inglés del Extended Abstract con revisión posterior; y (iii) uso limitado en la redacción de la memoria al apoyo en la corrección y revisión de ideas propias del autor, sin generación de contenido de relleno ni sustitución de la argumentación original.

El autor es plenamente responsable de todo el contenido de esta memoria, incluidas las partes en las que se emplearon herramientas de IAG como apoyo. Toda la información factual, los resultados experimentales, el código y las conclusiones han sido verificados, contrastados y asumidos críticamente por el autor. Las herramientas de IAG actuaron en todo momento como asistentes de proceso, nunca como fuente de conocimiento autónoma ni como generadoras de resultados de investigación.

Herramientas utilizadas

Tabla D.1: Resumen de herramientas de IAG empleadas en la elaboración del TFG.

Herramienta	Versión	Período	Finalidad y alcance
Claude / Claude Code (Anthropic)	Sonnet 4.5 / Sonnet 4.6	Feb.–May. 2025	Dos modalidades de uso: (1) asistencia en el desarrollo del código Python de los notebooks de experimentación (depuración, refactorización y sugerencias de implementación), con revisión, comprensión y validación independiente de todo el código por parte del autor antes de su incorporación al pipeline; (2) revisión y corrección de borradores de capítulos de la memoria, detección de inconsistencias y errores de formato LaTeX, ajuste de portadas, y preparación de la defensa oral. La redacción de las ideas, argumentos y conclusiones del trabajo es original del autor.
NotebookLM (Google)	Web (2024)	Feb.–Abr. 2025	Apoyo en la revisión bibliográfica: organización y consulta interactiva de artículos académicos en PDF (papers de referencia sobre modelos generativos, privacidad diferencial y evaluación de datos sintéticos). No se empleó para redactar ningún pasaje de la memoria ni para generar interpretaciones de los resultados propios.

Usos explícitamente excluidos

Las siguientes tareas **no** fueron realizadas con herramientas de IAG:

- Diseño del pipeline experimental y de las decisiones metodológicas del trabajo.
- Extracción, limpieza y preprocesamiento de los datos de MIMIC-III (notebooks 01_eda, 02_preprocessing, 03_data_validation).
- Entrenamiento de los modelos generativos (CTGAN, TVAE, TabDDPM, DP-CTGAN).
- Cálculo e interpretación de las métricas de fidelidad, utilidad analítica y privacidad (notebooks 08–10).
- Generación de las figuras y tablas de resultados incluidas en la memoria.

- Obtención, análisis y discusión de los resultados experimentales.

Declaración de responsabilidad

El autor declara que:

1. Ha revisado y asume la plena responsabilidad de todo el contenido generado con asistencia de herramientas de IAG, garantizando su exactitud, coherencia y adecuación al contexto científico del trabajo.
 2. Todo el código de investigación fue comprendido, verificado y ejecutado de forma independiente por el autor antes de incorporarlo al trabajo; los resultados experimentales son producto de dicha ejecución supervisada.
 3. Ha respetado en todo momento las obligaciones del *Data Use Agreement* de PhysioNet/MIMIC-III, sin compartir datos clínicos con ninguna herramienta de IAG externa.
 4. Es consciente de que la responsabilidad académica final sobre este trabajo recae íntegramente en su persona, con independencia de las herramientas empleadas como apoyo.
-